Lecture 6

代码优化和程序分析

徐 辉

xuh@fudan.edu.cn

学习地图

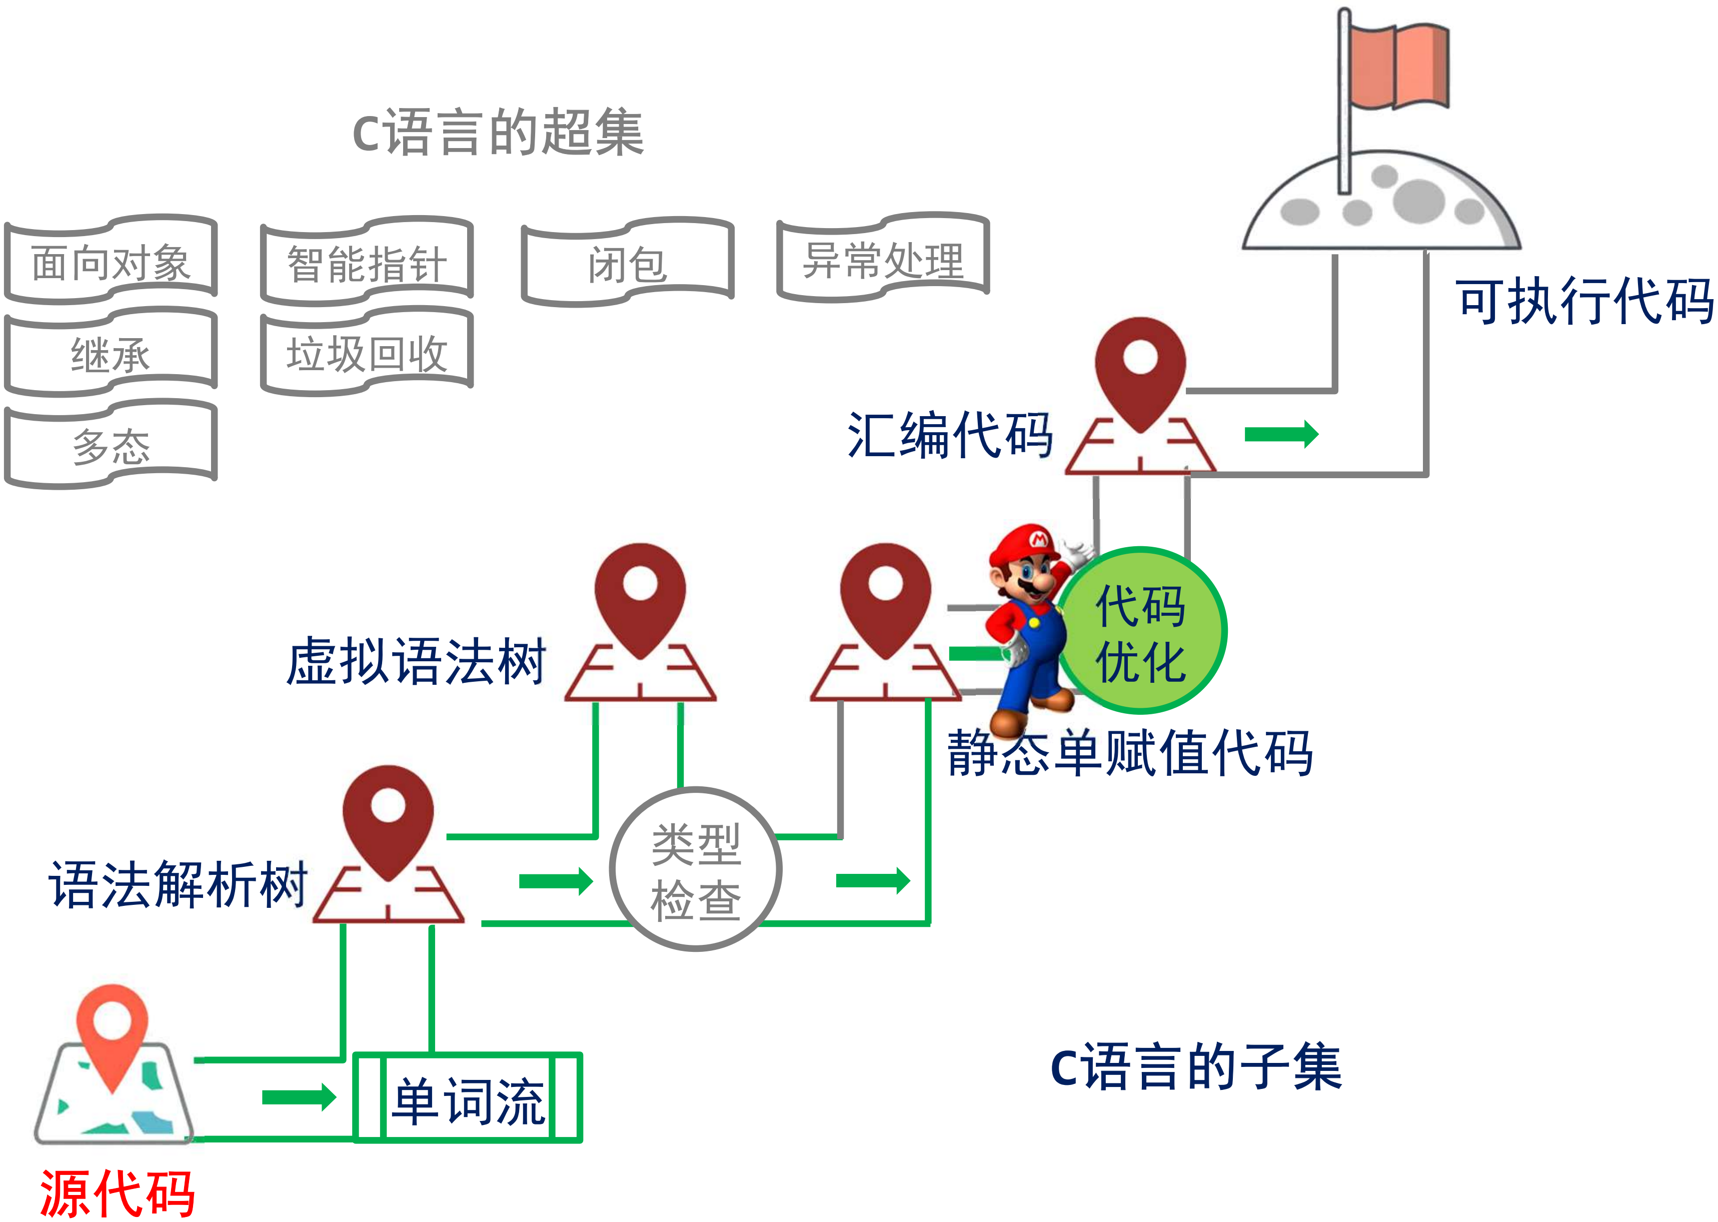
C语言的超集
面向对象
智能指针
闭包
异常处理
继承
垃圾回收
多态
可执行代码
汇编代码
代码
优化
虚拟语法树
静态单赋值代码
类型
检查
语法解析树
单词流
源代码
C语言的子集

大纲

- 一、代码优化问题
- 二、程序分析理论基础
- 三、数据流分析
- 四、指针分析

一、代码优化问题

LLVM的优化功能

```
#:opt -help
General options:

  --O0     - Optimization level 0. Similar to clang -O0
  --O1     - Optimization level 1. Similar to clang -O1
  --O2     - Optimization level 2. Similar to clang -O2
  --O3     - Optimization level 3. Similar to clang -O3
  --Os     - Like -O2 with extra optimizations for size. Similar to clang -Os
  --Oz     - Like -Os but reduces code size further. Similar to clang –Oz
…
```

```
#:llvm-as < /dev/null | opt –O1 -disable-output -debug-pass=Arguments
Pass Arguments:  -tti -tbaa -scoped-noalias -assumption-cache-tracker -
targetlibinfo -verify -ee-instrument -simplifycfg -domtree -sroa -early-cse -
lower-expect
…
```

LLVM的优化passes

LLVM’s Analysis and Transform Passes

- Introduction
- Analysis Passes
  - `-aa-eval`: Exhaustive Alias Analysis Precision Evaluator
  - `-basic-aa`: Basic Alias Analysis (stateless AA impl)
  - `-basiccg`: Basic CallGraph Construction
  - `-count-aa`: Count Alias Analysis Query Responses
  - `-da`: Dependence Analysis
  - `-debug-aa`: AA use debugger
  - `-domfrontier`: Dominance Frontier Construction

- Transform Passes
  - `-adce`: Aggressive Dead Code Elimination
  - `-always-inline`: Inliner for `always_inline` functions
  - `-argpromotion`: Promote ‘by reference’ arguments to scalars
  - `-bb-vectorize`: Basic-Block Vectorization
  - `-block-placement`: Profile Guided Basic Block Placement
  - `-break-crit-edges`: Break critical edges in CFG
  - `-codegenprepare`: Optimize for code generation
  - `-constmerge`: Merge Duplicate Global Constants
  - `-dce`: Dead Code Elimination

https://llvm.org/docs/Passes.html

主要的优化点

- 函数优化
- 全局变量优化
- 无效代码优化
- 循环优化

函数优化

- 传参优化：
  - -argpromotion: argument promotion
    - 将函数参数的引用传递改为值传第
  - -deadargelim: dead argument elimination
    - 删除内部函数的无效参数
- 调用优化：
  - -inline: function inlining
  - -tailcallelim: tail call elimination
    - 将尾递归内联展开

全局变量优化

- -constmerge: Merge Duplicate Global Constants
  - 合并相同的全局常量数据，如字符串
- -globaldce: Dead Global Elimination
  - 分析使用到的全局变量，删除其余的
- -globalopt: Global Variable Optimizer
  - 将符合条件的全局变量替换为常量

常量优化

- -sccp: sparse conditional constant propagation
  - 分析变量是否为常量，如果是则替换为常量
- -ipsccp: interprocedural sparse conditional constant propagation

无效代码优化

- -dce：dead code elimination
  - 删除不可达代码；
- -deadtypeelim：dead type elimination
  - 删除无用类型定义
- -sink：code sinking
  - 将代码向后移动，避免无用计算

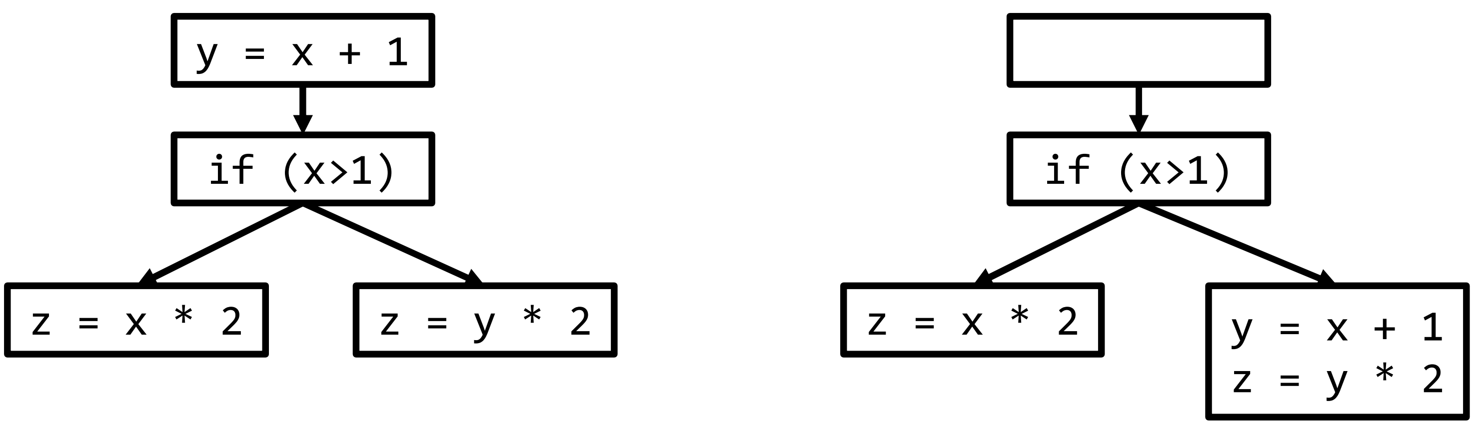

循环优化

- -loop-unroll: unroll loops
  - 循环展开
- -licm: Loop invariant code motion
  - 将循环内的代码移到循环外，避免重复计算
- -loop-unswitch: unswitch loops
  - 将循环内的条件语句移到循环外

```
for (...)
    A
    if (lic)
        B
    C
```

```
if (lic)
    for (...)
        A; B; C
else
    for (...)
        A; C
```

代码优化的核心问题和技术

- 核心问题：如何实现代码等价变换，提升代码效率。
- 核心技术：程序分析
  - 数据流分析
  - 控制流分析

二、程序分析理论基础

程序分析难题

- 一般来讲，程序属性（program properties）是不可计算的（undecidability）
  - 如：一个变量的值是否为常量？
- 一个算法可以做到即可靠（sound）又完备（complete）吗？
  - 不能，或者不能保证该算法一定可以退出（terminate）
- 如何设计程序分析算法是一门艺术。

莱斯定理：Rice's Theorem

CLASSES OF RECURSIVELY ENUMERABLE SETS
AND THEIR DECISION PROBLEMS(1)

BY

H. G. RICE

"Any nontrivial property about the language recognized by a Turing Machine is undecidable."

\- Henry Gordon Rice, 1953

Revisit Chomsky Hierarchy

Class	Languages	Automaton	Rules	Word Problem	Example
type-0	recursively enumerable	Turing machine	no restriction	undecidable	Post's corresp. problem
type-1	context sensitive	linear-bounded TM	$\alpha \to \gamma$ $\|\alpha\| \leq \|\gamma\|$	PSPACE-complete	$a^n b^n c^n$
type-2	context free	pushdown automaton	$A \to \gamma$	cubic	$a^n b^n$
type-3	regular	NFA / DFA	$A \to a$ or $A \to aB$	linear time	$a^* b^*$

证明方法1：规约到图灵机停机问题

- 假设算法A可以分析任意程序p中的某个变量x的值是否为常量，
- 设计一个程序p证明算法A不存在？

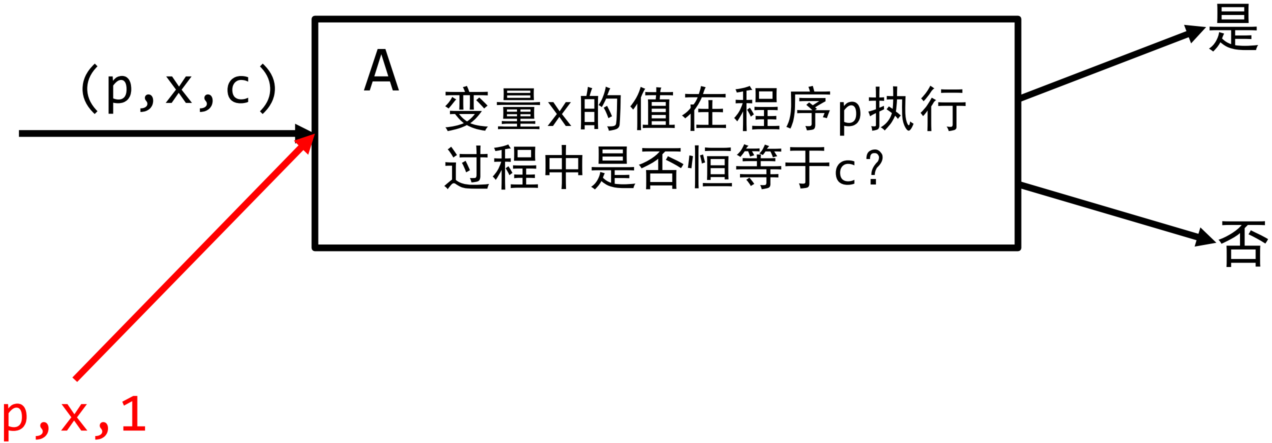


```
x = 1;
if (TM(j))
  x++;
```

当且仅当图灵机j不停机时，x为常量。

证明方法2：By Contradiction

- 假设算法A可以分析确定型图灵机T是否正确，输出accept或reject，如果无法分析则认为是fail。
  - 假设图灵机T正确指的是进入accept或reject状态；
  - 图灵机T错误是进入了fail状态。
- 如何构造矛盾？
  - 构造T的模拟器ST（<|w|steps）
  - 如果T结束在accept，则ST进入fail;
  - 如果T结束在其它状态或未结束，则ST为accept或reject

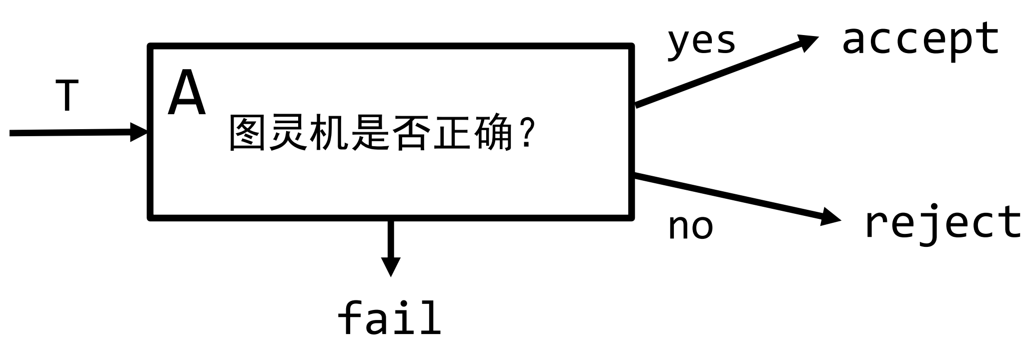

证明方法出处：Anders Møller, static program analysis

证明方法2：By Contradiction

- 如果T的结果为accept，则ST没有结束在fail状态；根据构造方法，ST的模拟对象S此时不能为accept，矛盾。
- 如果T的结果为reject，则说明ST结束在fail状态；根据构造方法，ST的模拟对象T此时应为accept，矛盾。

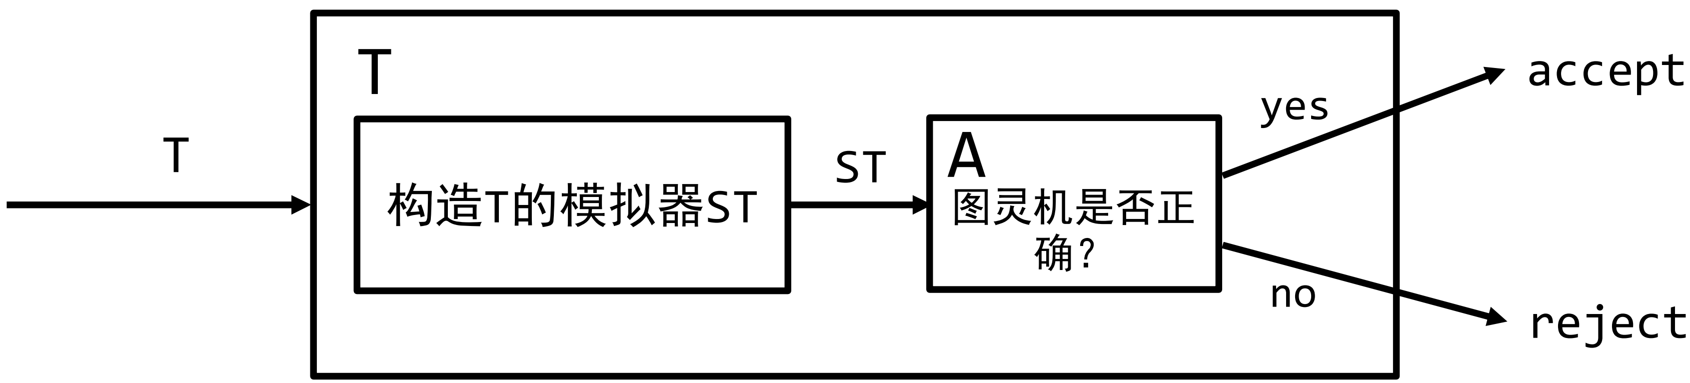

三、数据流分析

数据流分析

- 数据流分析：跟踪程序中的全部或一组变量的抽象值（abstract values）。
- 数据流分析问题举例：
  - 零值分析：变量x的取值可能为0吗？
    - 抽象值：{NZ, Z, MZ}
      - NZ: non-zero
      - Z: zero
      - MZ: maybe zero
  - 空指针分析：指针x可能为空指针吗？

如何分析除数为0的问题？

- 定义转移函数（transfer function）
  - 有哪些运算符会影响变量取值？
    - +, -, *, /, %...
- 定义合并函数（Join function）
  - Join(Z, Z) => Z
  - Join(NZ, NZ) => NZ
  - Join(Z, NZ) => MZ
  - Join(MZ, *) => MZ

应用：分析除数y是否可能为0？

```
x = 10;
y = x;
z = 0;
while (y>-1){
    x = x/y;
    y = y-1;
    z = 5;
}
```

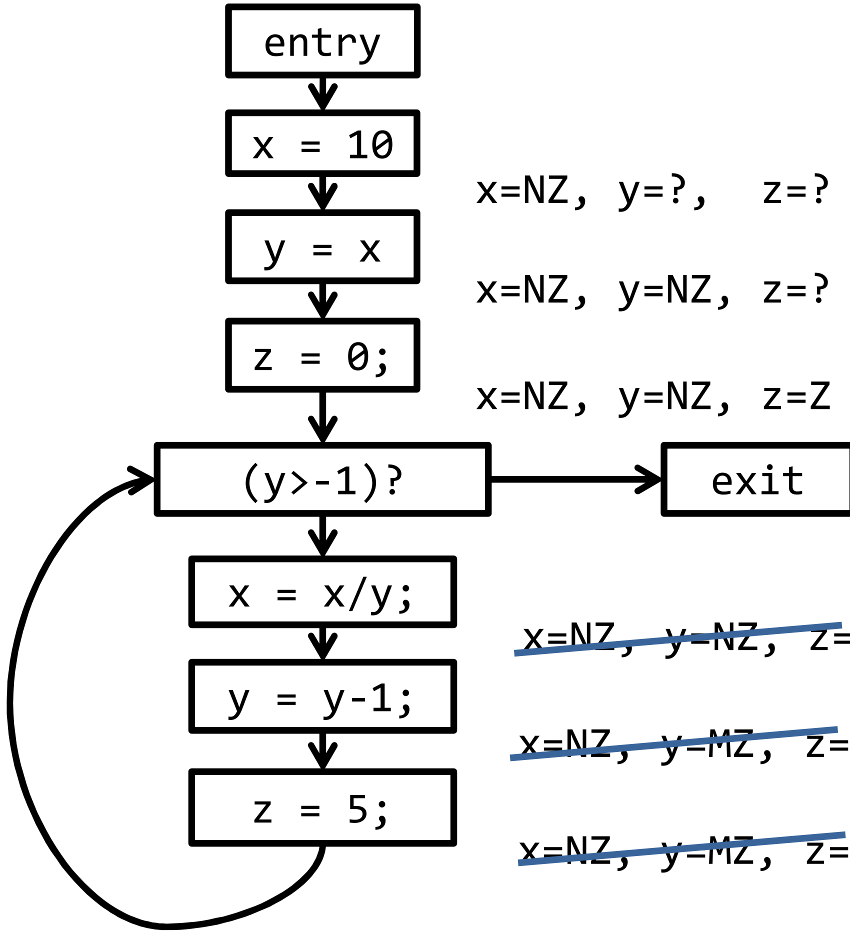

x=NZ, y=?, z=?

x=NZ, y=NZ, z=?

x=NZ, y=NZ, z=Z

~~x=NZ, y=NZ, z=Z~~ x=NZ, y=MZ, z=MZ

~~x=NZ, y=MZ, z=Z~~ x=NZ, y=MZ, z=MZ

~~x=NZ, y=MZ, z=NZ~~ x=NZ, y=MZ, z=MZ

数据流分析问题

- 可达性分析：Reaching definition analysis
  - 可用于常量分析、查找未初始化的变量
- 繁忙表达式分析：Very busy expression analysis
  - 优化代码体积
- 可用表达式分析：Available expression analysis
  - 避免重复计算相同的表达式
- 活跃变量分析：Live variable analysis
  - 寄存器分配

可达性分析

- 为每一个程序点（program point）分析某一变量的某个定义/赋值语句是否可达。

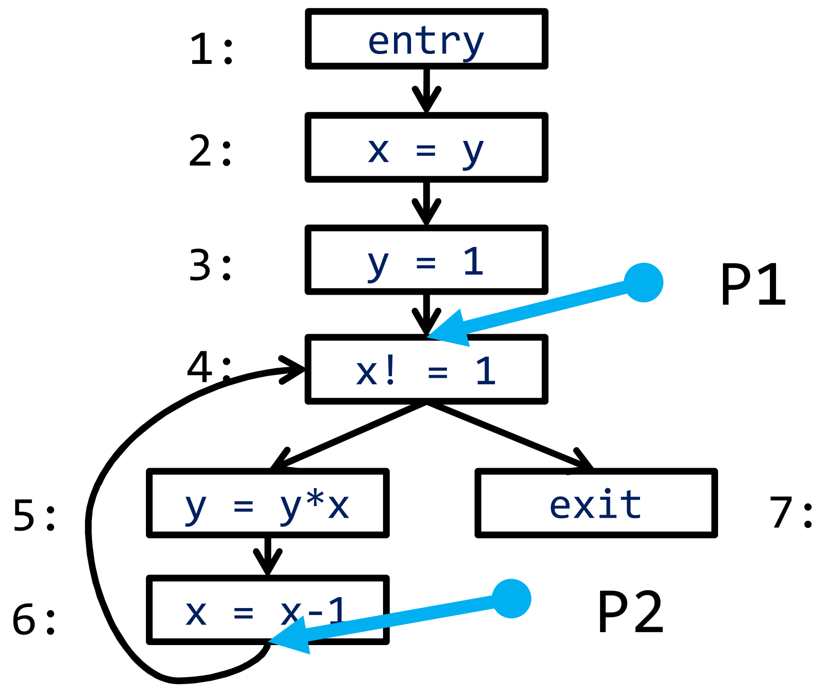

- y = 1 可到达P1
- y = 1 不能达到P2

分析方法

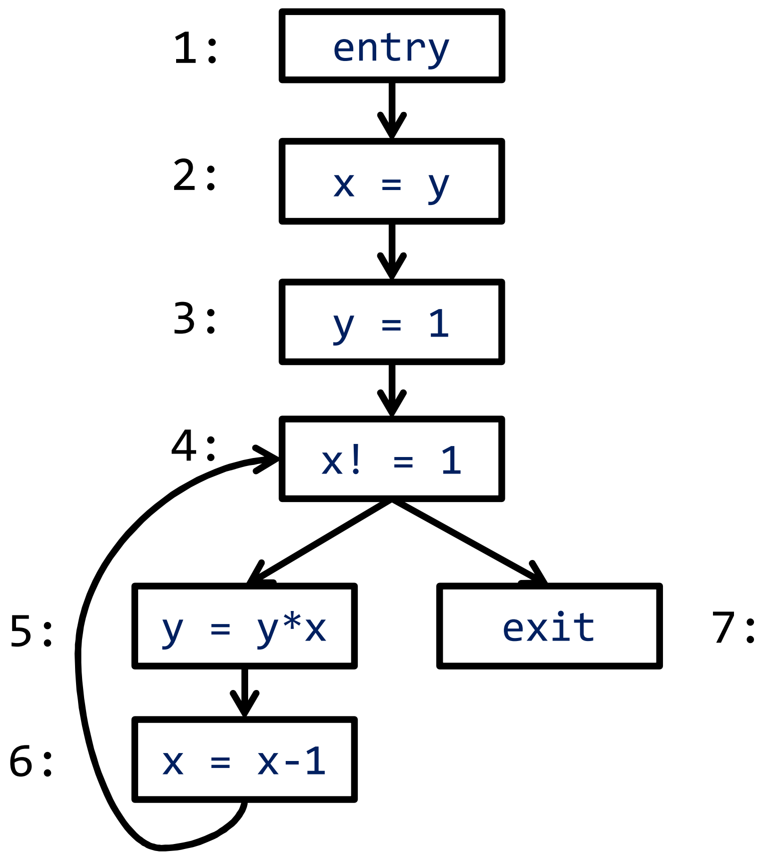

- 为每个节点分配一个编号
- 用IN(n)表示节点的入向属性集合。
- 用OUT(n)表示节点的出向属性集合。
- 遍历控制流图并应用Transfer和Join函数计算每一个节点的IN(n)和OUT(n)。
- 直到IN(n)和OUT(n)不再变化。

定义Transfer和Join函数

Transfer

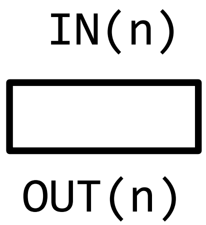

$$\mathrm{OUT(n)} = (\mathrm{IN(n)} - \mathrm{KILL(n)}) \cup \mathrm{Gen(n)}$$

n: `cond=?`

$$\mathrm{Gen(n)} = \emptyset$$
$$\mathrm{KILL(n)} = \emptyset$$

n: `x=a`

$$\mathrm{Gen(n)} = \{< x, n >\}$$
$$\mathrm{KILL(n)} = \{< x, m >: m \neq n\}$$

Join

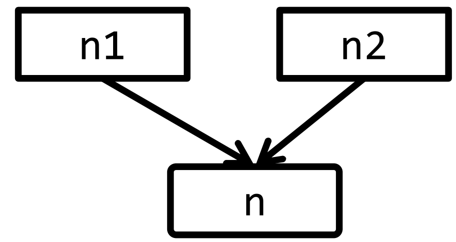

$$\mathrm{IN(n)} = \mathrm{OUT(n1)} \cup \mathrm{OUT(n2)}$$

$$\mathrm{IN}(n) = \bigcup_{n' \in \mathrm{predecessor}(n)} \mathrm{OUT}(n')$$

Chaotic Iteration

```
For (each node n):
    IN[n] = OUT[n] = ∅
OUT[entry] = {<v, ?>: v is a program variable}
Repeat:
    For(each node n):
        For(each n's predecessor p)
            IN[n] = IN[n] ∪ OUT[p]
        OUT(n)=(IN[n]-KILL(n)) ∪ Gen(n)
Until IN[n] and OUT[n] stops changing for all n
```

应用举例

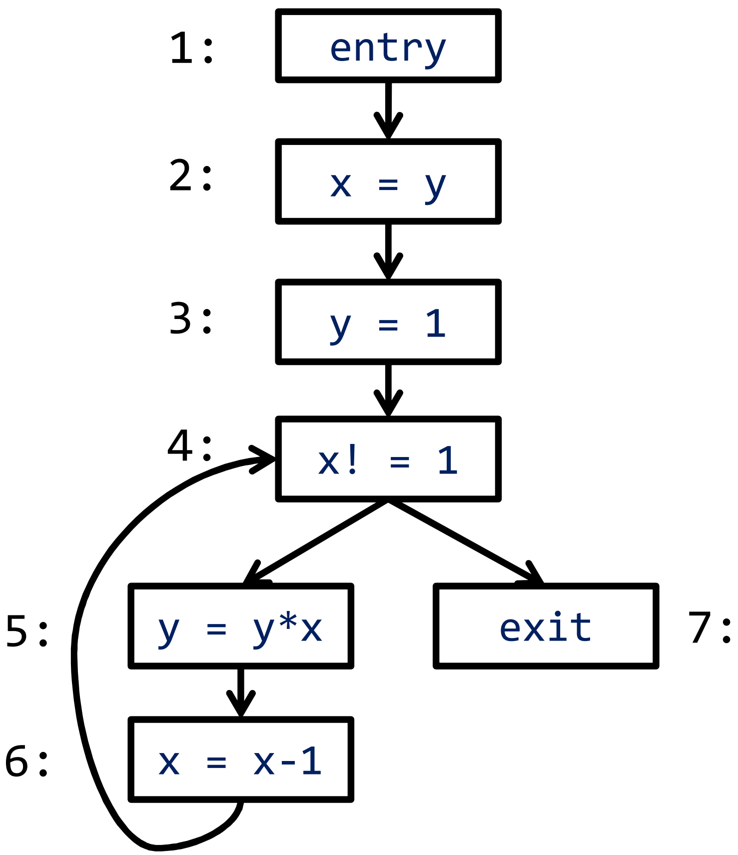

<x, n>: 表示变量x在第n个节点被赋值

n	IN(n)	OUT(n)
1	-	{<x,?><y,?>}
2	{<x,?><y,?>}	{<x,2><y,?>}
3	{<x,2><y,?>}	{<x,2><y,3>}
4	{<x,2><y,3><x,6><y,5>}	{<x,2><y,3><x,6><y,5>}
5	{<x,2><y,3><x,6><y,5>}	{<x,2><y,5><x,6>}
6	{<x,2><y,5><x,6>}	{<x,6><y,5>}
7	{<x,2><y,3><x,6><y,5>}	{<x,2><y,3><x,6><y,5>}

算法是否一定会终止？

- 可达定义分析的迭代算法一定会终止
  - Join和Transfer的两个函数是单调的（monotonic）
    - IN和OUT集合元素数目只会增加，不会减少。
  - IN集合OUT不可能无限扩大，最大是程序中所有定义语句的集合。
  - IN和OUT一定会在某一轮迭代后停止改变。

繁忙表达式分析

- 繁忙表达式：多条路径中都存在的公共表达式，且无论走那条路径，该表达式在其操作数被重新赋值之前被执行。

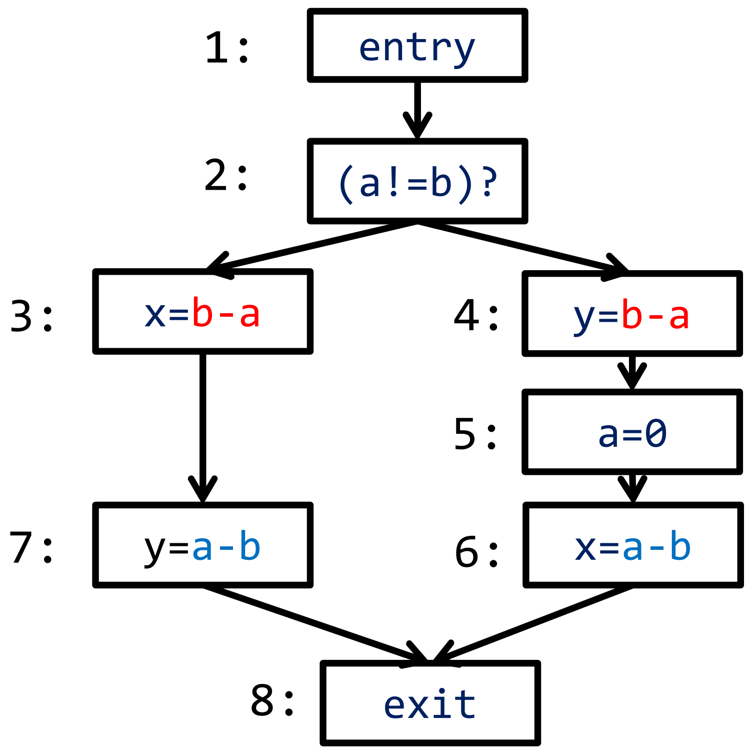

- b-a是繁忙表达式；
- a-b不是繁忙表达式

定义Transfer和Meet函数

Transfer

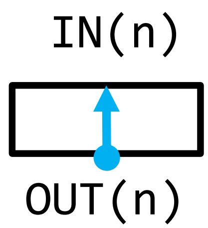

$$\mathrm{IN(n)} = (\mathrm{OUT(n)} - \mathrm{KILL(n)}) \cup \mathrm{Gen(n)}$$

n: cond?

$$\mathrm{Gen(n)} = \emptyset$$
$$\mathrm{KILL(n)} = \emptyset$$

n: x=a

$$\mathrm{Gen(n)} = \{a\}$$
$$\mathrm{KILL(n)} = \{\mathrm{expr\ e: e\ contains\ x}\}$$

Meet

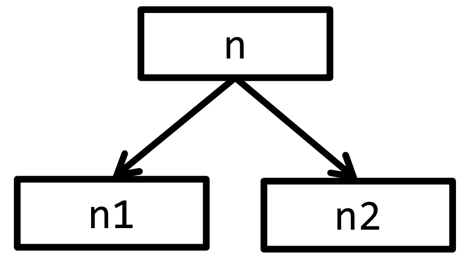

$$\mathrm{OUT(n)} = \mathrm{IN(n1)} \cap \mathrm{IN(n2)}$$

$$\mathrm{OUT(n)} = \bigcap_{\mathrm{n'} \in \mathrm{successor(n)}} \mathrm{IN(n')}$$

Chaotic Iteration

```
For (each node n):
    IN[n] = OUT[n] = set of all expressions in program
IN[exit] = Ø
Repeat:
    For(each node n):
        For(each n’s successor s):
            OUT[n] = OUT[n] ∩ IN[s]
        IN[n]=(OUT[n]-KILL(n)) ∪ Gen(n)
    Until IN[n] and OUT[n] stops changing for all n
```

练习

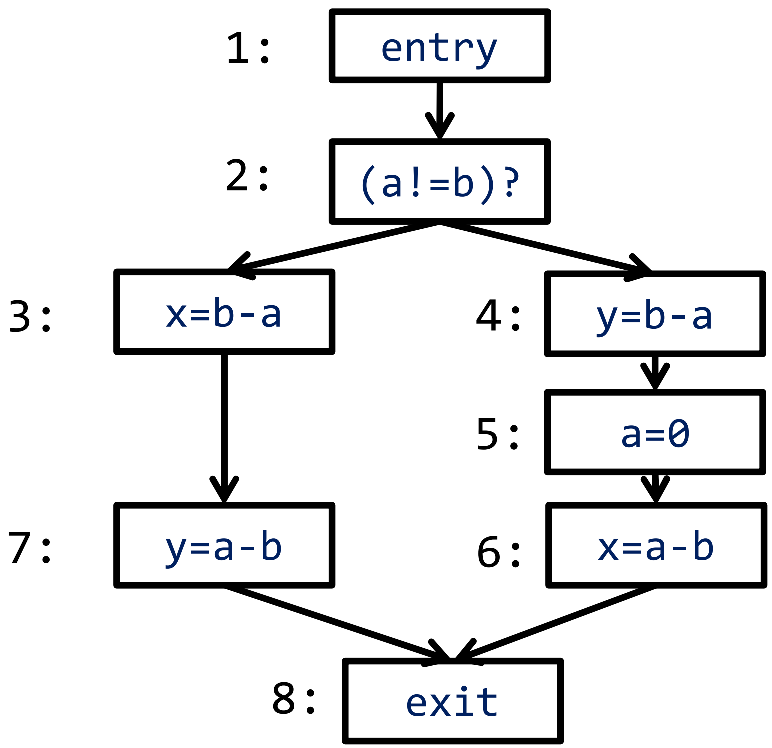

假设所有的节点都初始化为可用表达式集合：
{a-b, b-a}

n	IN(n)	OUT(n)
1	-	{b-a}
2	{b-a}	{b-a}
3	{a-b, b-a}	{a-b}
4	{b-a}	∅
5	∅	{a-b}
6	{a-b}	∅
7	{a-b}	∅
8	∅	—

可用表达式分析

- 可用表达式：无论走那条路径，该表达式的操作数都未重新赋值，避免重复计算表达式的值。

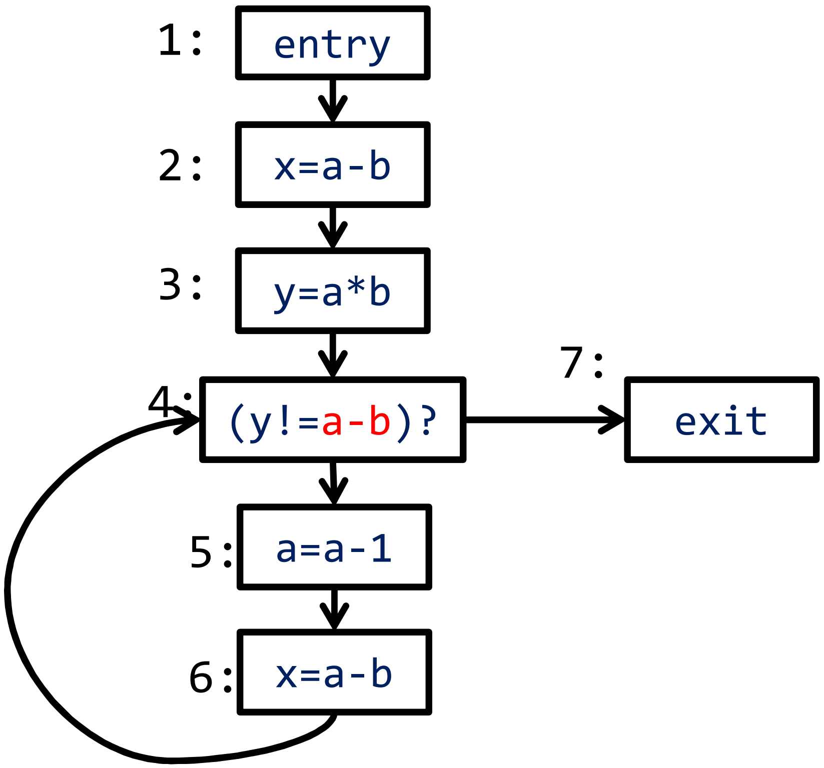

  - 避免重复计算a-b的值

练习

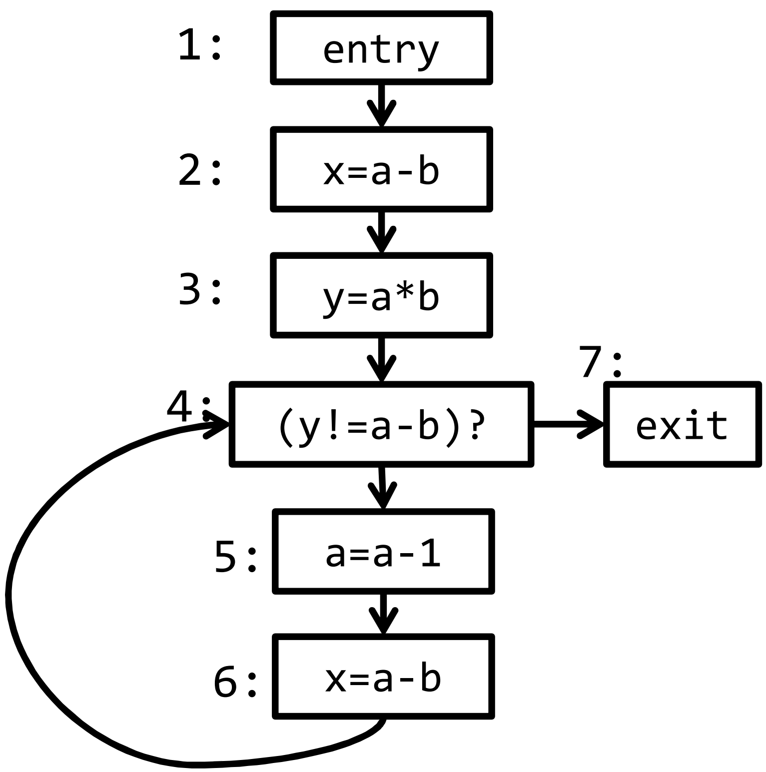

前向分析

n	IN[n]	OUT[n]
1	--	∅
2	∅	{a-b}
3	{a-b}	{a-b, a*b}
4	{a-b, ~~a*b~~}	{a-b, ~~a*b~~}
5	{a-b, ~~a*b~~}	∅
6	∅	{a-b}
7	{a-b, ~~a*b~~}	--

活跃变量分析

- 活跃变量：一个变量在被重新赋值前被使用(def-use)。

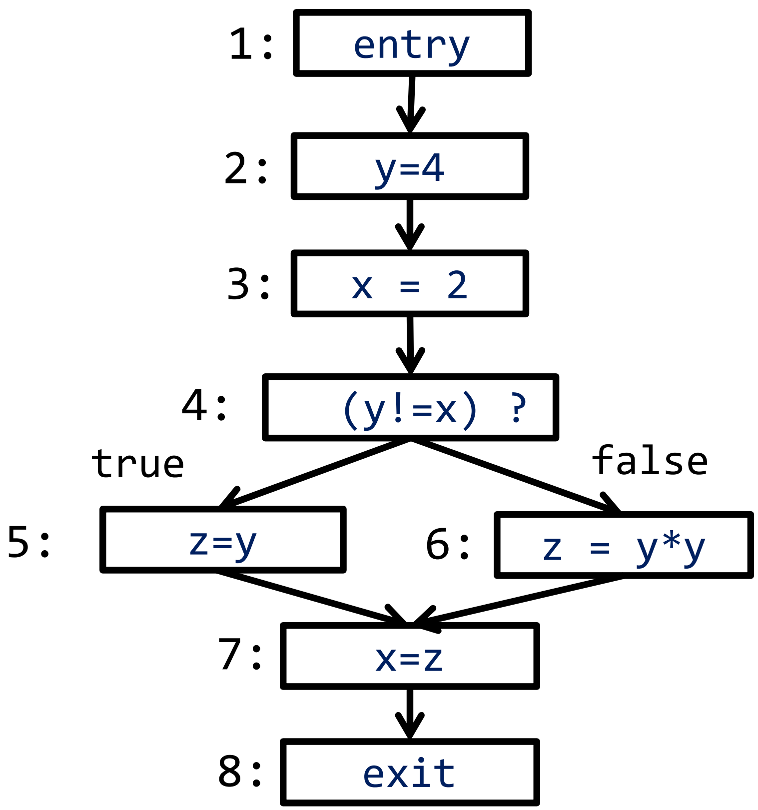

- x: 3-4-5-6
- y: 2-3-4-5-6
- z: 5-6-7

练习

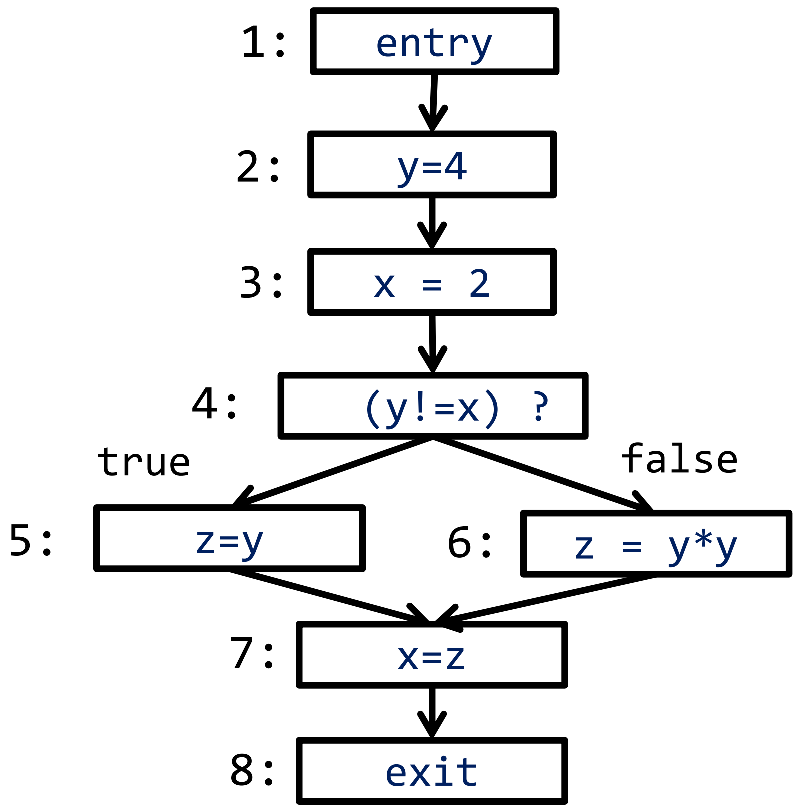

后向分析

n	IN[n]	OUT[n]
1	--	∅
2	∅	{y}
3	{y}	{x,y}
4	{x,y}	{y}
5	{y}	{z}
6	{y}	{z}
7	{z}	∅
8	∅	--

数据流分析方法

$$\boxed{\quad\quad} [n] = (\boxed{\quad\quad} [n] - KILL[n]) \cup GEN[n]$$

$$\boxed{\quad\quad} [n] = \boxed{\quad\quad} \; \boxed{\quad\quad} [n']$$

$$n' \in \boxed{\quad\quad} (n)$$

$\boxed{\quad}$ $\boxed{\quad}$ = IN or OUT

$\boxed{\quad}$ = ∪ (may) or ∩ (must)

$\boxed{\quad}$ = predecessors or successors

可达性分析

$$\boxed{\texttt{OUT}}\,[n] = (\,\boxed{\texttt{IN}}\,[n] - \texttt{KILL}[n]) \cup \texttt{GEN}[n]$$

$$\boxed{\texttt{IN}}\,[n] = \boxed{\bigcup}_{n' \in \boxed{\texttt{pred.}}(n)} \boxed{\texttt{OUT}}\,[n']$$

$\boxed{}$ $\boxed{}$ = IN or OUT

$\boxed{}$ = ∪ (may) or ∩ (must)

$\boxed{}$ = predecessors or successors

繁忙表达式分析

$$\boxed{\text{IN}}\,[n] = (\boxed{\text{OUT}}\,[n] - \text{KILL}[n]) \cup \text{GEN}[n]$$

$$\boxed{\text{OUT}}\,[n] = \underset{n' \in \boxed{\text{succ.}}(n)}{\boxed{\cap}}\ \boxed{\text{IN}}\,[n']$$

$\boxed{}$ $\boxed{}$ = IN or OUT

$\boxed{}$ = ∪ (may) or ∩ (must)

$\boxed{}$ = predecessors or successors

可用表达式分析

OUT [n] = (IN [n] - KILL[n]) ∪ GEN[n]

IN [n] = ∩ OUT [n’]

n’∈ pred. (n)

= IN or OUT

= ∪ (may) or ∩ (must)

= predecessors or successors

活跃变量分析

$$\boxed{\texttt{IN}}\ [n] = (\ \boxed{\texttt{OUT}}\ [n] - KILL[n])\ \cup\ GEN[n]$$

$$\boxed{\texttt{OUT}}\ [n] = \boxed{\ \cup\ }\ \boxed{\texttt{IN}}\ [n']$$

$$n' \in \boxed{\texttt{succ.}}\,(n)$$

$\boxed{}$ $\boxed{}$ = IN or OUT

$\boxed{}$ = ∪ (may) or ∩ (must)

$\boxed{}$ = predecessors or successors

数据流分析任务总结

	May Analysis (∪)	Must Analysis (∩)
前向分析	可达性分析	可用表达式分析
后向分析	活跃变量分析	繁忙表达式分析

- 可达定义分析
- 繁忙表达式分析
- 可用表达式分析
- 活跃变量分析

四、指针分析

指针分析问题

- 指针别名（Pointer alias）分析：判断两个指针是否在某一时刻指向同一内存地址。
- 指针指向（Points-to）分析：分析指针指向的内存地址，分析结果可用于指针别名分析。

```
Circle x = new Circle();
x.radius = 1;
y = x.radius;
assert(y == 1)
```

```
Circle x = new Circle();
Circle z = ?
x.radius = 1;
z.radius = 2;
y = x.radius;
assert(y == 1)
```

别名确定性

- May Alias
  - 如果两个指针是may alias，那么它们可能存在别名关系；
  - 反之则一定不存在别名关系（must-not alias）。
- Must Alias:
  - 如果两个指针是must alias，那么它们一定存在别名关系。
- 哪一个问题更容易？哪一种分析更有用？

指针分析的用途

- 编译器优化（保守策略）
  - 常量传播（constant propagation）
    - 下列代码中x是常量吗？
      - 如果*p和x一定不是alias，则是；
      - 如果*p和x一定是alias，则否；
      - 如果*p和x可能是alias，则否。
  - 无效代码删除（dead code elimination）
  - ...

```
x = 3;
*p = 4;
```

为什么指针分析很难

```
class Node {
  int data;
  Node next, prev;
}

Node h = null;
for (...) {
    Node v = new Node();
    if (h != null) {
        v.next = h;
        h.prev = v;
    }
    h = v;
}
```

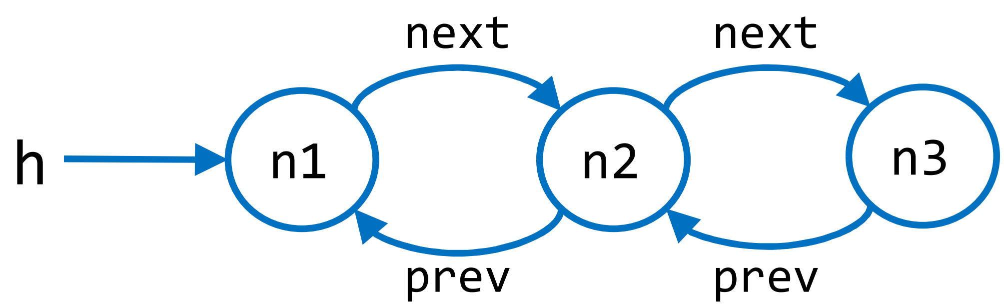


```
h.data
h.next.prev.data
h.next.next.prev.data
h.next.prev.next.prev.data
...
```

需要近似分析

- 一般来讲，指针分析问题是undecidable的问题
  - 需在soundness、completeness和termination中取舍
- 通常选择保留soundness、牺牲completeness
  - 造成false positives
  - 不会有false negatives
    - 无论程序如何运行

```
Circle x = new Circle();
Circle z = ?
x.radius = 1;
z.radius = 2;
y = x.radius;
assert(y == 1)
```

哪些操作可能造成Alias?

- 指针
- 函数调用传参（指针、引用）
- 数组索引

```
int *p, i;
p = &i;
```

```
void foo(Object a, Object b) { ... }
foo(x,x); // a和b在函数foo中是alias
```

```
int i,j,a[100];
i = j; // a[i] and a[j] alias
```

指针分析建模方法

- 不同分析方法实际精度存在一定区别，主要体现在
  - Flow-sensitivity：是否考虑代码执行顺序
    - Flow sensitive：计算每一个程序点的指针指向；
    - Flow insensitive：计算任意程序点可能的指向。
  - Path-sensitivity：是否考虑控制流
    - Path sensitive：分析过程只考虑单条特定控制流；
    - Path insensitive：分析过程不区分控制流；
  - Context-sensitivity：是否考虑函数调用
    - Context sensitive：支持跨函数调用分析；
    - Context insensitive：以函数为分析边界。
  - 如何对堆内存进行抽象
    - 以内存分配（malloc、new）为内存单元
    - 以每种类型为内存单元（粗粒度）

指针分析算法

- Andersen-style Analyses
- Steensgaard-style Analyses

指针分析表示方法

- 别名对：alias pairs
  - 如*p和*q、x和*p、x和*q
- 等价集合：equivalence sets
  - 如{*p, x, *q}
- 指针指向：point-to
  - p⟶x, q⟶x

```
int x;
p = &x;
q = p;
```

Andersen-style指针分析思路

- 将指针赋值视作子集约束
- 通过约束表示和传递指针指向信息
- Flow-insensitive
  - 不考虑语句顺序
- Context-insensitive
  - 与函数如何被调用无关
- 主要步骤
  1) 将指针指向关系映射为子集约束；
  2) 初始化约束图；
  3) 计算传递闭包更新约束关系。

提取约束关系

约束类型	赋值语句	约束	含义
Base	`a = &b`	$a \supseteq \{b\}$	$loc(b) \in pts(a)$
Simple	`a = b`	$a \supseteq b$	$pts(a) \supseteq pts(b)$
Complex	`a = *b`	$a \supseteq * b$	$\forall v \in pts(b), pts(a) \supseteq pts(v)$
Complex	`*a = b`	$* a \supseteq b$	$\forall v \in pts(a), pts(v) \supseteq pts(b)$

```
p = &a
q = &b
*p = q;
r = &c;
s = p;
t = *p;
*s = r;
```

```
p ⊇ {a}
q ⊇ {b}
*p ⊇ q
r ⊇ {c}
s ⊇ p
t ⊇ *p
*s ⊇ r
```

初始化约束图

- 约束图
  - 点表示变量的指针指向；
  - 边表示特定约束关系；
- 初始化
  - 包含关系：箭头
  - 指针指向：{}

赋值语句	约束	含义	边
a = &b	$a \supseteq \{b\}$	$loc(b) \in pts(a)$	no edge
a = b	$a \supseteq b$	$pts(a) \supseteq pts(b)$	b->a
a = *b	$a \supseteq * \, b$	$\forall v \in pts(b), pts(a) \supseteq pts(v)$	no edge
*a = b	$* \, a \supseteq b$	$\forall v \in pts(a), pts(v) \supseteq pts(b)$	no edge

p ⊇ {a}
q ⊇ {b}
*p ⊇ q
r ⊇ {c}
s ⊇ p
t ⊇ *p
*s ⊇ r

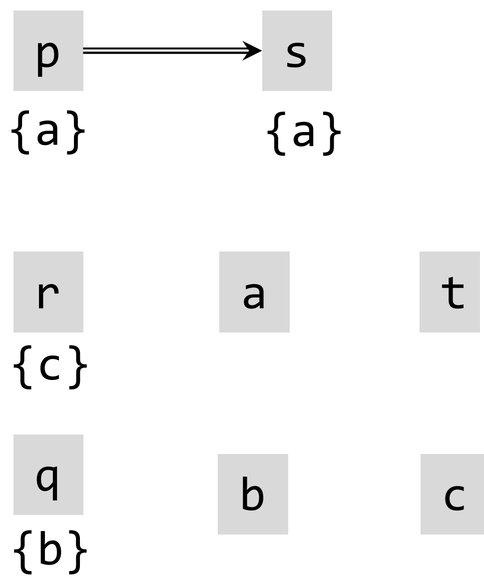

更新约束关系：Worklist算法

假设约束图已经初始化

```
Let W = { v | pts(v) ≠∅ } (所有指向集合非空的节点)
While W not empty
   v ← select from W
   for each a ∈ pts(v) do
     for each constraint p ⊇*v
       add edge a→p, and add a to W if edge is new
     for each constraint *v ⊇ q
       add edge q→a, and add q to W if edge is new
   for each edge v→q do
     pts(q) = pts(q) ∪ pts(v), and add q to W if pts(q) changed
```

更新约束关系

```
p ⊇ {a}
q ⊇ {b}
*p ⊇ q
r ⊇ {c}
s ⊇ p
t ⊇ *p
*s ⊇ r
```

```
for each a ∈ pts(v) do
  for each constraint p ⊇*v
    add edge a→p, and add a to W if edge is new
  for each constraint *v ⊇ q
    add edge q→a, and add q to W if edge is new
for each edge v→q do
  pts(q) = pts(q) ∪ pts(v), and add q to W if pts(q) changed
```

Step 1: Worklist: {p, s, r, q}

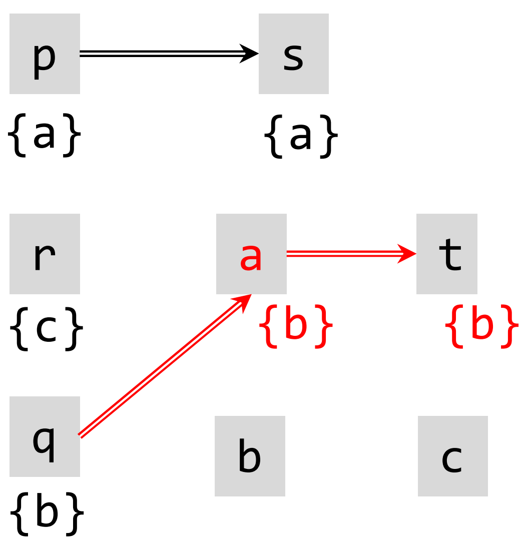

Result Worklist: {~~p,~~ s, r, q, a, t}

Step 2: Worklist: {s, r, q, a, t}

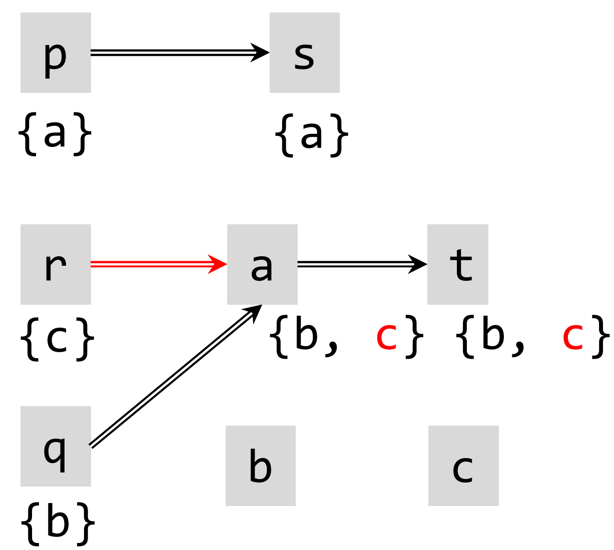

Result Worklist: {~~s~~, r, q, a, t}

精确性和算法复杂度

- 分析粒度较粗，相比flow sensitive存在误报。
  - *t和c不应为alias
- 复杂度O(n^3)，n是约束图的节点数。

```
p = &a
q = &b
*p = q;
r = &c;
s = p;
t = *p;
*s = r;
```

Flow Sensitive
分析结果

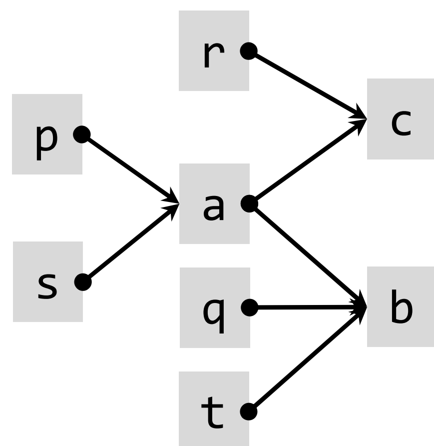

Andersen算法结果

```
pts(p) = {a}
pts(q) = {b}
pts(r) = {c}
pts(s) = {a}
pts(t) = {b, c}
pts(a) = {b, c}
pts(b) = Ø
pts(c) = Ø
```

Steensgaard-Style分析思路

- 使用等价约束（equality constraints）而非子集约束；
- 基于并查集的方法，如果x=y，则x和y联通
- 接近线性复杂度$O(n * \alpha(n))$，粒度比Andersen-style更粗

约束类型	赋值语句	约束	含义	注释
Base	a = &b	$a \subseteq \{b\}$	$loc(b) \subseteq pts(a)$	Steensgaard
		$a = \{b\}$	$loc(b) = pts(a)$	简化版
Simple	a = b	$a = b$	$pts(a) = pts(b)$	
Complex	a = *b	$a =* b$	$\forall v \in pts(b), pts(a) = pts(v)$	
Complex	*a = b	$* a = b$	$\forall v \in pts(a), pts(v) = pts(b)$	

简化版存在明显缺陷：a = &b, a = &c, b和c不应是alias

并查集算法（简化版）

- 维护不存在相交关系的集合，支持查找和联合两种操
  - Find(x)：返回包含变量x的集合
  - Union(x, y)：联合包含x和y的两个集合

```
while(getPair()!=NULL){
  [p,q] = readPair(p,q);
  pset = find(p);
  qset = find(q);
  if(pset == qset)
      continue;
  else union(p,q);
}
```

示例

```
a = &x
b = &y;
if p
  y = &z;
else
  y = &x;
c = &y;
```

```
a, &x
b, &y;
p
y, &z;
y, &x;
c, &y;
```

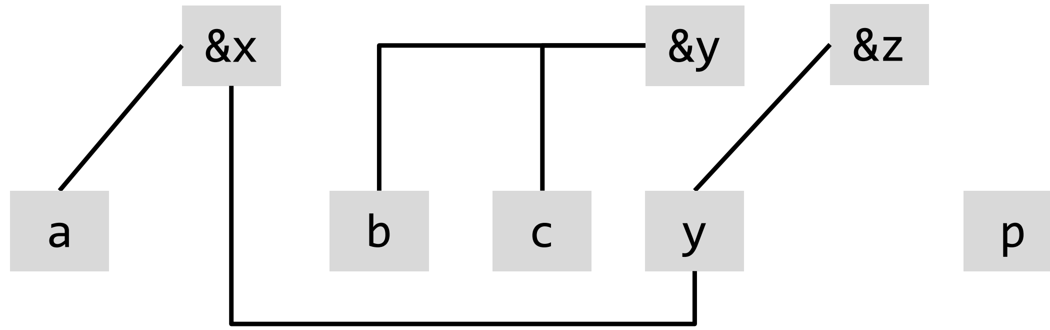

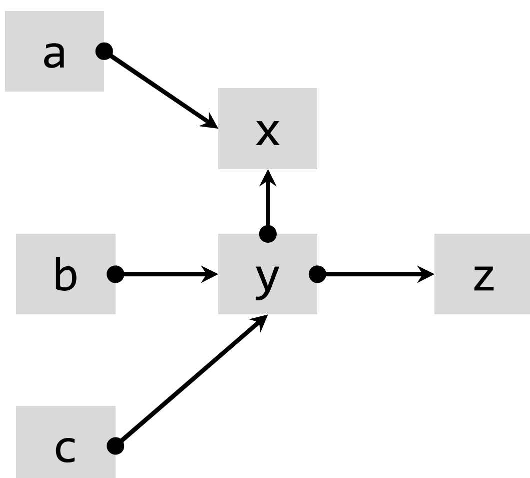

Andersen

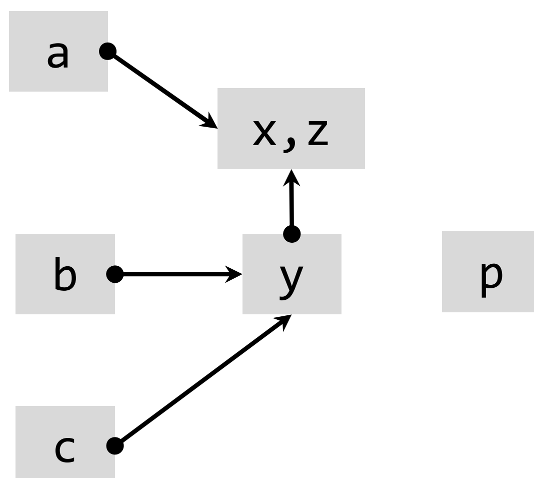

Steensgaard

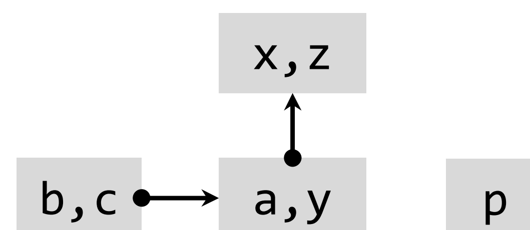

纯并查集

Andersen vs Steensgaard

- 都是flow-insensitive、context-insensitive
- 不同点在于points-to集合的构造思路
  - Andersen-style:
    - 基于子集关系的
    - 每个节点对应一个变量
    - 每个节点有多条出边
    - 比较精准但效率不高
  - Steensgaard-style:
    - 基于等价关系的
    - 每个节点对应多个变量
    - 每个节点只有一条出边
    - 比较快但精准度有限

Flow-insensitive分析的缺陷

- 相对流敏感算法分析结果不够精准，可用性较差
  - 代码优化
  - 漏洞检测
- 如何进行流敏感、路径敏感的指针分析？

```
int a = 1;
int b = 2;
int c = 3;

int x = &a;
doSth();
x = &b;
if(x == &c)//恒为假
  doSth();
if(x == &a)//恒为假
  doSth(x)
```

```
int* a = malloc(10);
int* b = malloc(10);

int* x = a;
doSth();
x = b;
free(a)//a和x不是alias
free(x)
```

五、数据流分析进阶

回到常量分析问题

- 下列哪个程序会使基于lattice的常量检测算法失准？

```
x = 1;
if (x==2)
  x = 3;
x是否为常量？
```

```
if (p)
  x = 1;
else
  x = -1;
y = x*x;
y是否为常量？
```

```
if (p)
  x = 1;
else
  x = 2;
if (p)
  y = x+2;
else
  y = x+1;
y是否为常量？
```

Meet/Join Over All Passes

- 一个program point的属性信息是由每一条到达该点的路径分别计算得到的。
- 主要挑战：循环导致路径数是无限的

```
while (i>1) {
  if (i%2==1)
    x = 1;
    y = 2;
  else
    x = 2;
    y = 1;
  i = i/2;
}
z = x+y;
z是否为常量？
```

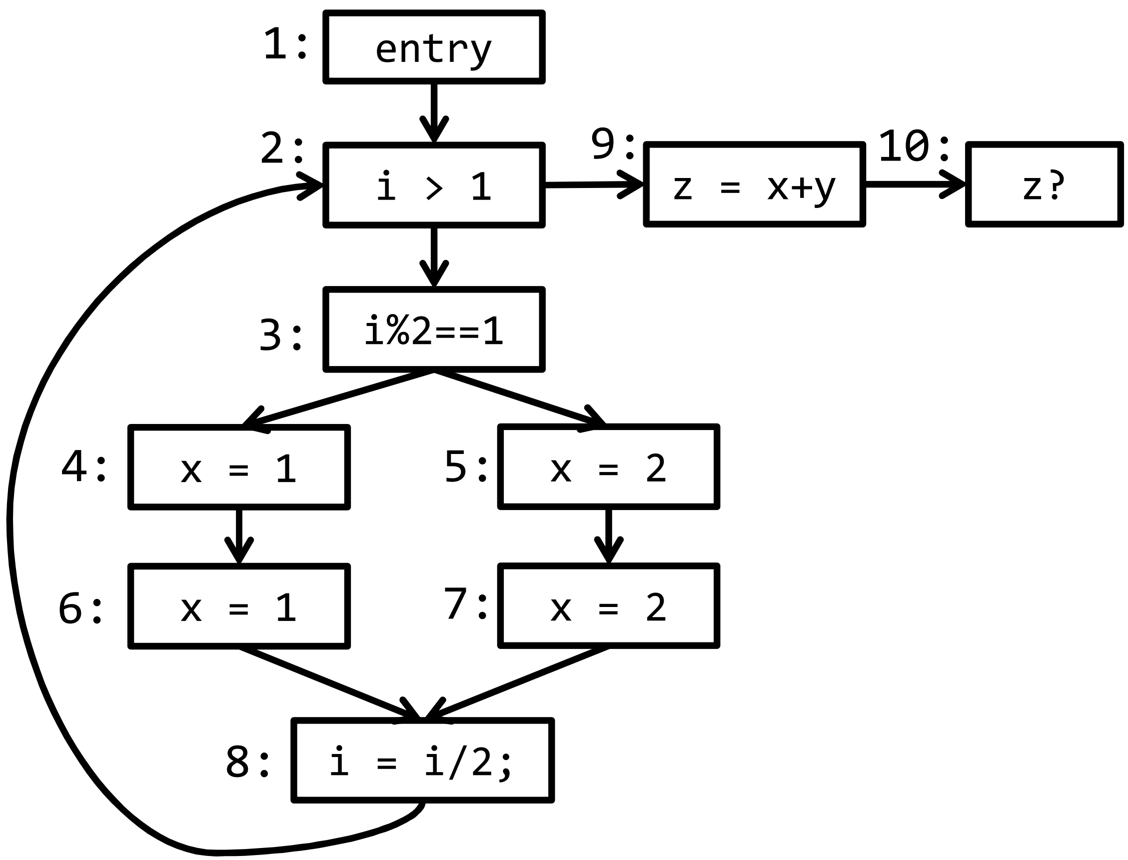

是否可以缩环？

- 是否可以基于强联通分量缩环？
  - 检测强联通分量：Tarjan算法

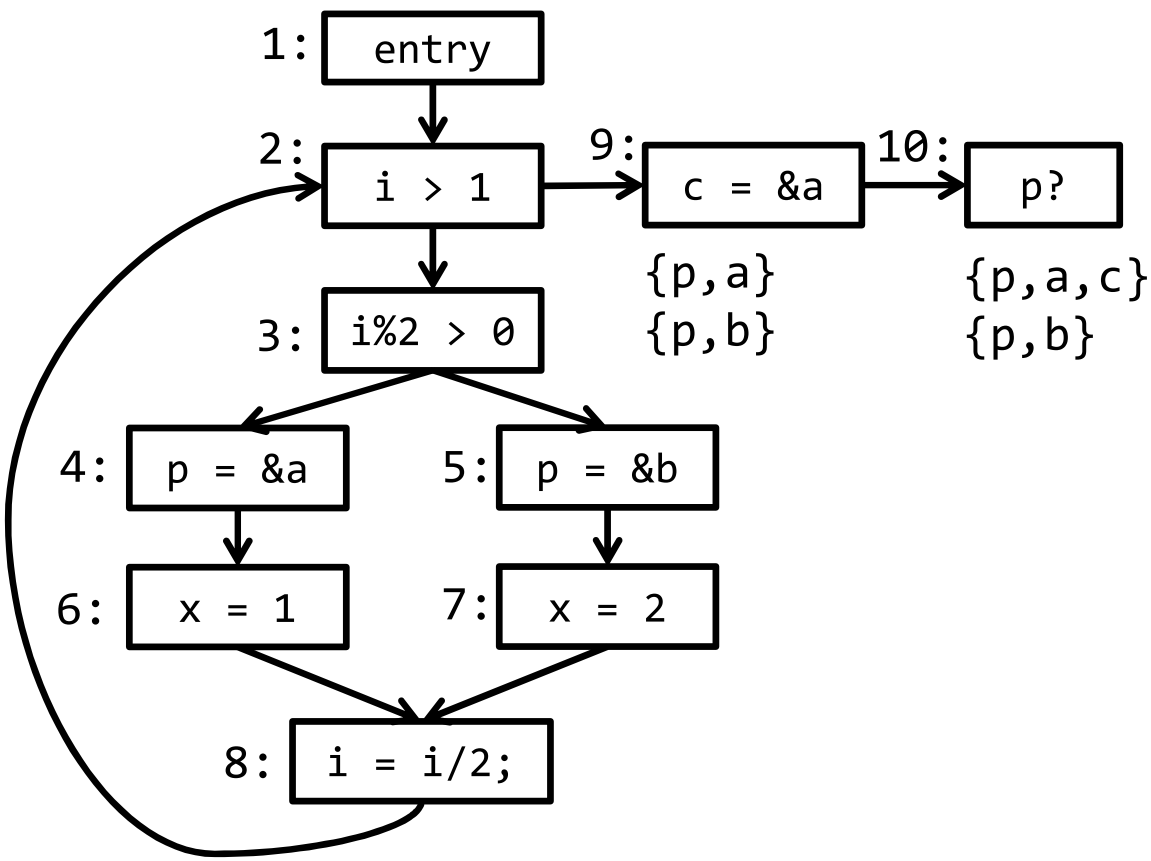

通过Tarjan算法找SCC

```
DFSVisit(v)
{
    N[v] = c; //记录每个节点的到达时间
    L[v] = c; //记录下一跳的最早到达时间
    c++;
    push v onto the stack;
    for each w in OUT(v) {
        if N[w] == UNDEFINED {
            DFSVisit(w);
            L[v] = min(L[v], L[w]);
        }  else if w is on the stack {
            L[v] = min(L[v], N[w]);
        }
    }
    if L[v] == N[v] { //找到强联通分量
        pop vertices off stack down to v;
    }
}
```

Tarjan算法找SCC：DFS

Stack:

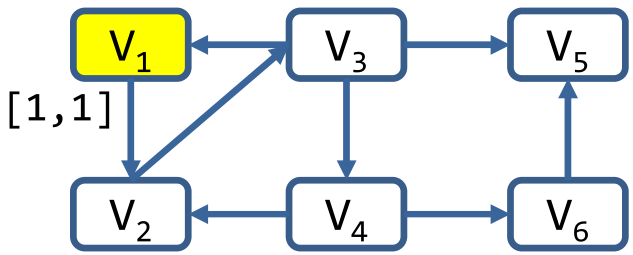

V1[1,1]

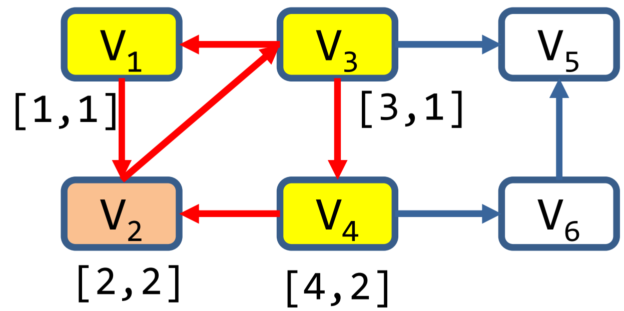

V2[2,2]
V1[1,1]

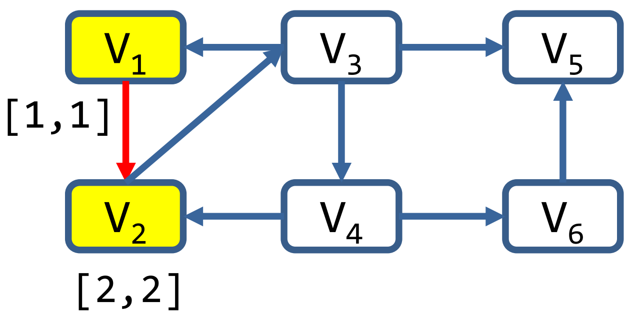

V3[3,1]
V2[2,2]
V1[1,1]

Stack:

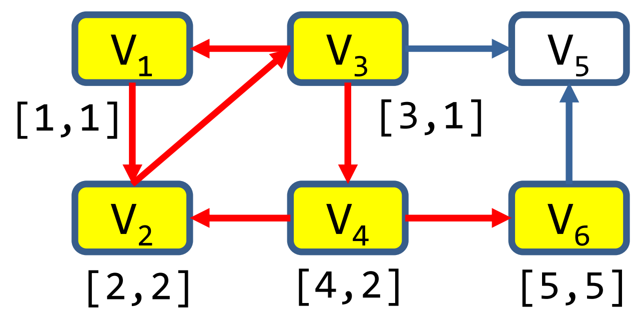

V4[4,2]
V3[3,1]
V2[2,2]
V1[1,1]

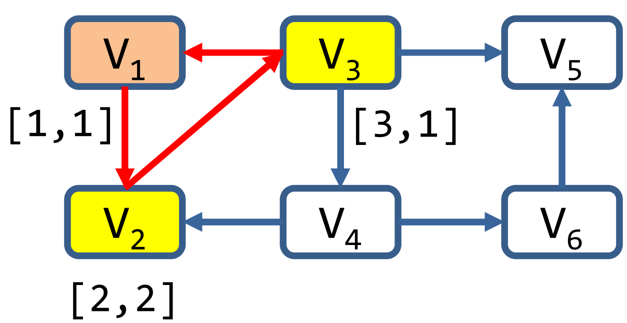

V6[5,5]
V4[4,2]
V3[3,1]
V2[2,2]
V1[1,1]

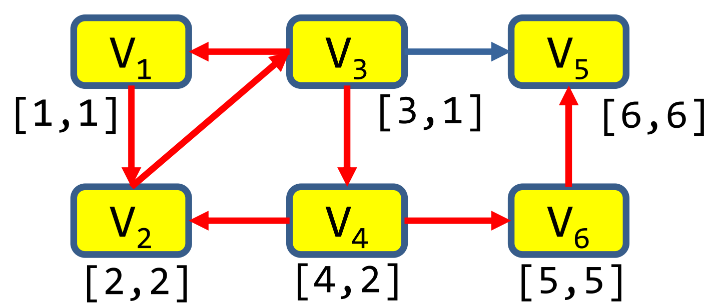

V5[6,6]
V6[5,5]
V4[4,2]
V3[3,1]
V2[2,2]
V1[1,1]

通过Tarjan算法找SCC

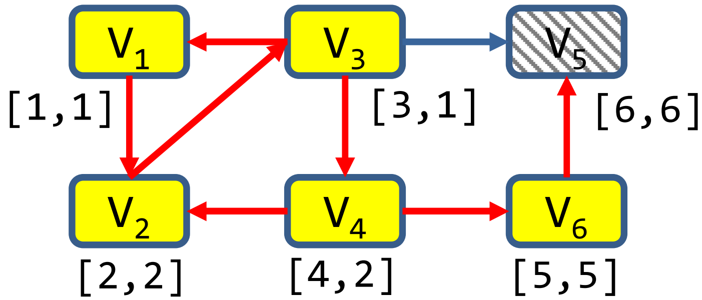

Stack:

V5[6,6]
V6[5,5]
V4[4,2]
V3[3,1]
V2[2,2]
V1[1,1]

SCC:

{V5}

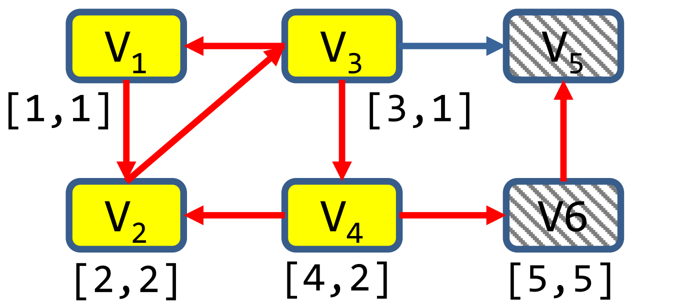

V6[5,5]
V4[4,2]
V3[3,1]
V2[2,2]
V1[1,1]

{V5}
{V6}

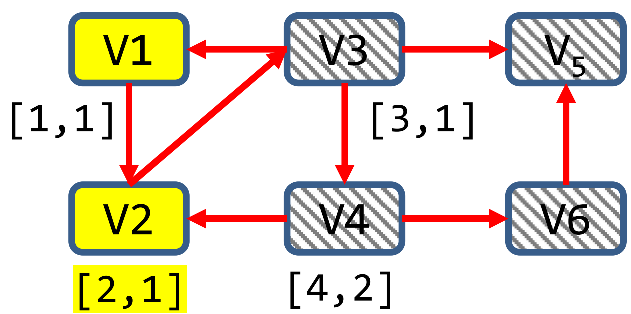

min(L[v], L[w]);

V2[2,1]
V1[1,1]

{V5}
{V6}
{4,3,2,1}

课后阅读

- 《编译原理（第2版）》
  - 第9章：Machine Independent Optimizations
- 《编译器设计（第2版）》
  - 第8章：优化简介
  - 第9章：数据流分析
  - 第10章：标量优化

参考资料

- B.Kam and J.D.Ullman,, Monotone data flow analysis frameworks. Acta informatica, 1977.
- [Andersen’94] Andersen, Lars Ole. "Program analysis and specialization for the C programming language." PhD diss., University of Cophenhagen, 1994.
- Steensgaard, Bjarne. "Points-to analysis in almost linear time." *Proceedings of the 23rd ACM SIGPLAN-SIGACT symposium on Principles of programming languages*. ACM, 1996.
- [Hind’01] Michael Hind, Pointer analysis: Haven‘t we solved this problem yet?. In *Proc. of the 2001 ACM SIGPLAN-SIGSOFT workshop on program analysis for software tools and engineering,* 2001.
- Whaley, John, and Monica S. Lam. "Cloning-based context-sensitive pointer alias analysis using binary decision diagrams." *ACM SIGPLAN Notices* 39.6 (2004): 131-144.
- Hardekopf, Ben, and Calvin Lin. "The ant and the grasshopper: fast and accurate pointer analysis for millions of lines of code." *ACM SIGPLAN Notices*. Vol. 42. No. 6. ACM, 2007.
- Bravenboer, Martin, and Yannis Smaragdakis. "Strictly declarative specification of sophisticated points-to analyses." *ACM SIGPLAN Notices*. Vol. 44. No. 10. ACM, 2009.
- http://web-static-aws.seas.harvard.edu/courses/cs252/2011sp/slides/Lec06-PointerAnalysis.pdf.
- https://www.cs.cmu.edu/afs/cs/academic/class/15745-s16/www/lectures/L6-Foundations-of-Dataflow.pdf