

Lecture 3

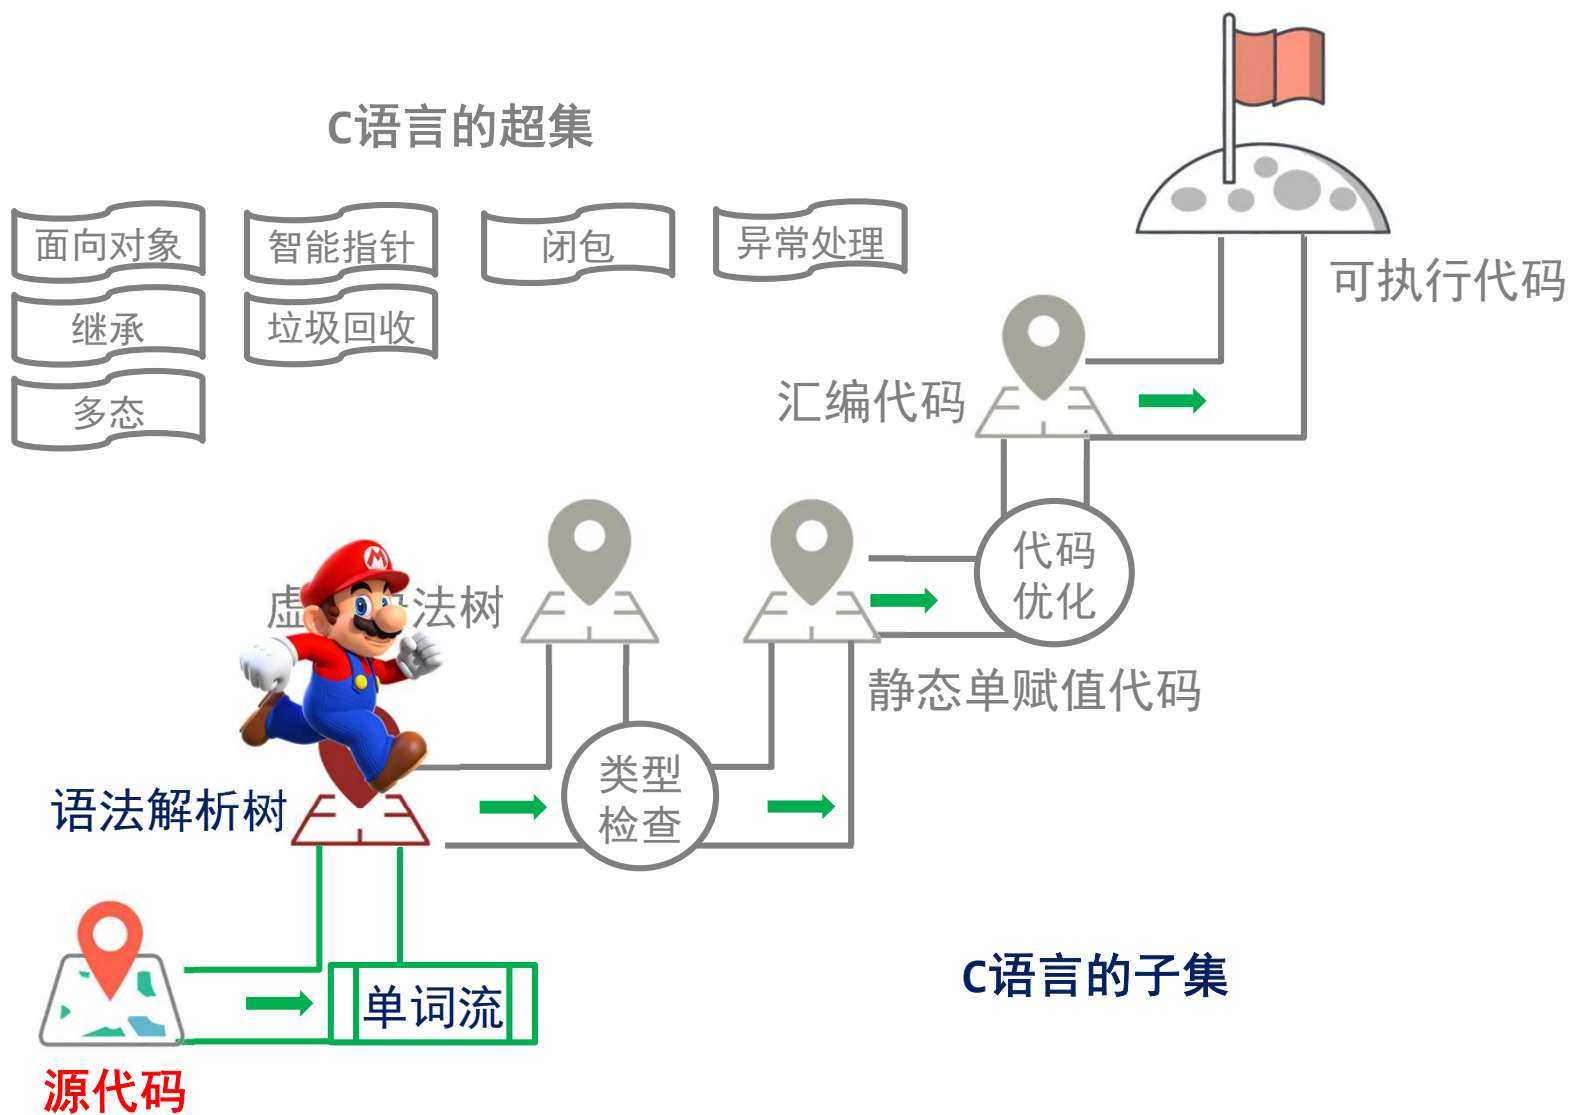
句式分析

徐 辉

xuh@fudan.edu.cn



学习地图



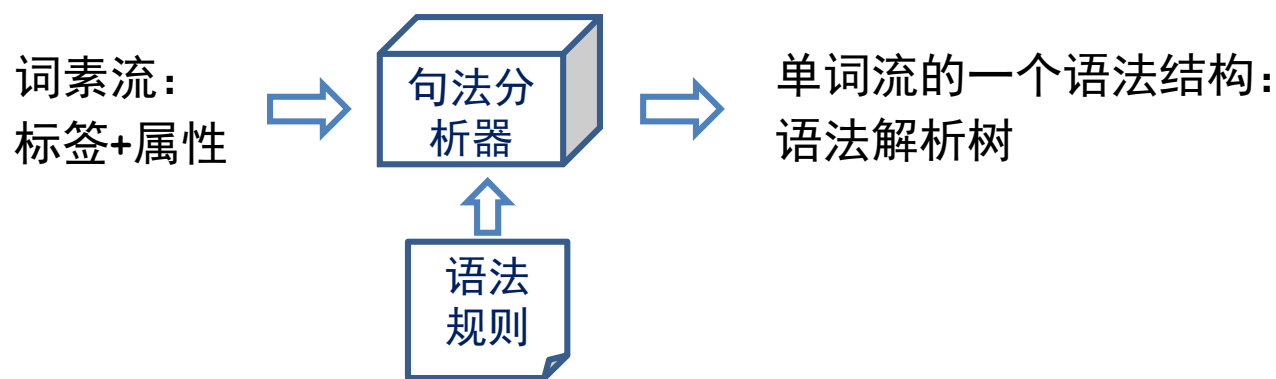
大纲

- 一、句式分析的基本概念
- 二、LLVM案例分析
- 三、自顶向下分析
- 四、自底向上分析
- 五、语法分析工具

一、句式分析的基本概念

问题定义

- 给定一个句子和语法规则，找到可生成该句子的一个语法推导。
- 通过词法分析已经将句子转换为了标签流。
- 语法规则（Grammar）定义了：
 - 什么是语法分析器（parser）可接受的标签组成，
 - 及其语法推导方式。



基本概念

- 一门语言 (language) 是多个句子 (sentences) 的集合。
- 句子 (sentence) 是由终结符 (terminal symbols) 组成的序列 (sequence)。
- 字符串 (string) 是包含终结符和非终结符的序列。
 - 字符串符号: α, β, γ
 - 非终结符: X, Y, Z
 - 终结符 (标签): a, b, c
- 一条语法 (grammar) 包括一个开始符号 S 和多条推导规则 (productions)
 - $X \rightarrow \beta$ 。

语法推导

- 语法 G 的语言 $L(G)$ 是该语法可推导的所有句子的集合。
- 问题：下列语法是否可推导出句子 $aaabbbccc$?

语法规则

[1] $S \rightarrow aBSc$

[2] $S \rightarrow abc$

[3] $Ba \rightarrow aB$

[4] $Bb \rightarrow bb$

推导

[1] $S \rightarrow aBSc$

[1] $S \rightarrow aBaBScc$

[3] $S \rightarrow aaBBScc$

[2] $S \rightarrow aaBBabccc$

[3] $S \rightarrow aaBaBbccc$

[3] $S \rightarrow aaaBBbccc$

[4] $S \rightarrow aaaBbbccc$


[4] $S \rightarrow aaabbbccc$

语法表示：使用正则表达式？

- 正则表达式是否可识别四则运算？
 - $y = a \times x + b$
 - $(var|num)((+|-|\times|\div)(var|num))^*$
 - $y = a \times (x + b)$
 - $('(|var|num)((+|-|\times|\div)('(|var|num|')'))^*$
 - 可导致单词流被错误接收：
 - $y = (a \times (x + b)$
 - $y = (a \times (x + (b$
- 正则表达式不能处理括号匹配问题： $(^*)^*$


非正则语言

- 不能用正则表达式或有穷自动机表示的语言。
 - 正则语言不能计数，如 $L = \{a^n b^n, n > 0\}$
 - 证明：
 - 假设DFA可识别该语言，其包含 p 个状态；
 - 假设某词素为 $a^q b^q, q > p$ 。
 - 识别该词素需要经过某状态 s_i 至少两次，分别对应第 j 和第 k 个 a ；
 - 该DFA可同时接受 $a^q b^q$ 和 $a^{q+k-j} b^q$ ，推出矛盾。



正则语言的泵引理 (Pumping Lemma)

- 词素数量有限的语言一定是正则语言。
- 词素数量无穷多的语言是否为正则语言？
- 某语言 $L(r)$ 是正则语言的必要条件：
 - 任意长度超过 p （泵长）的句子都可以被分解为 xyz 的形式
 - 其中 x 和 z 可为空，
 - 子句 y 被重复任意次（如 $xyyz$ ）后得到的句子仍属于该语言。




语言分析问题难度

- 通常来说，判断一个句子是否属于某个语言 $w \in L(G)$ 是不能计算的。

Chomsky Hierarchy

Class	Languages	Automaton	Rules	Word Problem	Example
type-0	recursively enumerable	Turing machine	no restriction	undecidable	Post's corresp. problem
type-1	context sensitive	linear-bounded TM	$\alpha \rightarrow \gamma$ $ \alpha \leq \gamma $	PSPACE-complete	$a^n b^n c^n$
type-2	context free	pushdown automaton	$A \rightarrow \gamma$	cubic	$a^n b^n$
type-3	regular	NFA / DFA	$A \rightarrow a$ or $A \rightarrow aB$	linear time	$a^* b^*$



上线文无关语法和BNF范式

- 上下文无关语法（CFG/context-free grammar）是一个四元组 (T, NT, S, P)
 - T : 终结符
 - NT : 非终结符
 - S : 起始符号
 - P : 产生式规则集合 $X \rightarrow \gamma$,
 - X 是非终结符
 - γ 是可能包含终结符和非终结符的字符串
- BNF范式（Backus-Naur form）是传统的上下文无关语法表示方法。

$$\langle SheepNoise \rangle ::= baa \langle SheepNoise \rangle$$
$$| baa$$


上线文无关语法举例

- 给定可生成所有匹配括号对的语法, $[[[]]]$ 是该语法的一个推导吗?

语法规则

$$\begin{array}{lcl} [1] & S & \rightarrow \epsilon \\ [2] & & | [S] \\ [3] & & | SS \end{array}$$

推导

$$\begin{array}{l} [3] \quad S \rightarrow SS \\ [2] \quad S \rightarrow S[S] \\ [3] \quad S \rightarrow S[SS] \\ [2] \quad S \rightarrow S[S[S]] \\ [1] \quad S \rightarrow S[S[]] \\ [2] \quad S \rightarrow S[[S][]] \\ [1] \quad S \rightarrow S[[][]] \\ [2] \quad S \rightarrow [S][][] \\ [1] \quad S \rightarrow [][][] \end{array}$$


语法解析树

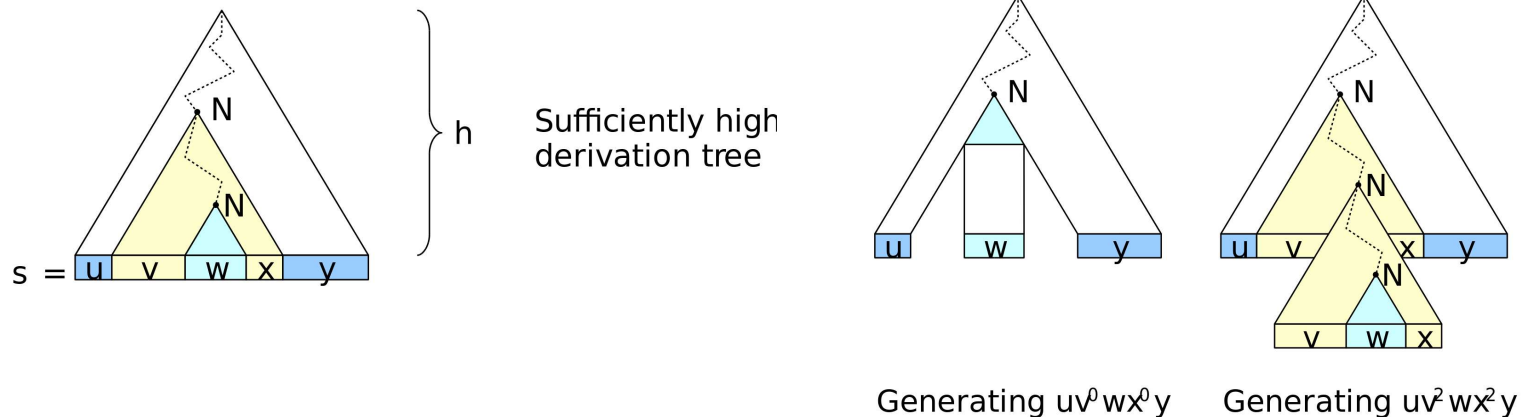
非CFG语言：上下文敏感语法

- $L = \{a^n b^n c^n, n > 0\}$ 不是CFG语言
- 无法用CFG定义
 - $X \rightarrow \gamma$
- 可以用上下文敏感语法定义
 - $\alpha A \beta \rightarrow \alpha \gamma \beta$
 - α 和 β 不变, A 展开

[1]	$S \rightarrow aBC$
[2]	$\quad \mid aSBC$
[3]	$CB \rightarrow CZ$
[4]	$CZ \rightarrow WZ$
[5]	$WZ \rightarrow WC$
[6]	$WC \rightarrow BC$
[7]	$aB \rightarrow ab$
[8]	$bB \rightarrow bb$
[9]	$bC \rightarrow bc$
[10]	$cC \rightarrow cc$

非CFG语言的泵引理

- CFG语言的泵引理（必要条件）：
 - 任意长度超过 p （泵长）的句子可以被拆分为 $uvwxy$,
 - 子句 v 和 x 被重复任意次后得到的新句子（如 $uvvwxxy$ ）仍属于该语言。
- 正则属于CFG: $uv^nwx^n\epsilon$



澄清几个概念

- Regular language: 用DFA/NFA可以计算
 - Regular expression
 - 狭义: 其表示的都是正则语言, 所有正则语言都可以用正则表达式表示 (Flex工具)
 - 广义 (regex): 字符串匹配工具。
- Context-free language: 需要pushdown automaton计算
 - Context-free grammar
 - 正则语言可以用CFG表示: $StartSymbol \rightarrow regex$
 - 特性: 右侧的非终结符均可替换为终结符
 - $S \rightarrow (0?1)^*$
 - $S \rightarrow 0S1S|1S0S|\epsilon$
- Context-sensitive language: 需要图灵机计算

下列语言是否为正则语言？

- 集合表示

- 1) $L = \{a^n b^n\}$
- 2) $L = \{a^n b^n | n \leq 100\}$
- 3) $L = \{a^n | n \geq 1\}$
- 4) $L = \{a^{2^n} | n \geq 1\}$
- 5) $L = \{a^p | p \text{ is prime}\}$

- Regex/CFG语法表示

- 1) $S \rightarrow (0?1)^*$
- 2) $S \rightarrow aT | \epsilon, T \rightarrow Sb$
- 3) $S \rightarrow 0S1S | 1S0S | \epsilon$
- 4) $S \rightarrow A | B$
 - $A \rightarrow E1A'E$
 - $A' \rightarrow A | \epsilon$
 - $B \rightarrow E0B'E$
 - $B' \rightarrow B | \epsilon$
 - $E \rightarrow 0S1S | 1S0S | \epsilon$

推导 (Derivation) 的优先级

暂不考虑优先级

[1]	$Expr \rightarrow (Expr)$
[2]	$ Expr Op num$
[3]	$ num$
[4]	$Op \rightarrow +$
[5]	$ -$
[6]	$ \times$
[7]	$ \div$

$(a + b) \times 2$




$(a + b) \times 2$

	$Expr$
[2]	$\Rightarrow_{lm} Expr Op num$
[1]	$\Rightarrow_{lm} (Expr) Op num$
[2]	$\Rightarrow_{lm} (Expr Op num) Op num$
[3]	$\Rightarrow_{lm} (num Op num) Op num$
[4]	$\Rightarrow_{lm} (num + num) Op num$
[6]	$\Rightarrow_{lm} (num + int) \times num$

左侧优先推导
(Leftmost Derivation)

右侧优先推导
(Rightmost Derivation)

	$Expr$
[2]	$\Rightarrow_{rm} Expr Op num$
[6]	$\Rightarrow_{rm} Expr \times num$
[1]	$\Rightarrow_{rm} (Expr) \times num$
[2]	$\Rightarrow_{rm} (Expr Op num) \times num$
[4]	$\Rightarrow_{rm} (Expr + num) \times num$
[3]	$\Rightarrow_{rm} (num + num) \times num$



语法解析树完全相同

练习：语法推导


给定下列语法和字符串 $aa + a *$

- 1) 写出左推导
- 2) 写出右推导
- 3) 画出语法推导树

[1]	$S \rightarrow SS +$
[2]	$\quad \mid SS *$
[3]	$\quad \mid a$

$$S \xRightarrow{lm} SS * \xRightarrow{lm} SS + S * \xRightarrow{lm} aS + S * \xRightarrow{lm} aa + S * \xRightarrow{lm} aa + a *$$

$$S \xRightarrow{rm} SS * \xRightarrow{rm} Sa * \xRightarrow{rm} SS + a * \xRightarrow{rm} Sa + a * \xRightarrow{rm} aa + a *$$



练习：语法设计

- 为下列语言设计语法规则。
 - 1) 所有0和1组成的字符串，每一个0后面紧跟着若干个1
 - 2) 所有0和1组成的字符串，0和1的个数相同
 - 3) 所有0和1组成的字符串，0和1的个数不相同

$$S \rightarrow (0? 1)^*$$

$$S \rightarrow 0S1S|1S0S|\epsilon$$

$$S \rightarrow A|B$$

$$A \rightarrow E1A'E$$

$$A' \rightarrow A|\epsilon$$

$$B \rightarrow E0B'E$$

$$B' \rightarrow B|\epsilon$$

$$E \rightarrow 0S1S|1S0S|\epsilon$$


二义性 (ambiguity)

- 如果 $L(G)$ 中的某个句子有一个以上的最左（或最右）推导，那么语法 G 就有二义性。
 - 语法解析树不同
- 根据下列语法规则如何推导出 $[] [] []$?

[1]	$S \rightarrow \epsilon$
[2]	$ T$
[3]	$T \rightarrow []$
[4]	$ [T]$
[5]	$ TT$

$S \rightarrow T \rightarrow TT \rightarrow TTT \rightarrow []TT \rightarrow T[] [] \rightarrow [] [] []$

$S \rightarrow T \rightarrow TT \rightarrow []T \rightarrow []TT \rightarrow [] []T \rightarrow [] [] []$



极端情况

- 存在无数棵语法解析树
 - 考虑循环的情况
- 根据下列语法规则如何推导出 $[][[][]]$?

[1]	$S \rightarrow \epsilon$
[2]	$ [S]$
[3]	$ SS$

$S \rightarrow \textcolor{red}{S}S \rightarrow [\textcolor{red}{S}]S \rightarrow []\textcolor{red}{S} \rightarrow [][\textcolor{red}{S}] \rightarrow [][S S] \rightarrow [][[S] [S]] \rightarrow [][[][]]$

$S \rightarrow \textcolor{red}{S}S \rightarrow \textcolor{red}{S} \rightarrow SS \rightarrow \dots$



消除二义性

[1]	$S \rightarrow \epsilon$
[2]	$ [S]$
[3]	$ SS$

消除循环引起的二义性

$S \rightarrow SS \rightarrow S$



[1]	$S \rightarrow \epsilon$
[2]	$ T$
[3]	$T \rightarrow []$
[4]	$ [T]$
[5]	$ TT$



[1]	$S \rightarrow \epsilon$
[2]	$ T$
[3]	$T \rightarrow UT$
[4]	$ U$
[5]	$U \rightarrow []$
[6]	$ [T]$

推导 $[] [] []$ 的例子

$T \rightarrow TT$ 左递归容易引起二义性（回溯语法）

将语义加入语法中：四则运算的例子

[1] $Expr \rightarrow Expr \ Bop \ Expr$
[2] | num
[3] | $(Expr)$
[4] $Bop \rightarrow +$
[5] | $-$
[6] | \times
[7] | \div

3 + 4 × 5 的语义?

$Expr$
 $\rightarrow Expr \ Bop \ Expr$ $(3 + 4) \times 5$
 $\rightarrow Expr \ Bop \ Expr \ Bop \ Expr$ $3 + (4 \times 5)$
 $\rightarrow Expr + Expr \times Expr$

将运算符特性加入到语法规则中：

- 优先级：() > × / ÷ > + / -
- 结合性：左结合


$Expr$
 $\rightarrow Expr \ AMop \ Term$
 $\rightarrow Term \ AMop \ Term$
 $\rightarrow Term \ AMop \ Term \ MDop \ Factor$
 $\rightarrow \dots$

[1] $Expr \rightarrow Expr \ AMop \ Term$
[2] | $Term$
[3] $Term \rightarrow Term \ MDop \ Factor$
[4] | $Factor$
[5] $Factor \rightarrow (Expr)$
[6] | num
[7] $AMop \rightarrow +$
[8] | $-$
[9] $MDop \rightarrow \times$
[10] | \div


If-Else嵌套的二义性语法

```
[1] Stmt → if Expr then Stmt else Stmt
[2]      | if Expr then Stmt
[3]      | Assignment
[4]      | ...
```

if Expr1 then if Expr2 then Assignment1 else Assignment2



```
if Expr1 then
  if Expr2 then
    Assignment1
  else
    Assignment2
```



```
if Expr1 then
  if Expr2 then
    Assignment1
  else
    Assignment2
```


消除If-Else语法的二义性

- 将语义编码加入到结构中
 - 要求else优先匹配内层if
 - 如果外层出现else，则内部嵌套的if语句一定有匹配的else

```
[1] Stmt → if Expr then Withelse else Stmt
[2]       | if Expr then Stmt
[3]       | Assignment
[4] Withelse → if Expr then Withelse else Withelse
[5]           | Assignment
```

```
[1] 有else配套的if语句，可继续展开[4]
[2] 无配套else的if语句
[3]
[4] 内层有配套else的if语句
[5]
```

if Expr1 then if Expr2 then Assignment1 else Assignment 2



```
if Expr1 then
  if Expr2 then
    Assignment1
  else
    Assignment2
```

不存在其它推导方式

练习：二义性分析

- 下列If-Else语法是否存在二义性？

```
[1] Stmt → if Expr then Stmt  
[2]       | matchedStmt  
[3] matchedStmt → if Expr then matchedStmt else Stmt  
[4]       | Assignment
```

if Expr1 then if Expr2 then Assignment1 else Assignment 2



if Expr1 then if Expr2 then Assignment1 else if Expr3 then Assignment2 else Assignment3



```
if Expr1 then  
  if Expr2 then  
    Assignment1  
  else  
    if Expr3 then  
      Assignment2  
    else  
      Assignment3
```

```
if Expr1 then  
  if Expr2 then  
    Assignment1  
  else  
    if Expr3 then  
      Assignment2  
  else  
    Assignment3
```

练习

- 为描述正则语言的正则表达式语法设计一种CFG
 - 支持字符[A-Za-z0-9]
 - 支持连接、或|、闭包*运算
 - 支持()
- 检查语法是否有二义性?

```
[1] < regex > ::= < union > | < concat > | < closure > | < term >
[2] < union > ::= < regex > "|" < regex >
[3] < concat > ::= < regex > < regex >
[4] < closure > ::= < regex > *
[5] < term > ::= < group > | < alphanum >
[6] < group > ::= (< regex >)
[7] < alphanum > ::= A|...|Z|a|...|z|0|...|9
```

- 主要问题:
 - 未考虑运算的优先级: 比如解析ab|c存在歧义。
 - 一般按照运算符优先级由低到高依次展开

改写

```
< regex > ::= < union > | < concat > | < closure > | < term >  
< union > ::= < regex > "|" < regex >  
< concat > ::= < regex > < regex >  
< closure > ::= < regex > *  
< term > ::= < group > | < alphanum >  
< group > ::= (< regex >)  
< alphanum > ::= A|...|Z|a|...|z|0|...|9
```



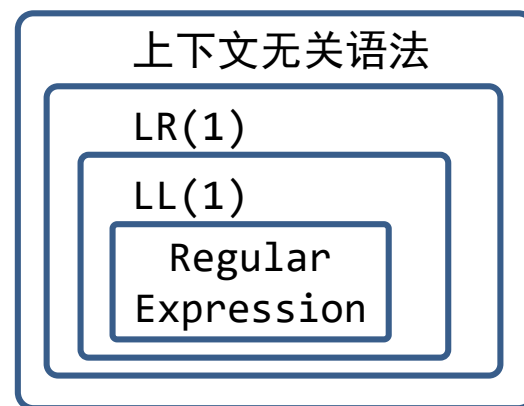
```
< regex > ::= < union > | < concat >  
< union > ::= < regex > "|" < concat >  
< concat > ::= < concat > < term > | < term >  
< term > ::= < element > * | < element >  
< element > ::= (< regex >)| < alphanum >  
< alphanum > ::= A|...|Z|a|...|z|0|...|9
```

思考

- 1) 用正则表达式可以定义所有的正则语言吗？
- 2) 用有穷自动机（正则表达式模拟器）可以解析任意正则表达式吗？
- 3) 用CFG可以定义任意正则语言吗？
- 4) 用CFG可以定义任意CFL语言吗？
- 5) 用pushdown automaton（CFG模拟器）可以解析任意正则表达式吗？
- 6) 用pushdown automaton可以解析任意CFG吗？
- 7) 用通用图灵机可以解析任意CFG吗？
- 8) 用通用图灵机可以解析任意程序吗？

编译器的任务：找到语法树推导

- 方法：
 - 自顶向下 (top-down parser)
 - 自底向上 (bottom-up parser)
- 语法难度：CFG > LR(1) > LL(1) > RE
 - 任意CFG需要花费更多时间进行语法分析
 - Earley/CYK算法复杂度 $O(n^3)$
 - LL(1)是LR(1)的一个子集
 - Left-to-Right, Leftmost
 - 前瞻单词1个
 - 适合自顶向下分析
 - LR(1)是无歧义CFG的一个子集
 - Left-to-Right, Rightmost
 - 前瞻单词1个
 - 适合自底向上分析



二、LLVM案例分析

LR(\emptyset)

LR(1): SLR/LALR

Clang采用自顶向下分析算法

A single unified parser for C, Objective C, C++, and Objective C++


Clang is the "C Language Family Front-end", which means we intend to support the most popular members of the C family. We are convinced that the right parsing technology for this class of languages is a **hand-built recursive-descent parser**. Because it is plain C++ code, recursive descent makes it very easy for new developers to understand the code, it easily supports ad-hoc rules and other strange hacks required by C/C++, and makes it straightforward to implement excellent diagnostics and error recovery.

We believe that implementing C/C++/ObjC in a single unified parser makes the end result easier to maintain and evolve than maintaining a separate C and C++ parser which must be bugfixed and maintained independently of each other.

作业回顾

$\langle \text{program} \rangle$	$::=$	$\langle \text{gdecl} \rangle^* \langle \text{function} \rangle^*$
$\langle \text{gdecl} \rangle$	$::=$	$\text{extern } \langle \text{prototype} \rangle;$
$\langle \text{function} \rangle$	$::=$	$\langle \text{prototype} \rangle \langle \text{body} \rangle$
$\langle \text{prototype} \rangle$	$::=$	$\langle \text{type} \rangle \langle \text{ident} \rangle (\langle \text{paramlist} \rangle)$
$\langle \text{paramlist} \rangle$	$::=$	$\epsilon \langle \text{type} \rangle \langle \text{ident} \rangle [, \langle \text{type} \rangle \langle \text{ident} \rangle]^*$
$\langle \text{body} \rangle$	$::=$	$\{ \langle \text{stmt} \rangle \}$
$\langle \text{stmt} \rangle$	$::=$	$\langle \text{exp} \rangle$
$\langle \text{exp} \rangle$	$::=$	$(\langle \text{exp} \rangle) \langle \text{const} \rangle \langle \text{ident} \rangle $ $\langle \text{exp} \rangle \langle \text{binop} \rangle \langle \text{exp} \rangle \langle \text{callee} \rangle$
$\langle \text{callee} \rangle$	$::=$	$\langle \text{ident} \rangle (\epsilon \langle \text{exp} \rangle [, \langle \text{exp} \rangle]^*)$
$\langle \text{ident} \rangle$	$::=$	$[A - Z_a - z][0 - 9A - Z_a - z]^*$
$\langle \text{const} \rangle$	$::=$	$\langle \text{intconst} \rangle \langle \text{doubleconst} \rangle$
$\langle \text{binop} \rangle$	$::=$	$+ - * <$
$\langle \text{intconst} \rangle$	$::=$	$[0 - 9][0 - 9]^*$
$\langle \text{doubleconst} \rangle$	$::=$	$\langle \text{intconst} \rangle . \langle \text{intconst} \rangle$
$\langle \text{type} \rangle$	$::=$	$\text{int} \text{double}$

LLVM前端架构



Lexer::LexTokenInternal()

```
bool Lexer::LexTokenInternal(Token &Result, bool TokAtPhysicalStartOfLine) {
LexNextToken:
    // New token, can't need cleaning yet.
    Result.clearFlag(Token::NeedsCleaning);
    Result.setIdentifierInfo(nullptr);
    const char *CurPtr = BufferPtr;
    if (isHorizontalWhitespace(*CurPtr)) {
        do {
            ++CurPtr;
        } while (isHorizontalWhitespace(*CurPtr));
        BufferPtr = CurPtr;
        Result.setFlag(Token::LeadingSpace);
    }
    char Char = getAndAdvanceChar(CurPtr, Result);
    tok::TokenKind Kind;
    switch (Char) {
        case '0': case '1': case '2': case '3': case '4':
        case '5': case '6': case '7': case '8': case '9':
            MIOpt.ReadToken();
            return LexNumericConstant(Result, CurPtr);
        case ...
```

根据首字符大致分类

`0-9` → NumericConstant

`A-Za-z_` → Identifier

特殊情况:

- 1) 保留字
- 2) u/U/L

`'\'` → CharConstant

`'\"'` → StringLiteral

`'?'` → tok::question

`'['` → tok::l_square

`']'` → tok::r_square

`'('` → tok::l_paren

`')'` → tok::r_paren

`'{'` → tok::l_brace

`'}'` → tok::r_brace










`';'` → tok::semi

`','` → tok::comma

`':'` → ?

`'.'` → ?

根据前两个字符大致分类



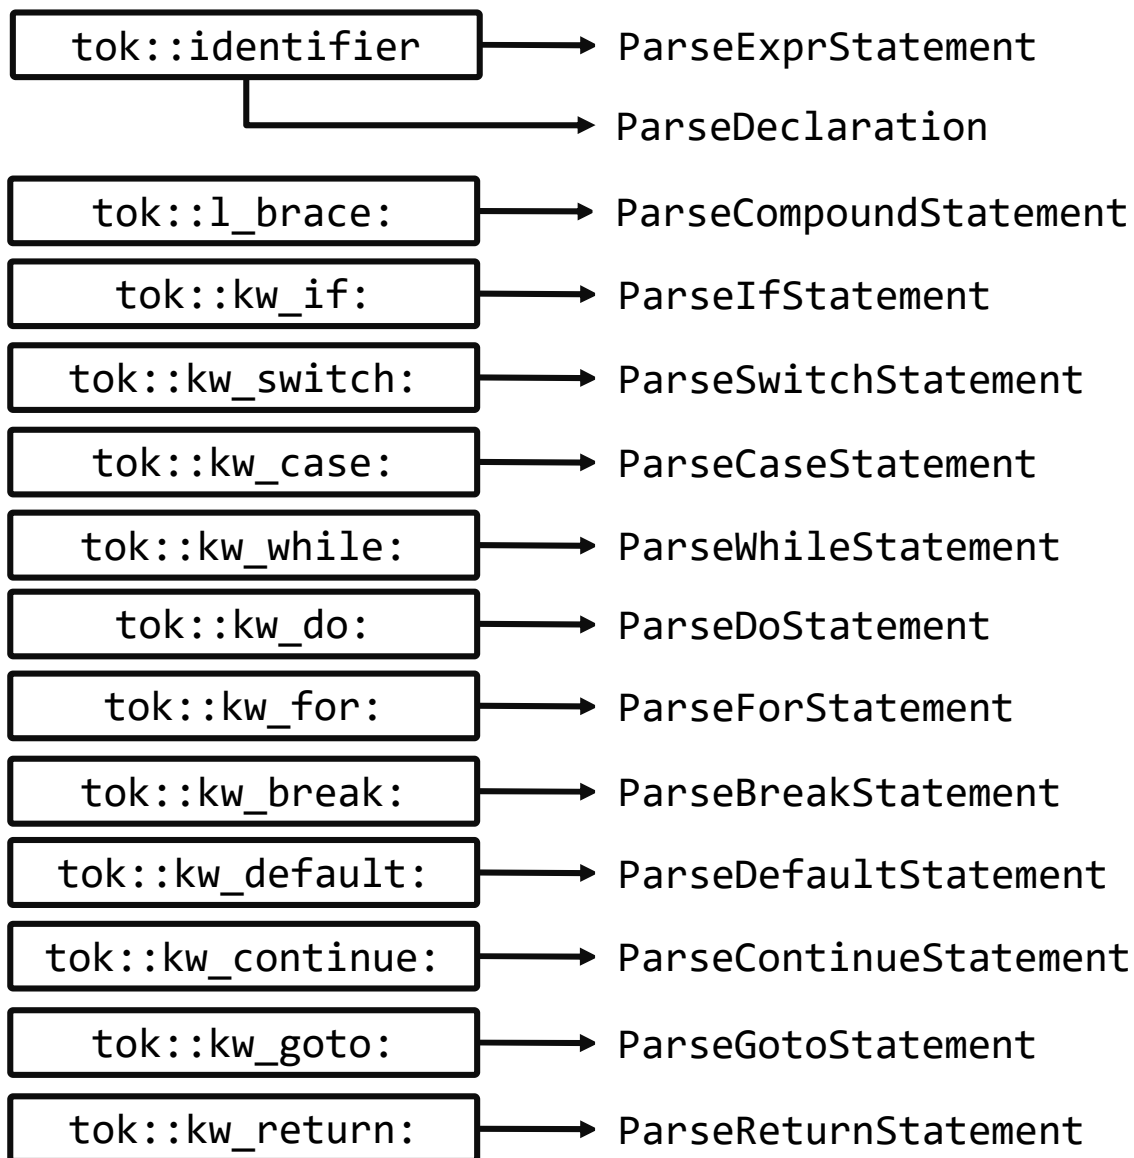
Token类

- 单个token，供lexer和parser使用，AST中不存在。
- `Sizeof(Token)`是16字节
- 分为两类：
 - Normal tokens: lexer返回的结果
 - 标识符信息（指向用于检索的哈希值）
 - Token类型（参照TokenKinds.def中的定义）
 - 位置、长度、Flags
 - 缺少了什么？
 - 数值信息
 - Annotation tokens: parser处理后的结果，添加了语义信息

Parser::ParseStatementOrDeclarationAfterAttributes()

```
Parser::ParseStatementOrDeclarationAfterAttributes(  
    StmtVector &Stmts, ParsedStmtContext StmtCtx,  
    SourceLocation *TrailingElseLoc, ParsedAttributesWithRange &Attrs) {  
    tok::TokenKind Kind = Tok.getKind();  
    switch (Kind) {  
        case tok::at: // May be a @try or @throw statement  
        {  
            AtLoc = ConsumeToken(); // consume @  
            return ParseObjCAtStatement(AtLoc, StmtCtx);  
        }  
        case tok::identifier: {  
            Token Next = NextToken();  
            if (Next.is(tok::colon)) { // C99 6.8.1: labeled-statement  
                return ParseLabeledStatement(Attrs, StmtCtx);  
            }  
            if (Next.isNot(tok::coloncolon)) { ... }  
            default: {  
                ...  
            }  
        }  
        ...  
    }  
}
```


根据首字符大致分类



如何解析表达式？

$x = 2 + 3 * 4 + 5$

- 根据运算符优先级，
- 假设 $* > + > =$



Pratt Parsing

优先级

=: [1,2]

+: [3,4]

*: [5,6]

```
Parse(token, precedence) {  
  left = token.next();  
  if left.type != tok::num  
    return -1;  
  while true:  
    op = token.peek();  
    if op.tokenype != tok::binop  
      return -1;  
    lp, rp = Precedence[op];  
    if lp < precedence  
      break;  
    token.next();  
    right = Parse(token, rp)  
    left = (op, left, right)  
  return left  
}
```

0 1 2 3 4 5 6 3 4 0

x = 2 + 3 * 4 + 5

Parse(start,0)

op: =,

Parse(=,2)

op: +

Parse(+,4)

op: *

Parse(*,+)

Return left = 4

left = *(3, 4)

0 1 2 3 4 5 6 3 4 0

x = 2 + 3 * 4 + 5

Return left = +(2, *(3, 4))

0 1 2 3 4 5 6 3 4 0

x = 2 + 3 * 4 + 5

Parse(pre5,+)

Return left = +(+(2, *(3, 4)), 5)

0 1 2 3 4 5 6 3 4 0

x = 2 + 3 * 4 + 5

Return left = = (x, +(+(2, *(3, 4)), 5))

三、自顶向下分析

Top-down

Recursive-descent

自顶向下构建语法解析树

假设每次都能选对规则

如何解析 $(num+num) \times num$?

```
[1] Expr → Expr + Term
[2]      | Expr - Term
[3]      | Term
[4] Term → Term × Factor
[5]      | Term ÷ Factor
[6]      | Factor
[7] Factor → (Expr)
[8]        | num
[9]        | id
```

word	cur	Rule	Stack
(Expr	[3]	Term
(Term	[4]	Term, ×, Factor
(Term	[6]	Factor, ×, Factor
(Factor	[7]	(, Expr,), ×, Factor
((-	Expr,), ×, Factor
num	Expr	[1]	Expr, +, Term,), ×, Factor
num	Expr	[3]	Term, +, Term,), ×, Factor
num	Term	[6]	Factor, +, Term,), ×, Factor
num	Term	[8]	num, +, Term,), ×, Factor
num	num	-	+, Term,), ×, Factor
+	+	-	Term,), ×, Factor
num	Term	[6]	Factor,), ×, Factor
num	Factor	[8]	num,), ×, Factor
num	num	-), ×, Factor
))	-	×, Factor
×	×	-	Factor
num	Factor	[8]	num
num	num	-	null
eof			

自动搜索语法树的算法...

```
输入：程序单词流 seq;  
      CFG语法 rules;  
Output: accept: 语法解析树 ptree,  
        reject;  
初始化:  
let ptree = start symbol;  
let ptr = root;  
let st = stack();  
st.push(null);  
  
开始:  
let word = seq.NextWord();  
While (true) do:  
    if (!ptr.nodeType().isTerminal())  
        For each rule in  $\{A \rightarrow \beta_1, \dots, \beta_n; A \rightarrow \dots\}$   
            ptr.children =  $(\beta_1, \dots, \beta_n)$ ;  
            For  $1 < i < n+1$   
                st.push( $\beta_{n+2-i}$ );  
            ptr =  $\beta_1$ ;  
        //ptr.nodeType()=terminal  
    else if (word == ptr) //单词匹配成功  
        word = seq.NextWord(); //下一个单词  
        ptr = st.pop()  
    else if (word == eof && cur == null)  
        accept and return ptree;  
    else  
        backtrack(); //回溯
```

- 不考虑递归的情况:
 - $A \rightarrow \dots \rightarrow A$
- 不考虑左递归的情况:
 - $A \rightarrow \dots \rightarrow AX$
- 复杂度高:
 - 单词个数
 - 规则个数
 - 规则生产的符号数
 - 基于栈的回溯

左递归问题

- 对CFG的一个规则来说，其右侧的第一个符号与左侧符号相同或者能够推导出左侧符号。
- 主要问题：可使搜索算法无限递归下去，不终止。

[1]	$Expr \rightarrow Expr + Term$
[2]	$ Expr - Term$
[3]	$ Term$

word	cur	Rule	Stack
(Expr	[1]	<i>Expr</i> , +, <i>Term</i>
(Expr	[1]	<i>Expr</i> , +, <i>Term</i> , +, <i>Term</i>
(Expr	[1]	<i>Expr</i> , +, <i>Term</i> , +, <i>Term</i> , +, <i>Term</i>
			...

消除左递归

- 引入新的非终结符，基本规则：

$$\begin{array}{|l} E \rightarrow E \alpha \\ | \beta \end{array} \Rightarrow \begin{array}{|l} E \rightarrow \beta E' \\ E' \rightarrow \alpha E' \\ | \epsilon \end{array} \qquad \begin{array}{|l} E \rightarrow E \alpha \\ | \beta \\ | \gamma \end{array} \Rightarrow \begin{array}{|l} E \rightarrow \beta E' | \gamma E' \\ E' \rightarrow \alpha E' \\ | \epsilon \end{array}$$

举例：


$$\begin{array}{|l} [1] \textit{Expr} \rightarrow \textit{Expr} + \textit{Term} \\ [2] \quad \quad | \textit{Expr} - \textit{Term} \\ [3] \quad \quad | \textit{Term} \end{array} \Rightarrow \begin{array}{|l} [1] \textit{Expr} \rightarrow \textit{Term} \textit{Expr}' \\ [2] \textit{Expr}' \rightarrow + \textit{Term} \textit{Expr}' \\ [3] \quad \quad | - \textit{Term} \textit{Expr}' \\ [4] \quad \quad | \epsilon \end{array}$$

$$\begin{array}{|l} [4] \textit{Term} \rightarrow \textit{Term} \times \textit{Factor} \\ [5] \quad \quad | \textit{Term} \div \textit{Factor} \\ [6] \quad \quad | \textit{Factor} \end{array} \Rightarrow \begin{array}{|l} [5] \textit{Term} \rightarrow \textit{Factor} \textit{Term}' \\ [6] \textit{Term}' \rightarrow \times \textit{Factor} \textit{Term}' \\ [7] \quad \quad | \div \textit{Factor} \textit{Term}' \\ [8] \quad \quad | \epsilon \end{array}$$

$$\begin{array}{|l} [7] \textit{Facor} \rightarrow (\textit{Expr}) \\ [8] \quad \quad | \textit{num} \\ [9] \quad \quad | \textit{name} \end{array} \Rightarrow \begin{array}{|l} [9] \textit{Facor} \rightarrow (\textit{Expr}) \\ [10] \quad \quad | \textit{num} \\ [11] \quad \quad | \textit{name} \end{array}$$

更多例子

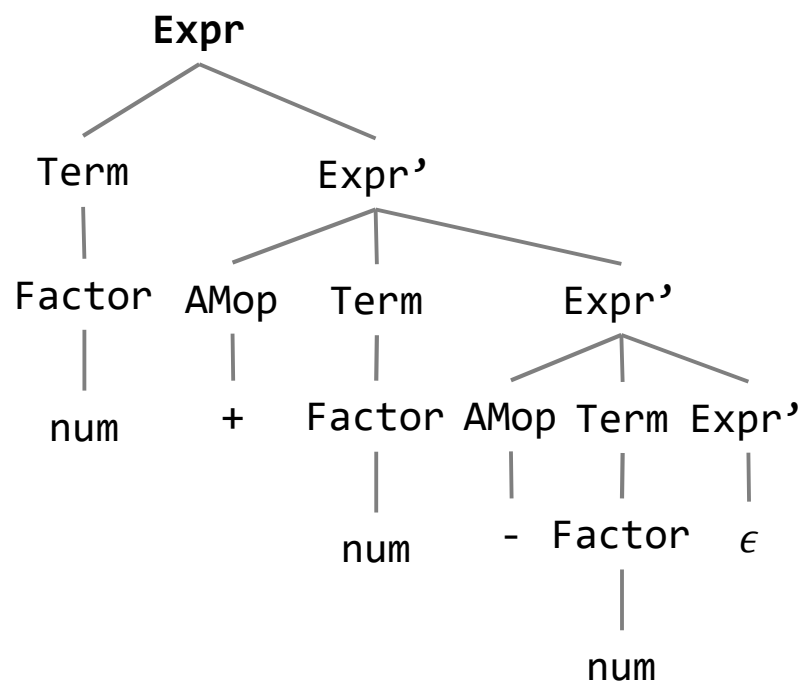
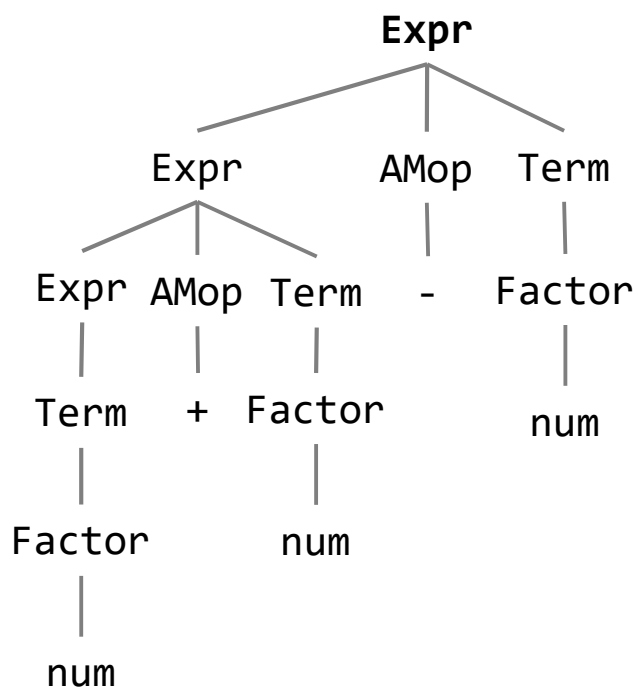
[1] $Expr \rightarrow Expr \text{ AMop } Term$
[2] $| Term$
[3] $Term \rightarrow Term \text{ MDop } Factor$
[4] $| Factor$
[5] $Factor \rightarrow (Expr)$
[6] $| num$
[7] $AMop \rightarrow +$
[8] $| -$
[9] $MDop \rightarrow \times$
[10] $| \div$



[1] $Expr \rightarrow Term \text{ Expr}'$
[2] $Expr' \rightarrow \text{AMop } Term \text{ Expr}'$
[3] $| \epsilon$
[4] $Term \rightarrow Factor \text{ Term}'$
[5] $Term' \rightarrow \text{MDop } Factor \text{ Term}'$
[6] $| \epsilon$
[7] $Factor \rightarrow (Expr)$
[8] $| num$
[9] $AMop \rightarrow +$
[10] $| -$
[11] $MDop \rightarrow \times$
[12] $| \div$

思考

- 是否会改变运算符结合性？如 $3+4-5$ 。
 - 语法解析树和虚拟语法树的区别



间接左递归问题

$$\begin{array}{l} E \rightarrow \alpha \\ \alpha \rightarrow \beta + \\ \beta \rightarrow E \end{array} \quad \Longrightarrow \quad E \rightarrow E +$$

展开所有非终结符NT检测和消除间接左递归

输入: Grammar{T,NT}

开始:

for i=1 to n

 for j=1 to i-1

 if $\exists NT_i \rightarrow NT_j \gamma$

 展开 $NT_i \rightarrow NT_j \gamma$ 中的非终结符 NT_j

 重写会造成 NT_i 左递归的规则

无回溯语法

- 目的：消除语法生成规则选择时的不确定性，避免回溯。
- 思路：如果对于每个非终结符的任意两个生成式，其产生的首个终结符号不同，则在前瞻一个单词的情况下，总能够选择正确的生成式规则。
 - [1] $NT_1 \rightarrow NT_i \rightarrow \dots \rightarrow \text{term}_1 NT_p$
 - [2] $NT_1 \rightarrow NT_j \rightarrow \dots \rightarrow \text{term}_2 NT_q$
- 预测解析 (Predictive Parsing) : LL(1)语法
 - Left-to-Right, Leftmost, 前瞻一个字符


消除回溯：提取左因子

- 对一组产生式提取并隔离共同前缀

$$A \rightarrow \alpha\beta_1 | \alpha\beta_2 | \dots | \alpha\beta_n | \gamma_1 | \dots | \gamma_j \quad \Rightarrow \quad \begin{aligned} A &\rightarrow \alpha B | \gamma_1 | \dots | \gamma_j \\ B &\rightarrow \beta_1 | \beta_2 | \dots | \beta_n \end{aligned}$$

应用举例：

```
[11] Factor → name
[12]         | name [ArgList]
[13]         | name (ArgList)
[14] ArgList → Expr MoreArgs
[15] MoreArgs → , Expr MoreArgs
[16]           | ε
```



```
[11] Factor → name Arguments
[12] Arguments → [ArgList]
[13]             | (ArgList)
[14]             | ε
[15] ArgList → Expr MoreArgs
[16] MoreArgs → , Expr MoreArgs
[17]           | ε
```

无回溯语法的必要性质

$$First^+(A \rightarrow \beta) = \begin{cases} First(\beta), & \text{if } \epsilon \notin First(\beta) \\ First(\beta) \cup Follow(A), & \text{otherwise} \end{cases}$$

$$\forall 1 \leq i, j \leq n, First^+(A \rightarrow \beta_i) \cap First^+(A \rightarrow \beta_j) = \emptyset$$

- 同一非终结符 A 的任意两个语法推导 $(A \rightarrow \beta_i)$ 和 $(A \rightarrow \beta_j)$ 所产生的的首个终结符不能相通。
- $First(\beta)$ 是从语法符号 β 推导出的每个子句的第一个终结符的集合，其值域是 $T \cup \{\epsilon, eof\}$ 。
- 如果 $First(\beta)$ 是 $\{\epsilon\}$ ，则计算紧随 A 之后出现的终结符的集合 $Follow(A)$ 。

First集合计算

- 对于生成式 $A \rightarrow \beta_1 \beta_2 \dots \beta_n$ 来说：
 - 如果 $\epsilon \notin First(\beta_1)$, 则 $First(A) = First(\beta_1)$
 - 如果 $\epsilon \in First(\beta_1) \& \dots \& \epsilon \in First(\beta_i)$, 则 $First(A) = First(\beta_1) \cup \dots \cup First(\beta_{i+1})$

[1] $Expr \rightarrow Term Expr'$
 [2] $Expr' \rightarrow + Term Expr'$
 [3] | $- Term Expr'$
 [4] | ϵ

[5] $Term \rightarrow Factor Term'$
 [6] $Term' \rightarrow \times Factor Term'$
 [7] | $\div Factor Term'$
 [8] | ϵ

[9] $Factor \rightarrow (Expr)$
 [10] | num
 [11] | id

	num	id	+	-	\times	\div	()	ϵ
<i>Expr</i>	✓	✓					✓		
<i>Expr'</i>			✓	✓					✓
<i>Term</i>	✓	✓					✓		
<i>Term'</i>					✓	✓			✓
<i>Factor</i>	✓	✓					✓		

Follow集合计算

- 紧随非终结符之后出现的所有可能的终结符

[1] $Expr \rightarrow Term\ Expr'$
 [2] $Expr' \rightarrow +\ Term\ Expr'$
 [3] | $-\ Term\ Expr'$
 [4] | ϵ

[5] $Term \rightarrow Factor\ Term'$
 [6] $Term' \rightarrow \times\ Factor\ Term'$
 [7] | $\div\ Factor\ Term'$
 [8] | ϵ

[9] $Factor \rightarrow (Expr)$
 [10] | num
 [11] | id

	num	id	+	-	\times	\div	()	ϵ	eof
$Expr$	✓	✓					✓	⊙		⊙
$Expr'$			✓	✓				⊙	✓	⊙
$Term$	✓	✓	⊙	⊙			✓	⊙		⊙
$Term'$			⊙	⊙	✓	✓		⊙	✓	⊙
$Factor$	✓	✓	⊙	⊙	⊙	⊙	✓	⊙		⊙

First+集合计算

$$First^+(A \rightarrow \beta) = \begin{cases} First(\beta), & \text{if } \epsilon \notin First(\beta) \\ First(\beta) \cup Follow(A), & \text{otherwise} \end{cases}$$

	num	id	+	-	×	÷	()	ε	eof
<i>Expr</i>	✓	✓					✓	\odot		\odot
<i>Expr'</i>			✓	✓				\odot	✓	\odot
<i>Term</i>	✓	✓	\odot	\odot			✓	\odot		\odot
<i>Term'</i>			\odot	\odot	✓	✓		\odot	✓	\odot
<i>Facor</i>	✓	✓	\odot	\odot	\odot	\odot	✓	\odot		\odot

解析表构造：应用哪条规则可得到目标终结符？

	num	id	+	-	×	÷	()	ε	eof
<i>Expr</i>	✓	✓					✓			
<i>Expr'</i>			✓	✓				⊙	✓	⊙
<i>Term</i>	✓	✓					✓			
<i>Term'</i>			⊙	⊙	✓	✓		⊙	✓	⊙
<i>Factor</i>	✓	✓					✓			

[1] $Expr \rightarrow Term\ Expr'$
 [2] $Expr' \rightarrow +\ Term\ Expr'$
 [3] | $-\ Term\ Expr'$
 [4] | ϵ

[5] $Term \rightarrow Factor\ Term'$
 [6] $Term' \rightarrow \times\ Factor\ Term'$
 [7] | $\div\ Factor\ Term'$
 [8] | ϵ

[9] $Factor \rightarrow (Expr)$
 [10] | *num*
 [11] | *id*

	num	id	+	-	×	÷	()	ε	eof
<i>Expr</i>	1	1					1			
<i>Expr'</i>			2	3				4		4
<i>Term</i>	5	5					5			
<i>Term'</i>			8	8	6	7		8		8
<i>Factor</i>	10	11					9			

应用解析表

(num+num)×num

[1] $Expr \rightarrow Term\ Expr'$
 [2] $Expr' \rightarrow +\ Term\ Expr'$
 [3] | $-\ Term\ Expr'$
 [4] | ϵ

[5] $Term \rightarrow Factor\ Term'$
 [6] $Term' \rightarrow \times\ Factor\ Term'$
 [7] | $\div\ Factor\ Term'$
 [8] | ϵ

[9] $Facor \rightarrow (Expr)$
 [10] | num
 [11] | id

	num	id	+	-	×	÷	()	<i>eof</i>
<i>Expr</i>	1	1					1		
<i>Expr'</i>			2	3				4	4
<i>Term</i>	5	5					5		
<i>Term'</i>			8	8	6	7		8	8
<i>Facor</i>	10	11					9		

word	cur	Rule	Stack
(Expr	[1]	Term, Expr'
(Term	[5]	Factor, Term', Expr'
(Factor	[9]	(, Expr,), Term', Expr'
((-	Expr,), Term', Expr'
num	Expr	[1]	Term, Expr',), Term', Expr'
num	Term	[5]	Factor, Term', Expr',), Term', Expr'
num	Factor	[10]	num, Term', Expr',), Term', Expr'
num	num	-	Term', Expr',), Term', Expr'
+	Term'	[8]	Expr',), Term', Expr'
+	Expr'	[2]	+, Term, Expr',), Term', Expr'
+	+	-	Term, Expr',), Term', Expr'
num	Term	[5]	Factor, Term', Expr',), Term', Expr'
num	Factor	[10]	num, Term', Expr',), Term', Expr'
num	num	-	Term', Expr',), Term', Expr'
)	Term'	[8]	Expr',), Term', Expr'
)	Expr'	[4]), Term', Expr'
))	-	Term', Expr'
+	Term'	[8]	Expr'
...

练习：

- 将正则表达式CFG改写为LL(1)语法并写出应用解析表

```
< regex > ::= < union > | < concat >  
< union > ::= < regex > "|" < concat >  
< concat > ::= < concat > < term > | < term >  
< term > ::= < element > * | < element >  
< element > ::= (< regex > ) | < alphanum >
```

解答：消除左递归

- 左递归问题一：
 - $\langle concat \rangle ::= \langle concat \rangle \langle term \rangle \mid \langle term \rangle$
- 改写结果：
 - $\langle concat \rangle ::= \langle term \rangle \langle concat' \rangle$
 - $\langle concat' \rangle ::= \langle term \rangle \langle concat' \rangle \mid \epsilon$
- 和下列形式等价（但转换AST时要注意结合性）：
 - $\langle concat \rangle ::= \langle term \rangle \langle concat \rangle \mid \langle term \rangle$
- 左递归问题二（间接左递归）：
 - $\langle regex \rangle ::= \langle union \rangle \mid \langle concat \rangle$
 - $\langle union \rangle ::= \langle regex \rangle \mid \langle concat \rangle$
 - $\Rightarrow \langle regex \rangle ::= \langle regex \rangle \mid \langle concat \rangle \mid \langle concat \rangle$
- 改写结果：
 - $\langle regex \rangle ::= \langle concat \rangle \langle regex' \rangle$
 - $\langle regex' \rangle ::= \mid \langle concat \rangle \langle regex' \rangle \mid \epsilon$

```
[1] < regex > ::= < concat > < regex' >
[2] < regex' > ::= " | " < concat > < regex' >
[3]                | ε
[4] < concat > ::= < term > < concat' >
[5] < concat' > ::= < term > < concat' >
[6]                | ε
[7] < term > ::= < element > *
[8]                | < element >
[9] < element > ::= ( < regex > )
[10]                | < alphanum >
```

解答：消除回溯

- 回溯问题语法
 - $\langle term \rangle ::= \langle element \rangle^*$
 - $\quad \quad \quad | \langle element \rangle$
- 改写结果：
 - $\langle term \rangle ::= \langle element \rangle \langle follow \rangle$
 - $\langle follow \rangle ::= * | \epsilon$

```
[1]  $\langle regex \rangle ::= \langle concat \rangle \langle regex' \rangle$ 
[2]  $\langle regex' \rangle ::= "|" \langle concat \rangle \langle regex' \rangle$ 
[3]  $\quad \quad \quad | \epsilon$ 
[4]  $\langle concat \rangle ::= \langle term \rangle \langle concat' \rangle$ 
[5]  $\langle concat' \rangle ::= \langle term \rangle \langle concat' \rangle$ 
[6]  $\quad \quad \quad | \epsilon$ 
[7]  $\langle term \rangle ::= \langle element \rangle \langle follow \rangle$ 
[8]  $\langle follow \rangle ::= *$ 
[9]  $\quad \quad \quad | \epsilon$ 
[10]  $\langle element \rangle ::= (\langle regex \rangle)$ 
[11]  $\quad \quad \quad | \langle alphanum \rangle$ 
```

解答：构建LL(1)解析表

	()	A – Z, a – z, 0 – 9		*	ε	eof
<i>regex</i>	√[1]		√[1]				
<i>regex'</i>				√[1]		√	⊙[3]
<i>concat</i>	√[4]		√[4]				
<i>concat'</i>	√[5]		√[5]			√	⊙[6]
<i>term</i>	√[7]		√[7]				
<i>element</i>	√[10]		√[11]				
<i>follow</i>	⊙[9]		⊙[9]		√[8]	√	
<i>alphanum</i>			√[12]				

√:first()

⊙:follow()

[]:语法规则条目

通用自顶向下语法分析算法：Earley算法

- 三种基本操作：

- 预测 (Prediction) : 对于每个状态 $X \rightarrow \alpha \circ Y \beta$, 根据语法规则预测 $Y \rightarrow \circ \gamma$ 。
- 扫描 (Scanning) : 如果下一个待处理的符号是 a , 并且存在状态 $X \rightarrow \alpha \circ a \beta$, 则扫描该字符并且将状态变更为 $X \rightarrow \alpha a \circ \beta$ 。
- 完成 (Completion) : $Y \rightarrow \gamma \circ$ 完成了对 Y 的分析, 进而更新 $X \rightarrow \alpha \circ Y \beta$ 为 $X \rightarrow \alpha Y \circ \beta$ 。

Earley

算法参考

```
DECLARE ARRAY S;

function INIT(words) {
    S ← CREATE-ARRAY(LENGTH(words) + 1)
    for k ← from 0 to LENGTH(words)
        S[k] ← EMPTY-ORDERED-SET
}

function EARLEY-PARSE(words, grammar) {
    INIT(words)
    ADD-TO-SET(( $\gamma \rightarrow \bullet S$ , 0), S[0])
    for k ← from 0 to LENGTH(words)
        for each state in S[k] { // S[k] can expand during this loop
            if not FINISHED(state) {
                if NEXT-ELEMENT-OF(state) is a nonterminal then
                    PREDICTOR(state, k, grammar) // non-terminal
                else
                    SCANNER(state, k, words) // terminal
            }
            else
                COMPLETER(state, k)
        }
    }
    return chart
}

procedure PREDICTOR(( $A \rightarrow \alpha \bullet B \beta$ , j), k, grammar) {
    for each ( $B \rightarrow \gamma$ ) in GRAMMAR-RULES-FOR(B, grammar)
        ADD-TO-SET(( $B \rightarrow \bullet \gamma$ , k), S[k])
}

procedure SCANNER(( $A \rightarrow \alpha \bullet a \beta$ , j), k, words)
    if  $a \in \text{PARTS-OF-SPEECH}(\text{words}[k])$ 
        ADD-TO-SET(( $A \rightarrow \alpha a \bullet \beta$ , j), S[k+1])

procedure COMPLETER(( $B \rightarrow \gamma \bullet$ , x), k)
    for each ( $A \rightarrow \alpha \bullet B \beta$ , j) in S[x]
        ADD-TO-SET(( $A \rightarrow \alpha B \bullet \beta$ , j), S[k])
```

Earley算法

如何根据下列语法规则
解析 $(3+4) \times 5$?

$(num+num) \times num$

[1]	$Expr \rightarrow Expr + Term$
[2]	$ Expr - Term$
[3]	$ Term$
[4]	$Term \rightarrow Term \times Factor$
[5]	$ Term \div Factor$
[6]	$ Factor$
[7]	$Factor \rightarrow (Expr)$
[8]	$ num$
[9]	$ id$

no	production	origin	comment
$s(0) = \circ (num+num) \times num$			
1	$Expr \rightarrow \circ Expr + Term$	$s(0)$	start rule
2	$Expr \rightarrow \circ Expr - Term$	$s(0)$	start rule
3	$Expr \rightarrow \circ Term$	$s(0)$	start rule
4	$Term \rightarrow \circ Term \times Factor$	$s(0)$	Predict from [0][3]
5	$Term \rightarrow \circ Term \div Factor$	$s(0)$	Predict from [0][3]
6	$Term \rightarrow \circ Factor$	$s(0)$	Predict from [0][3]
7	$Factor \rightarrow \circ (Expr)$	$s(0)$	Predict from [0][6]
8	$Factor \rightarrow \circ num$	$s(0)$	Predict from [0][6]
9	$Factor \rightarrow \circ id$	$s(0)$	Predict from [0][6]
$s(1) = (\circ num+num) \times num$			
1	$Factor \rightarrow (\circ Expr)$	$s(0)$	Scan from [0][7]
2	$Expr \rightarrow \circ Expr + Term$	$s(1)$	Predict from [1][1]
3	$Expr \rightarrow \circ Expr - Term$	$s(1)$	Predict from [1][1]
4	$Expr \rightarrow \circ Term$	$s(1)$	Predict from [1][1]
5	$Term \rightarrow \circ Term \times Factor$	$s(1)$	Predict from [1][4]
6	$Term \rightarrow \circ Term \div Factor$	$s(1)$	Predict from [1][4]
7	$Term \rightarrow \circ Factor$	$s(1)$	Predict from [1][4]
8	$Factor \rightarrow \circ (Expr)$	$s(1)$	Predict from [1][7]
9	$Factor \rightarrow \circ num$	$s(1)$	Predict from [1][7]
10	$Factor \rightarrow \circ id$	$s(1)$	Predict from [1][7]

Earley算法

[1] $Expr \rightarrow Expr + Term$
 [2] | $Expr - Term$
 [3] | $Term$
 [4] $Term \rightarrow Term \times Factor$
 [5] | $Term \div Factor$
 [6] | $Factor$
 [7] $Factor \rightarrow (Expr)$
 [8] | num
 [9] | id

no	production	origin	comment
$s(2) = (num \circ + num) \times num$			
1	$Factor \rightarrow num \circ$	$s(1)$	Scan from [1][9]
2	$Term \rightarrow Factor \circ$	$s(1)$	Complete [1][7]
3	$Term \rightarrow Term \circ \times Factor$	$s(1)$	Complete [1][5]
4	$Term \rightarrow Term \circ \div Factor$	$s(1)$	Complete [1][6]
5	$Expr \rightarrow Term \circ$	$s(1)$	Complete [1][4]
6	$Expr \rightarrow Expr \circ + Term$	$s(1)$	Complete [1][2]
7	$Expr \rightarrow Expr \circ - Term$	$s(1)$	Complete [1][3]
8	$Factor \rightarrow (Expr \circ)$	$s(0)$	Complete [1][1]
$s(3) = (num + \circ num) \times num$			
1	$Expr \rightarrow Expr + \circ Term$	$s(1)$	Scan from [2][6]
2	$Term \rightarrow \circ Term \times Factor$	$s(3)$	Predict from [3][1]
3	$Term \rightarrow \circ Term \div Factor$	$s(3)$	Predict from [3][1]
4	$Term \rightarrow \circ Factor$	$s(3)$	Predict from [3][1]
5	$Factor \rightarrow \circ (Expr)$	$s(3)$	Predict from [3][4]
6	$Factor \rightarrow \circ num$	$s(3)$	Predict from [3][4]
7	$Factor \rightarrow \circ id$	$s(3)$	Predict from [3][4]

Earley算法

[1] $Expr \rightarrow Expr + Term$
 [2] | $Expr - Term$
 [3] | $Term$
 [4] $Term \rightarrow Term \times Factor$
 [5] | $Term \div Factor$
 [6] | $Factor$
 [7] $Factor \rightarrow (Expr)$
 [8] | num
 [9] | id

no	production	origin	comment
$s(4) = (num+num \circ) \times num$			
1	$Factor \rightarrow num \circ$	$s(3)$	Scan from [3][6]
2	$Term \rightarrow Factor \circ$	$s(3)$	Complete [3][7]
3	$Term \rightarrow Term \circ \times Factor$	$s(3)$	Complete [3][5]
4	$Term \rightarrow Term \circ \div Factor$	$s(3)$	Complete [3][6]
5	$Expr \rightarrow Term \circ$	$s(3)$	Complete [3][4]
6	$Expr \rightarrow Expr \circ + Term$	$s(3)$	Complete [3][2]
7	$Expr \rightarrow Expr \circ - Term$	$s(3)$	Complete [3][3]
8	$Expr \rightarrow Expr + Term \circ$	$s(1)$	Complete [3][1]
9	$Factor \rightarrow (Expr \circ)$	$s(0)$	Complete [1][1]
$s(5) = (num+num) \circ \times num$			
1	$Factor \rightarrow (Expr) \circ$	$s(0)$	Scan from [4][9]
2	$Term \rightarrow Factor \circ$	$s(0)$	Complete [0][6]
3	$Term \rightarrow Term \circ \times Factor$	$s(0)$	Complete [0][4]
4	$Term \rightarrow Term \circ \div Factor$	$s(0)$	Complete [0][5]
5			
6			
7			

Earley算法

```

[1] Expr → Expr + Term
[2]      | Expr - Term
[3]      | Term
[4] Term → Term × Factor
[5]      | Term ÷ Factor
[6]      | Factor
[7] Facor → (Expr)
[8]      | num
[9]      | id
    
```

no	production	origin	comment
s(6) = (num+num)×°num			
1	$Term \rightarrow Term \times \circ Factor$	s(0)	Scan from [6][3]
2	$Facor \rightarrow \circ (Expr)$	s(0)	Predict from [6][1]
3	$Facor \rightarrow \circ num$	s(6)	Predict from [6][1]
4	$Facor \rightarrow \circ id$	s(6)	Predict from [6][1]
s(7) = (num+num)×num°			
1	$Facor \rightarrow num \circ$	s(6)	Scan from [6][4]
2	$Term \rightarrow Term \times Factor \circ$	s(0)	Complete [6][1]
3	$Expr \rightarrow Term \circ$	s(0)	Complete [0][3]
4			
5			
6			
7			

Earley算法能否解析非CFG语法?

练习：

- 应用Earley算法解析正则 $\text{num}+\text{num}-\text{num}$
- 应用Earley算法解析正则 $(a|b)^*$

```
[1]  $Expr \rightarrow Expr + Term$   
[2]      |  $Expr - Term$   
[3]      |  $Term$   
[4]  $Term \rightarrow Term \times Factor$   
[5]      |  $Term \div Factor$   
[6]      |  $Factor$   
[7]  $Factor \rightarrow (Expr)$   
[8]      |  $num$   
[9]      |  $id$ 
```

```
[1]  $\langle regex \rangle ::= \langle union \rangle$   
[2]      |  $\langle concat \rangle$   
[3]  $\langle union \rangle ::= \langle regex \rangle \mid \langle concat \rangle$   
[4]  $\langle concat \rangle ::= \langle concat \rangle \langle term \rangle$   
[5]      |  $\langle term \rangle$   
[6]  $\langle term \rangle ::= \langle element \rangle^*$   
[7]      |  $\langle element \rangle$   
[8]  $\langle element \rangle ::= (\langle regex \rangle)$   
[9]      |  $\langle alphanumeric \rangle$ 
```

自顶向下解析算法小结

- Earley算法
 - 支持所有CFG
 - 复杂度 $O(n^3)$
 - 无歧义语法: $O(n^2)$
- 能否有更快的算法?
 - 要求CFG为LL(1)
 - 不存在左递归
 - 不存在回溯



A programmer's wife asks him to go to the grocery. She says "Get a gallon of milk. If they have eggs, get 12." The programmer returns with 12 gallons of milk.

A programmer is going to the grocery store and his wife tells him, "Buy a gallon of milk, and if there are eggs, buy a dozen." So the programmer goes, buys everything, and drives back to his house. Upon arrival, his wife angrily asks him, "Why did you get 13 gallons of milk?" The programmer says, "There were eggs!"

四、自底向上分析

SLR/LALR/LR(1)

基本思路：基于规约的方法

- 如果在句法分析栈的上边缘找到 β 且 $A \rightarrow \beta$ ，则将其规约为 A ；
- 否则移进

[1]	$S \rightarrow \epsilon$
[2]	[S]S

	当前栈	待输入
第1步:		[]
第2步:	[]
第3步:	[S]
第4步:	[S]S	
第5步:	S	

移进和规约 (Shift-Reduce)

$$\begin{array}{ll} \text{Shift} & \text{Reduce} \\ \text{移进表示:} & \text{规约表示:} \end{array} \quad \frac{w:\beta}{wa:\beta a} \text{shift} \quad \frac{[r] X \rightarrow \alpha}{w:\beta \alpha} \text{reduce}(r)$$

$$\begin{array}{ll} \text{示例:} & \end{array} \quad \begin{array}{l} \frac{\epsilon:\beta_0}{[:\beta_0[} \text{shift} \\ \frac{[:\beta_1}{[]:\beta_1]} \text{shift} \\ \dots \\ \frac{[][][]:\beta_7}{[][][]:\beta_7]} \text{shift} \end{array} \quad \begin{array}{l} [1] S \rightarrow \epsilon \\ \frac{w:\beta}{w:\beta S} \text{reduce}([1]) \\ [2] S \rightarrow [S]S \\ \frac{w:\beta[S]S}{w:\beta S} \text{reduce}([2]) \end{array}$$

移进-规约应用


最右推导

	[] [] [] []
[[] [] [] []
[S] [] [] []
[S]	[] [] [] []
[S][] [] [] []
[S][[] [] [] []
[S][[S] [] [] []
[S][[S]] [] [] []
[S][[S][] [] [] []
[S][[S][S] [] [] []
[S][[S][S]] [] [] []
[S][[S][S]S] [] [] []
[S][[S]S] [] [] []
[S]S] [] [] []
S] [] [] []

[illegible]
$$\begin{array}{l} [1] \quad S \rightarrow \epsilon \\ [2] \quad \quad | [S]S \end{array}$$

```
shift [
reduce([1])
shift
shift
shift
reduce([1])
shift
shift
reduce([1])
shift
reduce([1])
reduce([2])
reduce([2])
shift
reduce([1])
reduce([2])
reduce([2])
```

LR(0)句柄分析



可应用 $E \rightarrow E + T$
规约的句柄状态 ➡

$E \rightarrow \circ E + T$

$E \rightarrow E \circ + T$

$E \rightarrow E + \circ T$

$E \rightarrow E + T \circ$

可应用 $E \rightarrow T$
规约的句柄状态 ➡

$E \rightarrow \circ T$

$E \rightarrow T \circ$

可应用 $T \rightarrow T \times F$
规约的句柄状态 ➡

$T \rightarrow \circ T \times F$

$T \rightarrow T \circ \times F$

$T \rightarrow T \times \circ F$

$T \rightarrow T \times F \circ$

可应用 $T \rightarrow F$
规约的句柄状态 ➡

$T \rightarrow \circ F$

$T \rightarrow F \circ$

可应用 $F \rightarrow (E)$
规约的句柄状态 ➡

$F \rightarrow \circ (E)$

$F \rightarrow (\circ E)$

$F \rightarrow (E \circ)$

$F \rightarrow (E) \circ$

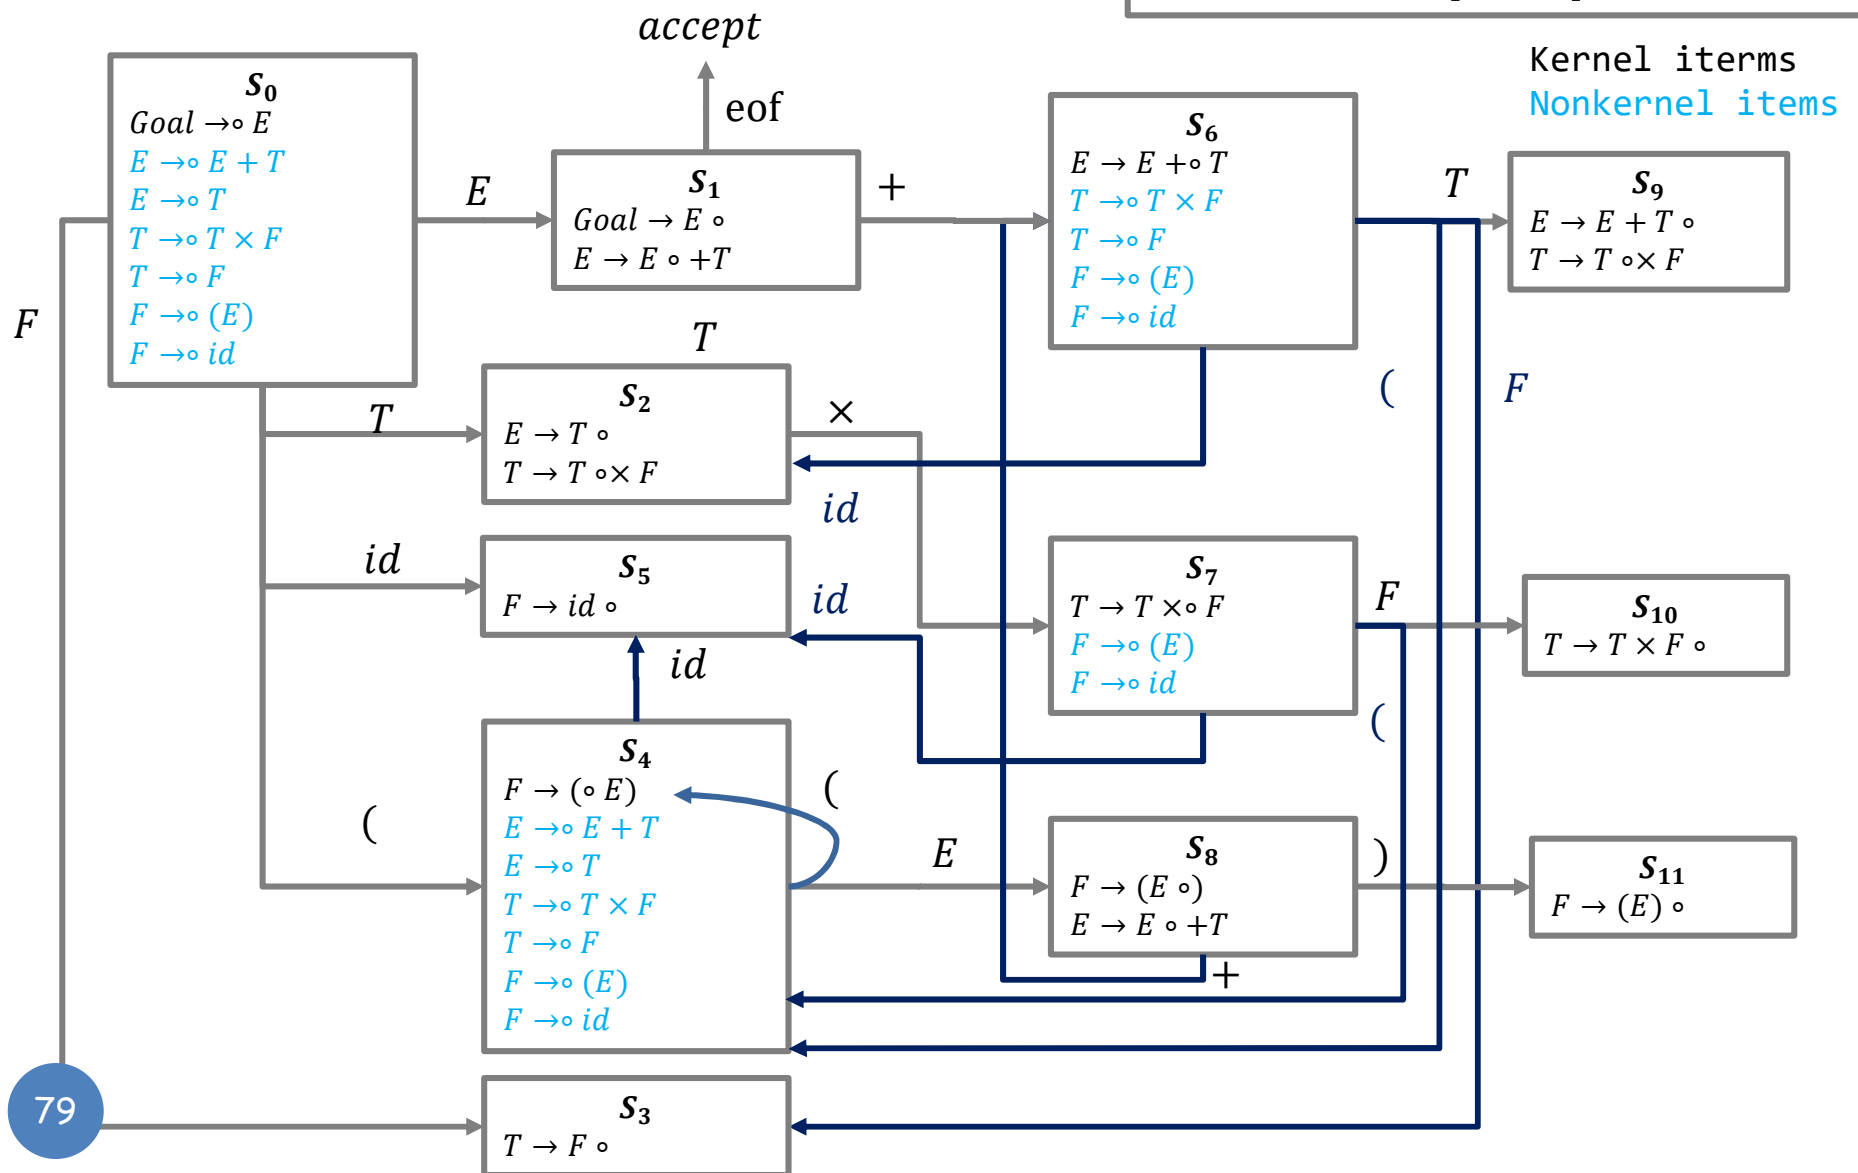
可应用 $F \rightarrow id$
规约的句柄状态 ➡

$F \rightarrow \circ id$

$F \rightarrow id \circ$

LR(0)自动机构建

While (S has changed)
 for each item $[A \rightarrow \beta \circ C \delta, a] \in S$
 for each production $[C \rightarrow \lambda] \in G$
 if $[C \rightarrow \circ \lambda] \notin S$
 $S \leftarrow S \cup [C \rightarrow \circ \lambda]$



LR(0)自动机的状态转移关系表

迭代	规范项	id	+	×	()	eof	E	T	F
0	S_0	S_5	\emptyset	\emptyset	S_4	\emptyset	\emptyset	S_1	S_2	S_3
1	S_1	\emptyset	S_6	\emptyset	\emptyset	\emptyset	<i>accept</i>	\emptyset	\emptyset	\emptyset
	S_2	\emptyset	\emptyset	S_7	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset
	S_3	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset
	S_4	S_5	\emptyset	\emptyset	S_4	\emptyset	\emptyset	S_8	S_2	S_3
	S_5	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset
2	S_6	S_5	\emptyset	\emptyset	S_4	\emptyset	\emptyset	\emptyset	S_9	S_3
	S_7	S_5	\emptyset	\emptyset	S_4	\emptyset	\emptyset	\emptyset	\emptyset	S_{10}
	S_8	\emptyset	S_6	\emptyset	\emptyset	S_{11}	\emptyset	\emptyset	\emptyset	\emptyset
3	S_9	\emptyset	\emptyset	S_7	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset
	S_{10}	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset
	S_{11}	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset	\emptyset

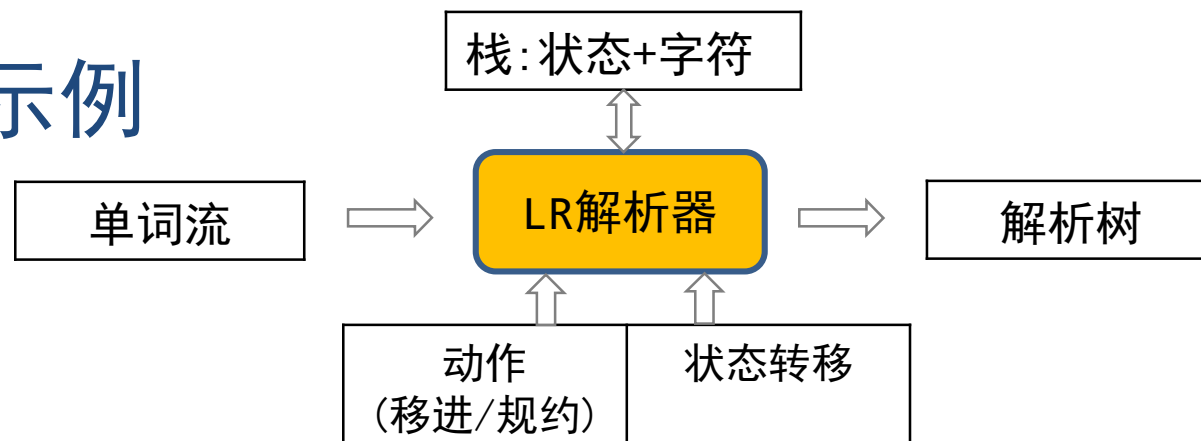
构建SLR解析表

移进条件：如果 $A \rightarrow \alpha \circ a\beta \in S_i$ ，并且 $Goto(S_i, a) = S_j$ ，设置 $Action(S_i, a) = \text{"shift } j\text{"}$

规约条件：如果 $A \rightarrow \alpha \circ \in S_i$ ， $\forall a \in Follow(A)$ ，设置 $Action(S_i, a) = \text{"reduce } A \rightarrow \alpha\text{"}$

规范项	Action						Goto		
	id	+	×	()	eof	E	T	F
S ₀	shift S ₅			shift S ₄			S ₁	S ₂	S ₃
S ₁		shift S ₆				accept			
S ₂		reduce [2]	shift S ₇		reduce [2]	reduce [2]			
S ₃									
S ₄	shift S ₅			shift S ₄			S ₈	S ₂	S ₃
S ₅		reduce [6]	reduce [6]		reduce [6]	reduce [6]			
S ₆	shift S ₅			shift S ₄				S ₉	S ₃
S ₇	shift S ₅			shift S ₄					S ₁₀
S ₈		shift S ₆			shift S ₁₁				
S ₉		reduce [1]	shift S ₇		reduce [1]	reduce [1]			
S ₁₀		reduce [3]	reduce [3]		reduce [3]	reduce [3]			
S ₁₁		reduce [5]	reduce [5]		reduce [5]	reduce [5]			

SLR应用示例



Stack	Symbols	Input	Action
S_0		id×id \$	shift id, goto S_5
S_0S_5	id	×id \$	reduce by $F \rightarrow id$, back to S_0 , goto S_3
S_0S_3	F	×id \$	reduce by $T \rightarrow F$, back to S_0 , goto S_2
S_0S_2	T	×id \$	shift ×, goto S_7
$S_0S_2S_7$	T ×	id \$	shift id, goto S_5
$S_0S_2S_7S_5$	T × id	\$	reduce by $F \rightarrow id$, back to S_7 , goto S_{10}
$S_0S_2S_7S_{10}$	T × F	\$	reduce by $T \rightarrow T \times F$, back to $S_7S_2S_0$, goto S_2
S_0S_2	T	\$	reduce by $E \rightarrow T$, back to S_0 , goto S_1
S_0S_1	E	\$	

练习

- 下面的语法是否是LL(1)? 是否是SLR(1)

[1] $S \rightarrow AaAb$
[2] $\quad \quad |BbBa$
[3] $A \rightarrow \epsilon$
[4] $B \rightarrow \epsilon$

是LL(1)

$First^+(S \rightarrow AaAb) = \{a\}$

$First^+(S \rightarrow BbBa) = \{b\}$

S_0
 $S' \rightarrow \circ S$
 $S \rightarrow \circ AaAb$
 $S \rightarrow \circ BbAa$
 $A \rightarrow \circ$
 $B \rightarrow \circ$

不是SLR(1)

$Follow(A) = Follow(B) = \{a, b\}$

$Action(S_0, a) = reduce[3] \text{ 或 } reduce[4]$

练习

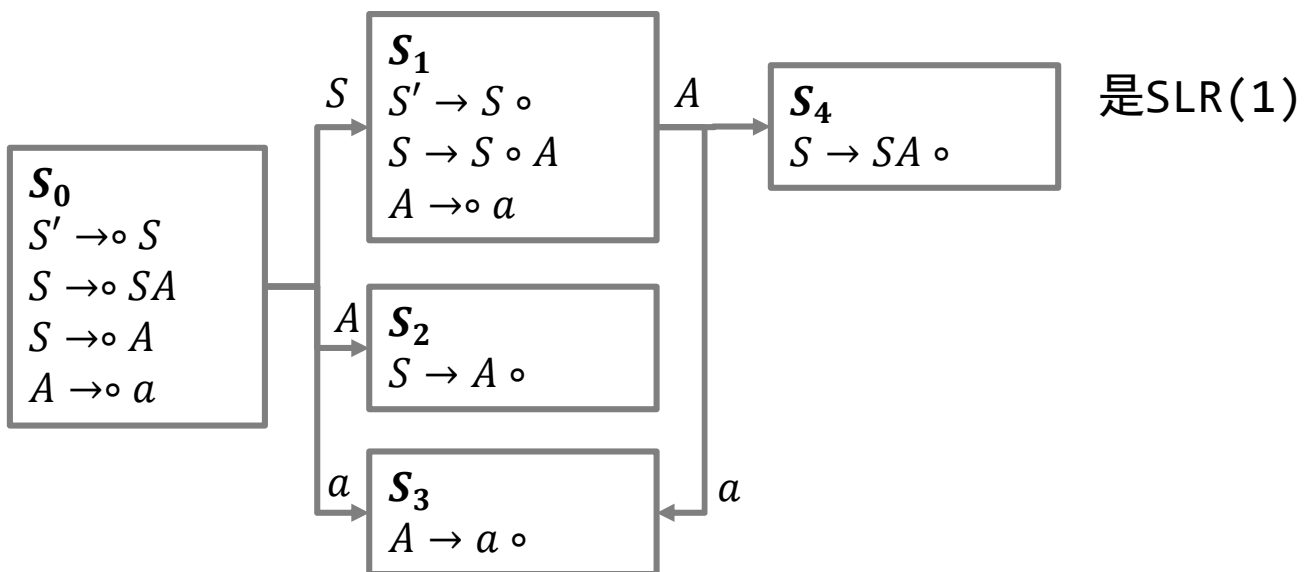
- 下面的语法是否是LL(1)? 是否是SLR(1)

[1] $S \rightarrow SA$
[2] $|A$
[3] $A \rightarrow a$

不是LL(1)

$First^+(S \rightarrow SA) = \{a\}$

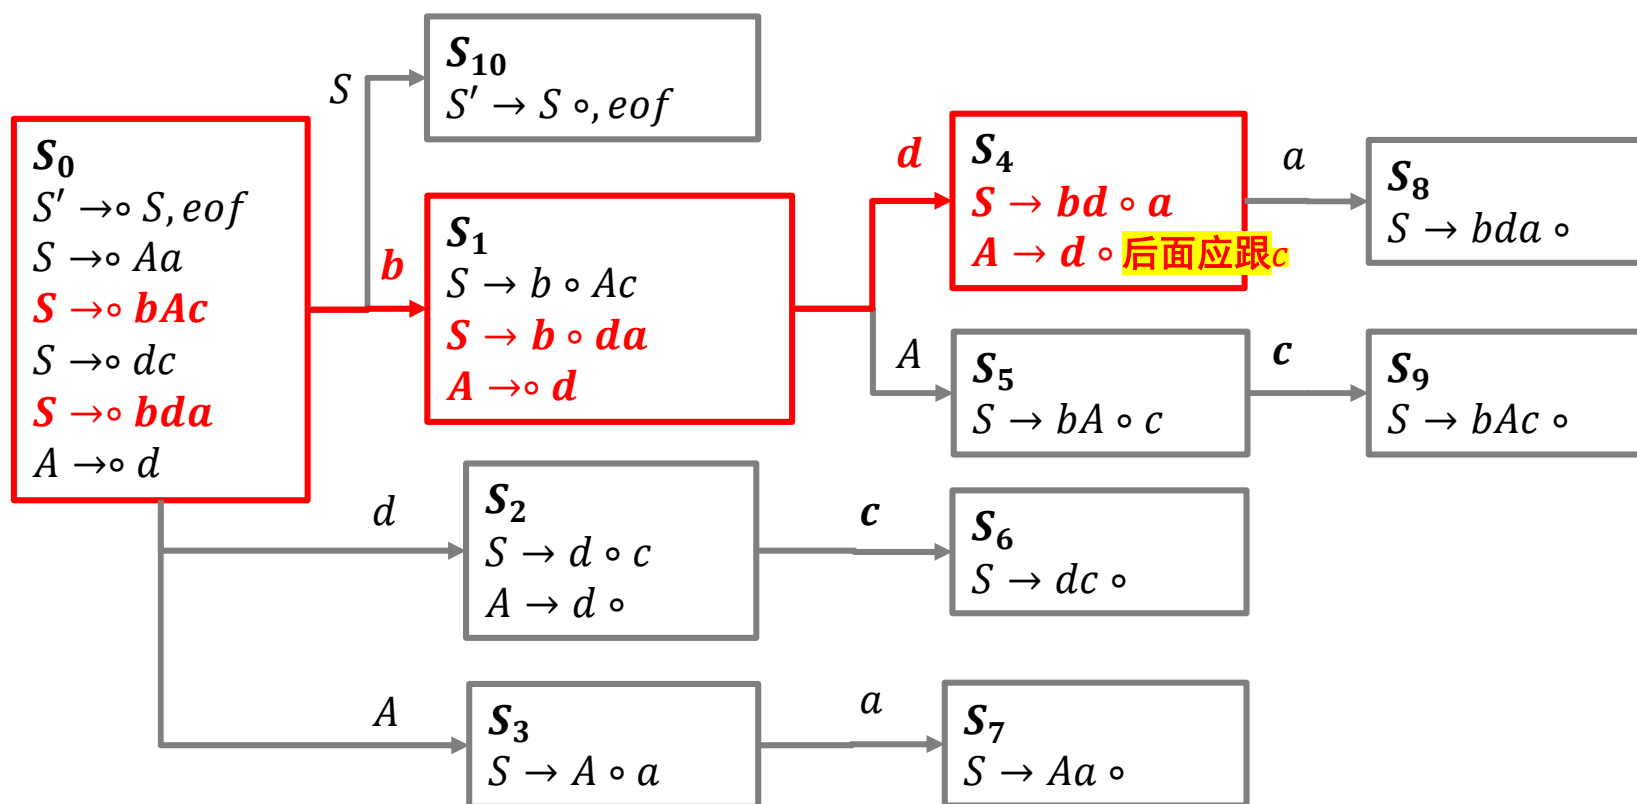
$First^+(S \rightarrow A) = \{a\}$



二义性语法：移进-规约冲突

- 利用SLR解析表解析bda时存在移进-规约冲突
 - S_4 下一个字符为 a ，可移进
 - $a \in \text{Follow}(A)$ ，可规约

[1]	$S \rightarrow Aa$
[2]	$\quad \quad bAc$
[3]	$\quad \quad dc$
[4]	$\quad \quad bda$
[5]	$A \rightarrow d$



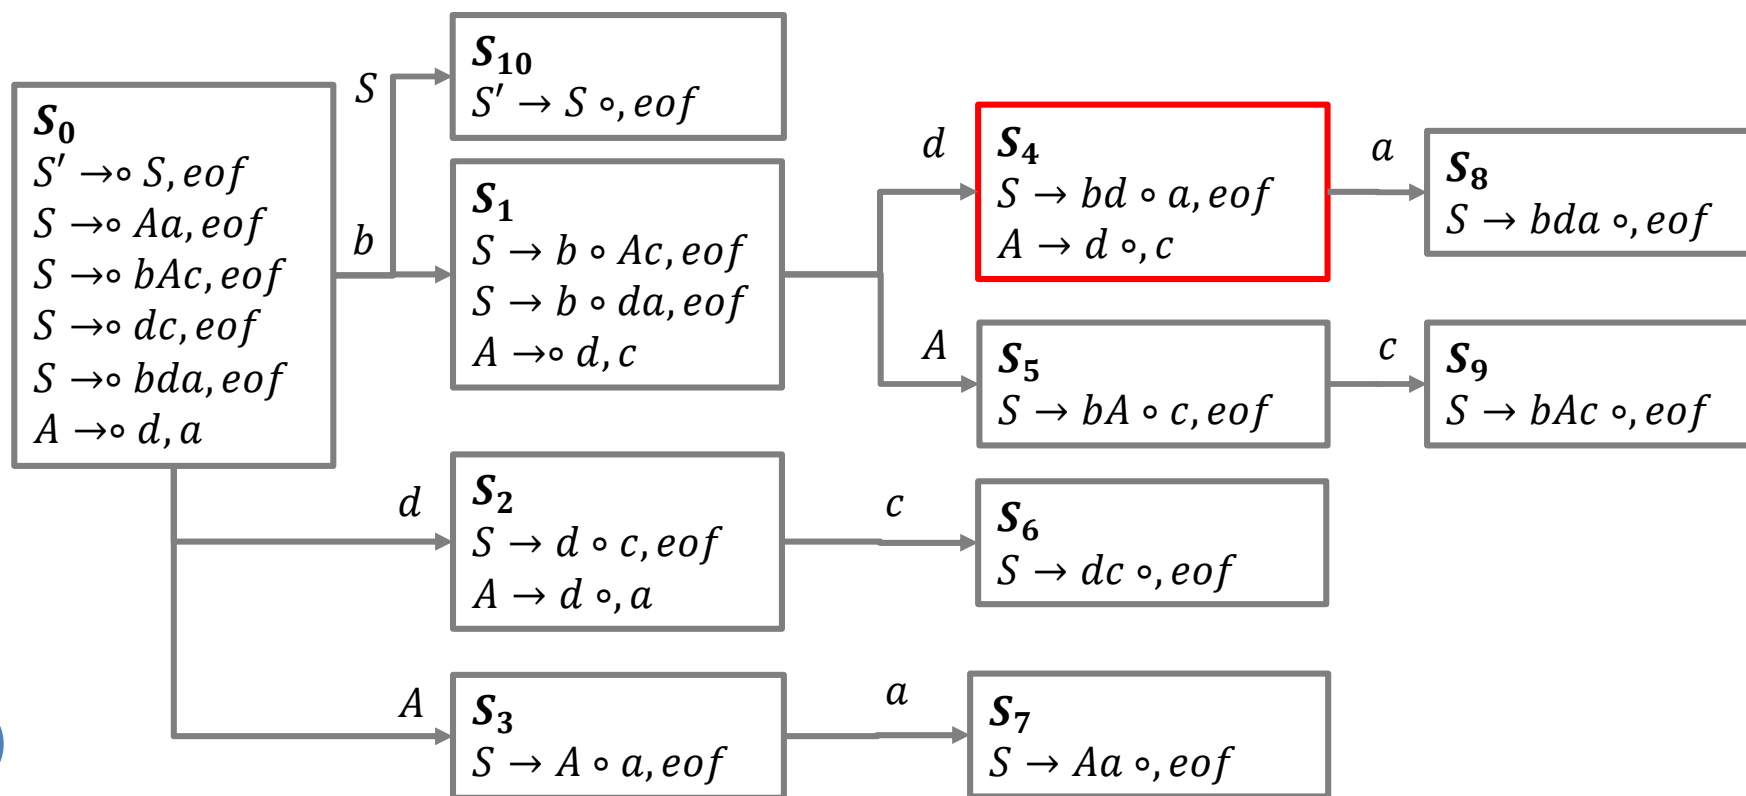
LR(1)自动机构造

[0] $S' \rightarrow S$
[1] $S \rightarrow Aa$
[2] $\quad |bAc$
[3] $\quad |dc$
[4] $\quad |bda$
[5] $A \rightarrow d$

1) 构造其LR(1)项的全集

2) 迭代过程

- 通过闭包找到规范族
- 分析规范族之间的状态转移关系



得到LR(1)解析表

规范项	Action					Goto	
	a	b	c	d	eof	S	A
S ₀		shift S ₁		shift S ₂		S ₁₀	S ₃
S ₁				shift S ₄			S ₅
S ₂	reduce [5]		shift S ₆				
S ₃	shift S ₇						
S ₄	shift S ₈		reduce [5]				
S ₅			shift S ₉				
S ₆					reduce [3]		
S ₇					reduce [1]		
S ₈					reduce [4]		
S ₉					reduce [2]		
S ₁₀					accept		

应用LR(1)解析表

Stack	Symbols	Input	Action
S_0		bda \$	shift b, goto S_1
S_0S_1	b	da \$	shift d, goto S_4
$S_0S_1S_4$	bd	a \$	shift d, goto S_8
$S_0S_1S_4S_8$	bda	\$	reduce by $S \rightarrow bda$, back to S_0 , goto S_{10}
S_0S_{10}	S	\$	accept

什么情况下容易出现移进-规约冲突？

[1]	$S \rightarrow bAc$
[2]	bda
[3]	Aa
[4]	$A \rightarrow d$

[1]	$S \rightarrow \beta_1 X \beta_2$
[2]	$\beta_1 \beta_3 \beta_4$
[3]	$X \rightarrow \beta_3$

- 同一非终结符的两条规则：
 - 拥有共同的起始字符串 β_1 ；
 - β_1 后面分别为非终结符 $X\beta_2$ 和字符串 $\beta_3\beta_4$ ；
 - 存在规则 $X \rightarrow \beta_3$ 。
 - $Follow(X) \cap First(\beta_4) \neq \emptyset$
- 或存在两种推导满足上述条件，如：

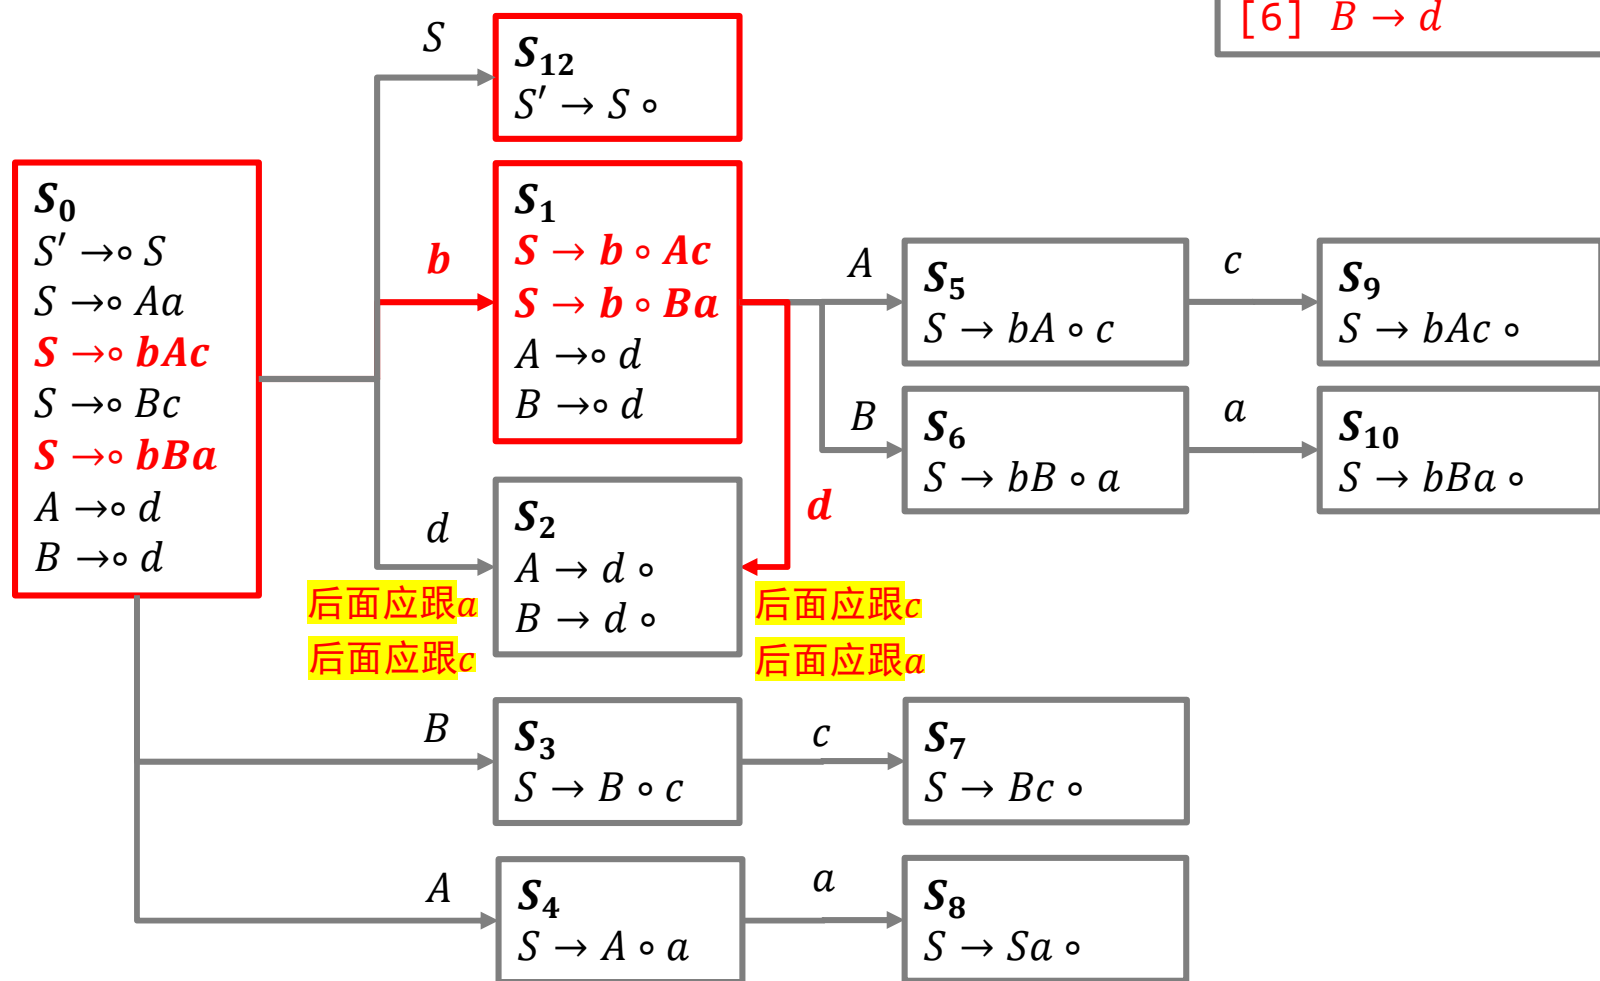
[1]	$S \rightarrow \beta_0 \beta_1 X \beta_2$
[2]	$S \rightarrow \beta_0 Y$
[3]	$Y \rightarrow \beta_1 \beta_3 \beta_4$
[3]	$X \rightarrow \beta_3$

二义性语法：规约-规约冲突

- 解析bda时存在规约($A \rightarrow d$)-规约($B \rightarrow d$)冲突
 - $a \in \text{Follow}(A)$ 且 $a \in \text{Follow}(B)$
- 解析da、dc等其它句子时存在同样的问题。

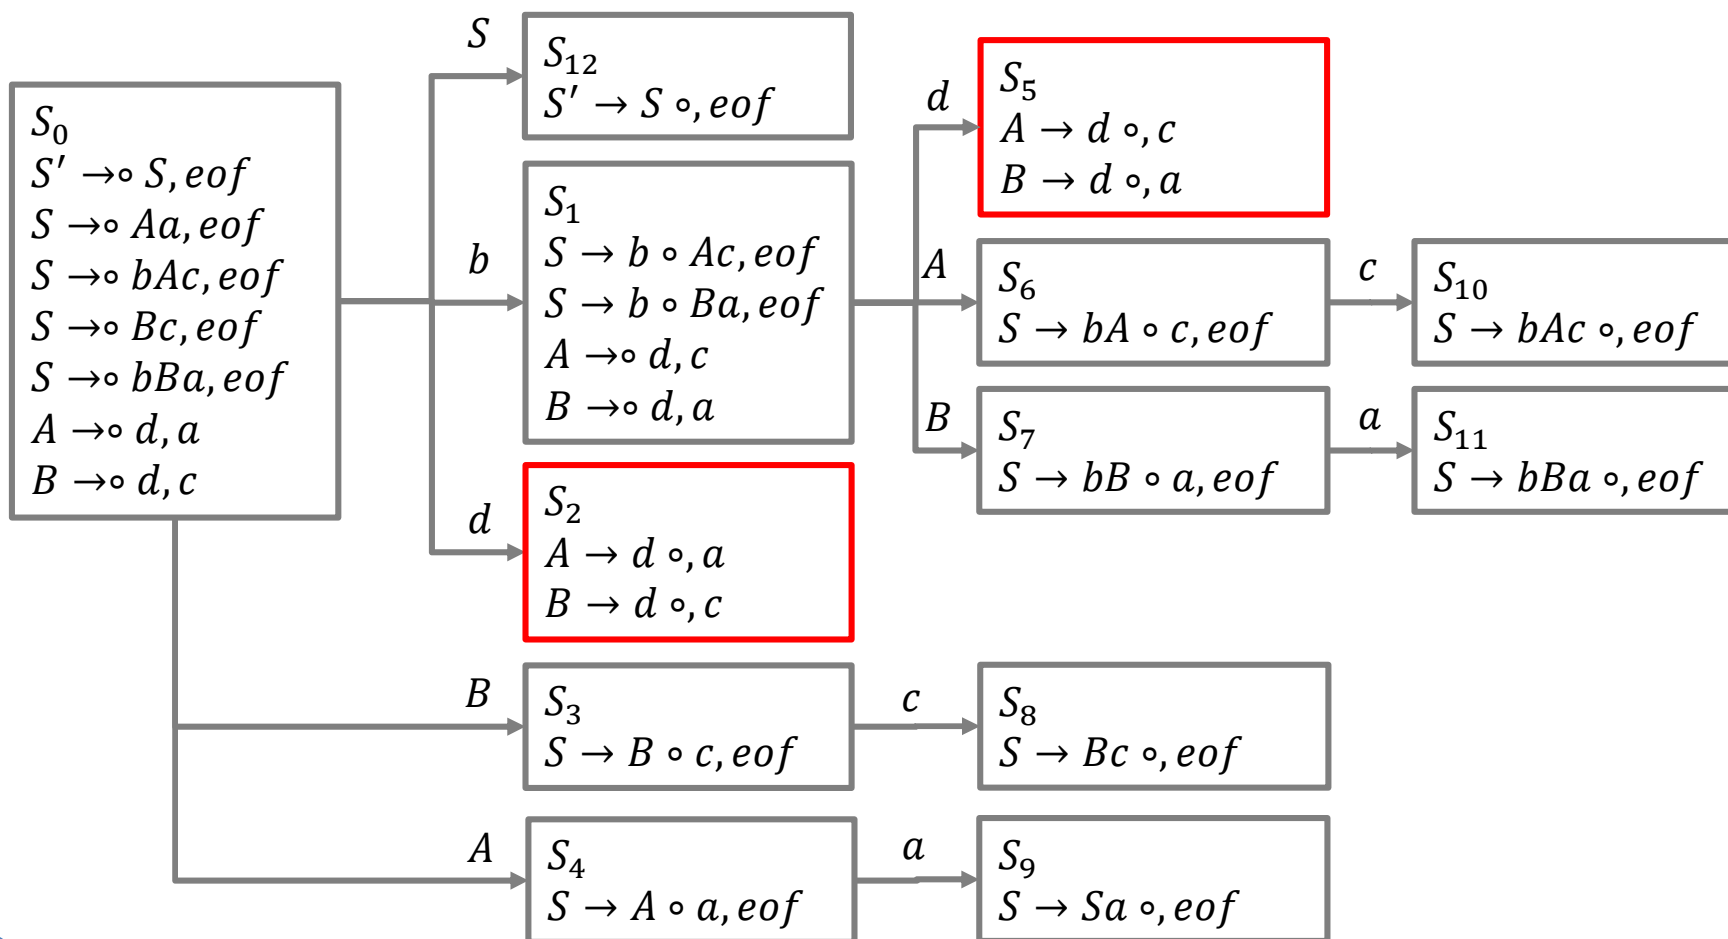
```

[1]  $S \rightarrow Aa$ 
[2]    $|bAc$ 
[3]    $|Bc$ 
[4]    $|bBa$ 
[5]  $A \rightarrow d$ 
[6]  $B \rightarrow d$ 
    
```



LR(1)自动机构造

[1] $S \rightarrow Aa$
 [2] $\quad \quad |bAc$
 [3] $\quad \quad |Bc$
 [4] $\quad \quad |bBa$
 [5] $A \rightarrow d$
 [6] $B \rightarrow d$



什么情况下容易出现规约-规约冲突?

[1]	$S \rightarrow Aa$
[2]	$\quad bAc$
[3]	$\quad Bc$
[4]	$\quad bBa$
[5]	$A \rightarrow d$
[6]	$B \rightarrow d$

[1]	$S \rightarrow \beta_1 X \beta_2$
[2]	$\quad \beta_1 Y \beta_3$
[3]	$X \rightarrow \beta_4$
[4]	$Y \rightarrow \beta_4$

- 同一非终结符的两条规则：
 - 拥有共同的起始字符串 β_1 ;
 - β_1 后面分别为非终结符 $X\beta_2$ 和字符串 $Y\beta_3$;
 - 存在规则 $X \rightarrow \beta_4$ 和 $Y \rightarrow \beta_4$ 。
 - $Follow(X) \cap Follow(Y) \neq \emptyset$
- 或存在两种推导满足上述条件，如

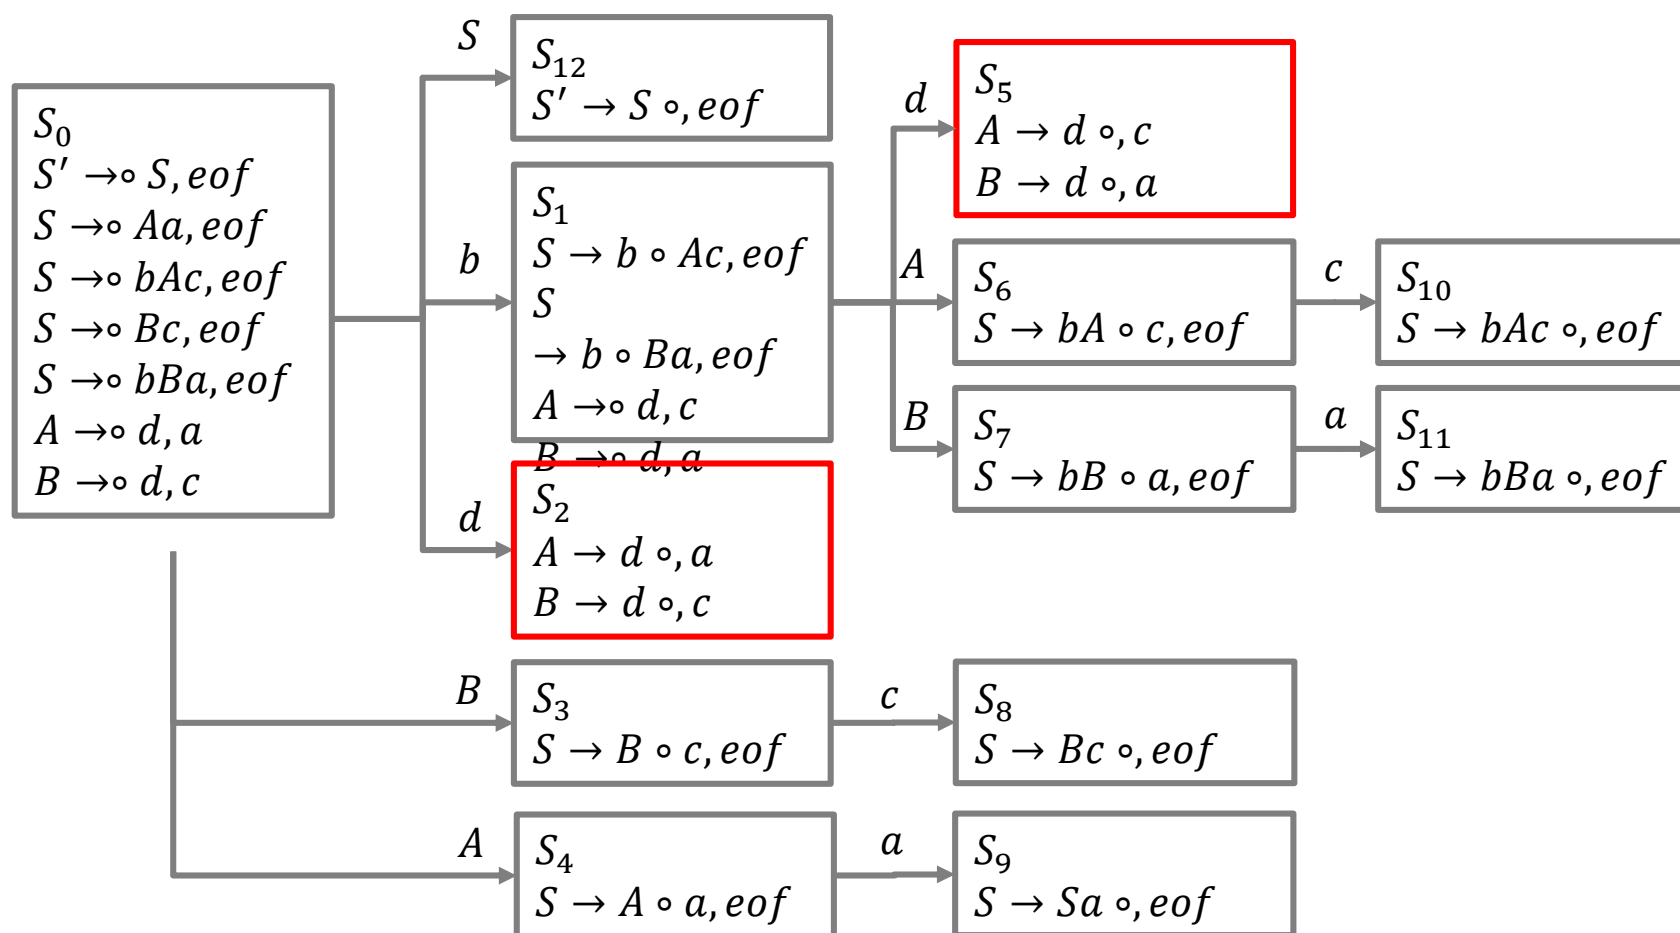
[1]	$S \rightarrow \beta_0 X$
[2]	$\quad \beta_0 \beta_1 Y \beta_3$
[3]	$X \rightarrow \beta_1 Z \beta_2$
[4]	$Y \rightarrow \beta_4$
[5]	$Z \rightarrow \beta_4$

思考：SLR和LR如何选取移进、规约操作？

- SLR维护当前的栈顶句柄信息
 - 通过构造LR(0)自动机和下一个字符判断是否可以移进
 - 需要规约时根据Follow判断是否可行
- 经典LR(1)思路类似：
 - 自动机构造时考虑Follow信息；
 - 但LR(1)的规范项和规范集数量很多
- 折中思路：LALR (Lookahead LR)
 - 自动机构造时考虑Follow信息
 - 同时精简规范集

LALR构造思路


- 合并句柄状态完全相同的状态集
- 下面LR(1)自动机 S_2 和 S_5 可以合并，但合并后存在规约-规约冲突
 - 该语法不是LALR



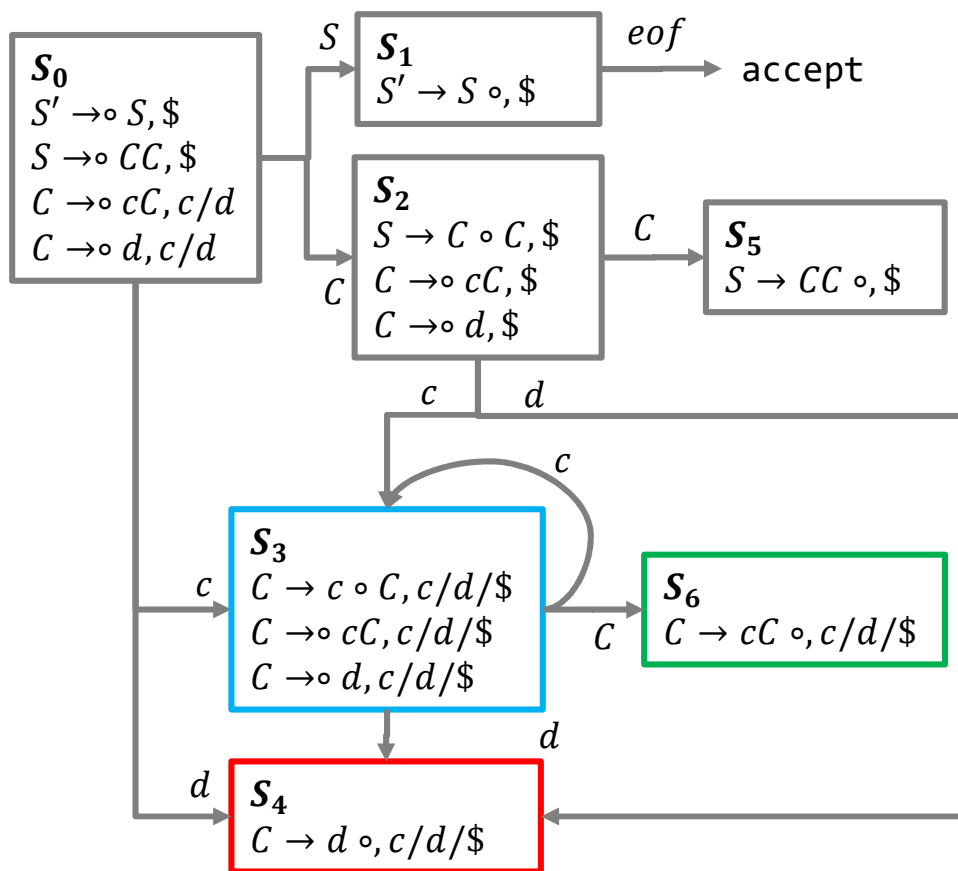
LALR语法举例

- [1] $S' \rightarrow S$
- [2] $S \rightarrow CC$
- [3] $C \rightarrow cC$
- [4] $\quad \quad | d$

- 可以合并的规范集
 - S3和S6、S4和S7、S8和S9；
 - Follow项取并集。



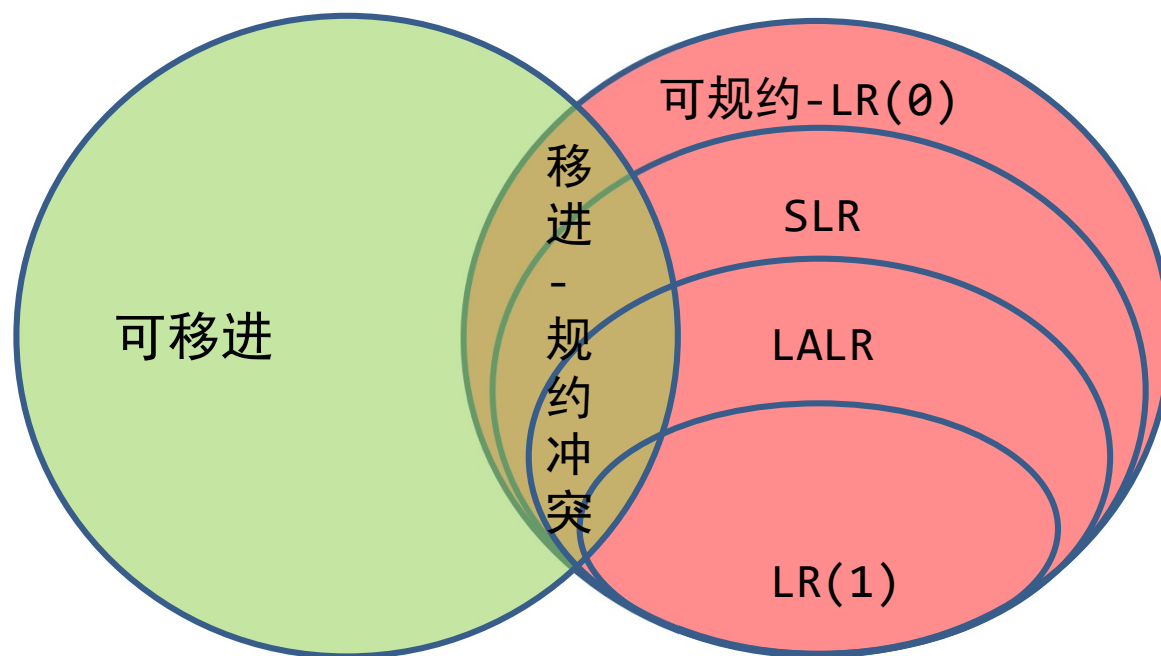
LALR解析表



规范项				Goto	
	c	d	eof	S	C
S ₀	shift S ₃	shift S ₄		S ₁	S ₂
S ₁			accept		
S ₂	shift S ₃				S ₅
S ₃	shift S ₃	shift S ₄			S ₆
S ₄	reduce [4]	reduce [4]	reduce [4]		
S ₅			reduce [2]		
S ₆	reduce [3]	reduce [3]	reduce [3]		

几种语法的关系

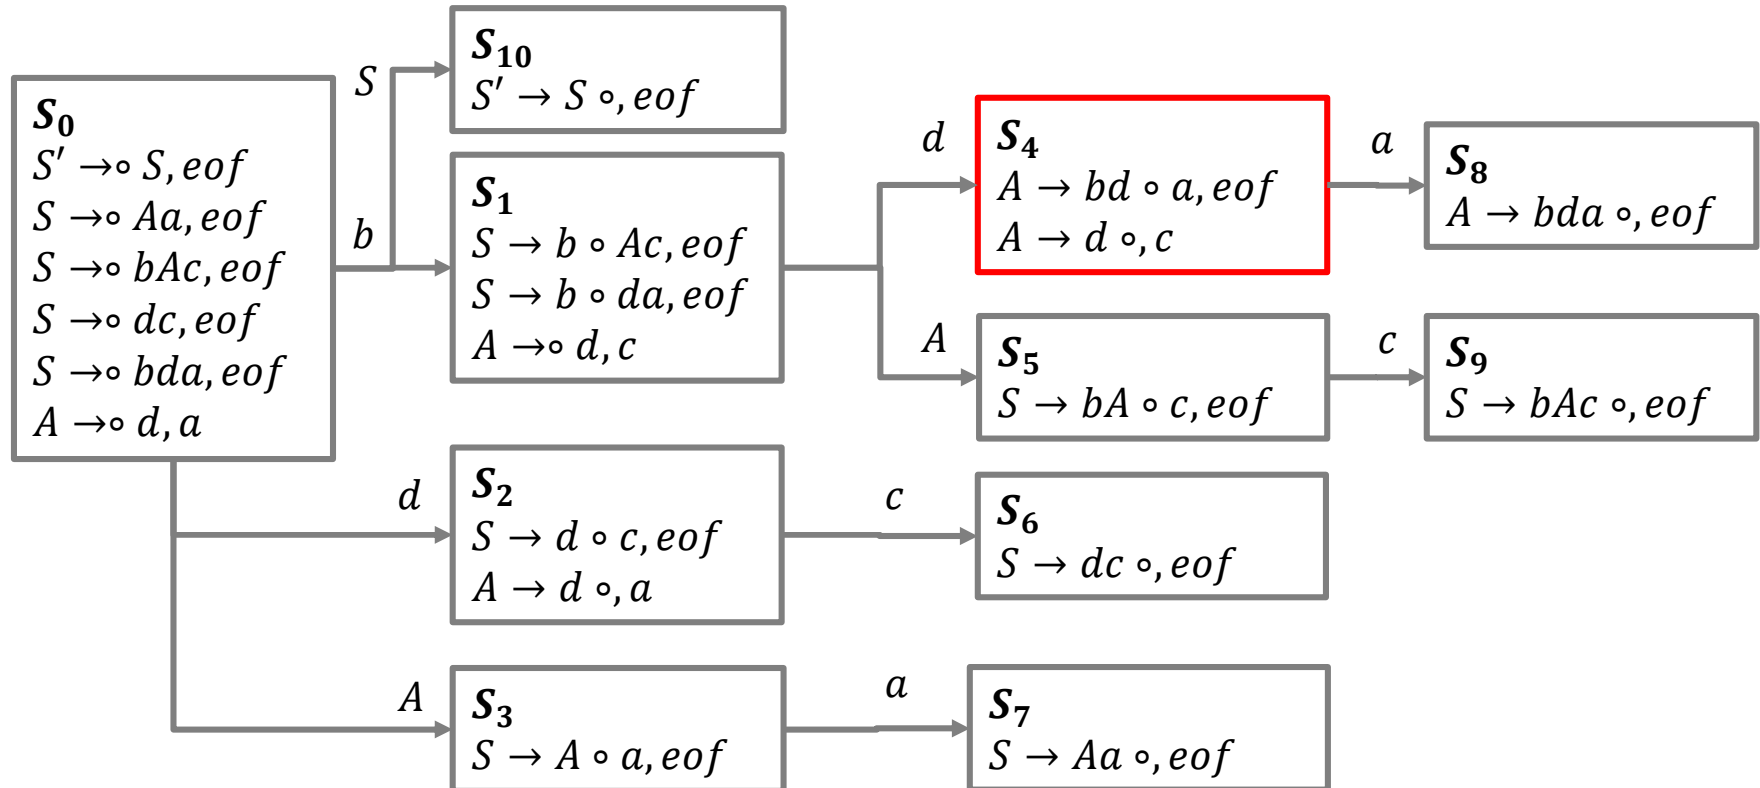
- 语法表达能力: $LR(1) > LALR(1) > SLR$
 - 规约条件严苛: $LR(1) > LALR(1) > SLR$
 - 移进条件同 $LR(0)$?



举例：LALR，非SLR(1)语法

- 构造SLR解析表则解析bda时存在移进-规约冲突
- LALR解析方法可以避免冲突

[1]	$S \rightarrow Aa$
[2]	$\quad bAc$
[3]	$\quad dc$
[4]	$\quad bda$
[5]	$A \rightarrow d$



思考

- LL(1)语法一定是LR(1)吗？为什么？
 - 不一定是SLR(1)
 - 不一定是LALR(1)

举例说明：LL(1)非SLR(1)

[1] $S \rightarrow AaAb$
 [2] $\quad \quad |BbBa$
 [3] $A \rightarrow \epsilon$
 [4] $B \rightarrow \epsilon$

是LL(1)

- $First^+(S \rightarrow AaAb) = \{a\}$

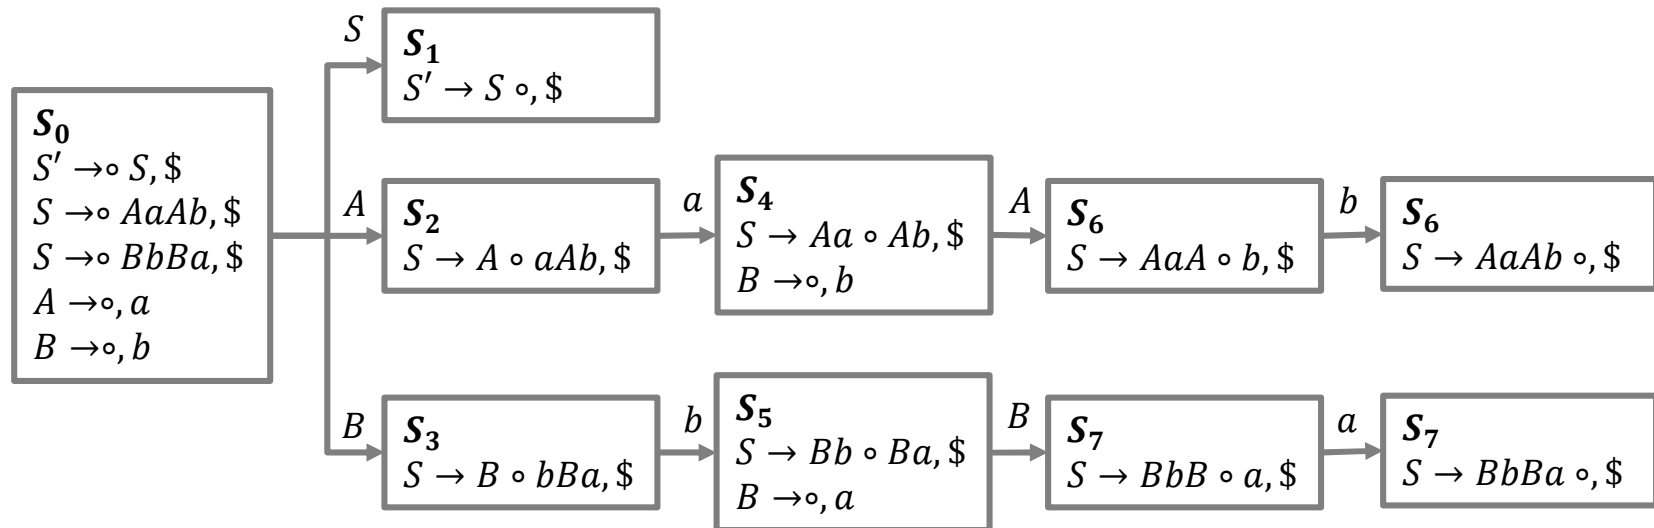
- $First^+(S \rightarrow BbBa) = \{b\}$

不是SLR(1)

- $Follow(A) = Follow(B) = \{a, b\}$

- $Action(S_0, a) = reduce[3] \text{ 或 } reduce[4]$

是LR(1)



举例说明：LL(1)非LALR(1)

[1]	$S \rightarrow aAaAb$
[2]	$\quad bBbBa$
[3]	$A \rightarrow b$
[4]	$B \rightarrow b$

练习

- 下列语法是否是LR(1) ?


```
< regex > ::= < union > | < concat >  
< union > ::= < regex > "|" < concat >  
< concat > ::= < concat > < term > | < term >  
< term > ::= < element > * | < element >  
< element > ::= (< regex > ) | < alphanum >
```

```
[1] < regex > ::= < concat > < regex' >  
[2] < regex' > ::= "|" < concat > < regex' >  
[3]           | $\epsilon$   
[4] < concat > ::= < term > < concat' >  
[5] < concat' > ::= < term > < concat' >  
[6]           | $\epsilon$   
[7] < term > ::= < element > < follow >  
[8] < follow > ::= *  
[9]           | $\epsilon$   
[10] < element > ::= (< regex > )  
[11]           | < alphanum >
```

如果LR（1）不够用怎么办？

- LR(1)解析表存在冲突
- GLR (Generalized LR)
 - 遇到冲突时分别尝试两种解析指令
 - 复制栈状态，维护解析搜索树

通用自底向上CFG分析： CYK算法



CYK解析算法伪代码参考

INIT:

Grammar: R_1, R_2, \dots, R_r

String to parse: $w = w_1, w_2, \dots, w_l$

$P[n, n, r]$ initied with false

Foreach $i = 1$ to n :

 Foreach $R_r \rightarrow a_i$

$P[1, i, r] = \text{True}$

Foreach $l = 2$ to n :

 Foreach $i = 1$ to $n-l+1$:

 Foreach $j = 1$ to $l-1$:

 Foreach $R_r \rightarrow R_a R_b$

 If $P[j, i, a]$ and $P[l-j, i+j, b]$:

$P[l, i, r] = \text{True}$

If $P[n, 1, 1]$:

w is a string of the language

Else:

w is not a string of the language


参考资料

- 《编译原理（第2版）》第四章：Syntax Analysis;
- 《编译器设计（第2版）》
 - 第三章：语法分析器。

五、语法分析工具

Bison

- 语法分析工具YACC(POSIX)/Bison (GNU)
 - 默认采用LALR(1)解析
 - 支持LR(1)等方法



计算器程序示例

Main.c 计算器文件
Lexer.l 词法定义
Parser.y 语法定义
Expression.h 文件
Expression.c 功能函数

Lex文件

```
%{ /* Lexer.l file */
#include "Expression.h"
#include "Parser.h"
#include <stdio.h> %}

%option outfile="Lexer.c"
header-file="Lexer.h"
%option warn nodefault
%option reentrant noyywrap never-interactive nounistd
%option bison-bridge

%%

[ \r\n\t]* { continue; /* Skip blanks. */ }
[0-9]+ { sscanf(yytext, "%d", &yylval->value); return TOKEN_NUMBER; }
"*" { return TOKEN_STAR; }
"+" { return TOKEN_PLUS; }
"(" { return TOKEN_LPAREN; }
")" { return TOKEN_RPAREN; }
. { continue; /* Ignore unexpected characters. */}

%%

int yyerror(const char *msg) {
    fprintf(stderr, "Error: %s\n", msg);
    return 0;
}
```

```

%{ /* * Parser.y file * */
#include "Expression.h"
#include "Parser.h"
#include "Lexer.h"
int yyerror(SExpression **expression, yyscan_t scanner, const char *msg) { /* Add error
handling routine as needed */ }
%}

%code requires { typedef void* yyscan_t; }
%output "Parser.c"
%defines "Parser.h"
%define api.pure
%lex-param { yyscan_t scanner }
%parse-param { SExpression **expression }
%parse-param { yyscan_t scanner }
%union { int value; SExpression *expression; }
%token TOKEN_LPAREN "("
%token TOKEN_RPAREN ")"
%token TOKEN_PLUS "+"
%token TOKEN_STAR "*"
%token <value> TOKEN_NUMBER "number"
%type <expression> expr

/* Precedence (increasing) and associativity */
%left "+"
%left "*" %

%%
input : expr { *expression = $1; } ;
expr : expr[L] "+" expr[R] { $$ = createOperation( eADD, $L, $R ); }
    | expr[L] "*" expr[R] { $$ = createOperation( eMULTIPLY, $L, $R ); }
    | "(" expr[E] ")" { $$ = $E; }
    | "number" { $$ = createNumber($1); }
} ; %%

```

main.c

```
int yyparse(SExpression **expression, yyscan_t scanner);
SExpression *getAST(const char *expr) {
    SExpression *expression;
    yyscan_t scanner;
    YY_BUFFER_STATE state;
    if (yylex_init(&scanner)) return NULL;
    state = yy_scan_string(expr, scanner);
    if (yyparse(&expression, scanner)) return NULL;
    yy_delete_buffer(state, scanner);
    yylex_destroy(scanner);
    return expression;
}

int evaluate(SExpression *e) {
    switch (e->type) {
        case eVALUE: return e->value;
        case eMULTIPLY: return evaluate(e->left) * evaluate(e->right);
        case eADD: return evaluate(e->left) + evaluate(e->right);
        default: /* should not be here */ return 0;
    }
}

int main(void) {
    char expr[256];
    scanf("%s", expr);
    SExpression *e = getAST(test);
    int result = evaluate(e);
    printf("Result of '%s' is %d\n", test, result);
    deleteExpression(e);
    return 0;
}
```


Expression.h

```
#ifndef __EXPRESSION_H__
#define __EXPRESSION_H__

typedef enum tagEOperationType {
    eVALUE,
    eMULTIPLY,
    eADD
} EOperationType;

typedef struct tagSExpression {
    EOperationType type; /* /< type of operation */
    int value; /* /< valid only when type is eVALUE */
    struct tagSExpression *left; /* /< left side of the tree */
    struct tagSExpression *right; /* /< right side of the tree */
} SExpression;

SExpression *createNumber(int value);
SExpression *createOperation(EOperationType type, SExpression *left, SExpression *right);
void deleteExpression(SExpression *b);

#endif
```

Expression.c

```
static SExpression *allocateExpression() {
    SExpression *b = (SExpression *)malloc(sizeof(SExpression));
    if (b == NULL) return NULL;
    b->type = eVALUE;
    b->value = 0;
    b->left = NULL;
    b->right = NULL;
    return b;
}

SExpression *createNumber(int value) {
    SExpression *b = allocateExpression();
    if (b == NULL) return NULL;
    b->type = eVALUE;
    b->value = value;
    return b;
}

SExpression *createOperation(EOperationType type, SExpression *left, SExpression *right) {
    SExpression *b = allocateExpression();
    if (b == NULL) return NULL;
    b->type = type;
    b->left = left;
    b->right = right;
    return b;
}

void deleteExpression(SExpression *b) {
    if (b == NULL) return;
    deleteExpression(b->left);
    deleteExpression(b->right);
    free(b);
}
```

总结

一、句式分析的基本概念

二、LLVM案例分析

三、自顶向下分析

- LL(1)语言
- 通用算法：Earley算法

四、自底向上分析

- SLR、LALR、LR(1)语言
- 通用算法：GLR算法、CYK算法

五、语法分析工具